

《概率论与数理统计》



数理统计的分类

描述统计学——

对随机现象进行观测、试验，
以取得有代表性的观测值

推断统计学——

对已取得的观测值进行整理、
分析, 作出推断、决策, 从而
找出所研究的对象的规律性

引言

碳酸饮料质量抽查合格率不足八成

国家质检总局7月9日公布的国家监督抽查结果表明：



碳酸饮料

抽查范围：

广东、广西、湖南、湖北、云南、四川、重庆、山西、陕西等9个省、自治区、直辖市

抽查企业

26家

抽查产品

31种

合格

23种

抽样合格率

74.2%

抽查中发现的主要质量问题

- 可溶性固形物不合格
- 总酸不合格
- 二氧化碳气容量不合格
- 超限量使用糖精钠
- 菌落总数超标

产品质量存在问题被予以公开曝光的三家企业

南宁市庆丰工贸有限责任公司
南宁市金茶山果蔬食品饮料厂
昆明市森泉饮品有限公司

张立云 编制 新华社发

产品的合格率

图4 中国未梳棉月度进口量

单位：吨





图4 中国棉花进口量及占全球贸易的比重

单位：千吨

单位：%



艾塔农业

农作物进口量

1. 您最不满意的龙年春晚节目是？



诺奖得者为何说“人工智能其实就是统计学” AI真的只是华丽辞藻吗




思维解构

发布时间：18-08-12 17:15

2018年8月11日，诺贝尔经济学奖获得者Thomas J. Sargent（托马斯·萨金特）在“共享全球智慧 引领未来科技”世界科技创新论坛上表示：人工智能其实就是统计学，只不过用了一个很华丽的辞藻。

托马斯·萨金特是谁呢？



作者最新文章

诺奖得者为何说“人工智能其实就是统计学”AI真的只是华丽辞藻吗

Galaxy Note9启迪未来？

Bixby：告别“扫一扫”，迎来“我看看”

是否想要无强迫植入内置软件的纯净系统，它可以带给你原生态安卓

相关文章

统计学为基础，人工智能的核心知识还有数学（博弈论、数值分析、逻辑学等）、运筹学（优化）、计算机科技（分布式计算、并行计算、*CPU*、*NPU*）、神经科学，甚至心理学。

2016年3月15
日,谷歌围棋人
工智能
AlphaGo战胜
韩国棋手李世
石,掀起了近
年人工智能发
展的高潮。



机器学习

人工智能中的统计学

- 机器学习涉及概率论、统计学、逼近论、凸分析、计算复杂性理论等多门学科。
- 机器学习理论主要是设计和分析一些让计算机可以自动“学习”的算法。
- 机器学习从数据中自动分析获得规律，并利用规律对未知数据进行预测。
- 因为学习算法中涉及了大量的统计学理论，机器学习与推断统计学联系尤为密切，也被称为统计学习理论。

2014年微软推出的“**小冰**”，就是借助微软在大数据、自然语义分析、机器学习和深度神经网络方面的技术积累，

将中国**近7亿网民**多年积累的**公开文献记录**精炼为**几千万条**真实而有趣的**语料库**，通过分析**对话的语境与语义**，实现了超越简单人机问答的自然交互。



数据挖掘

- 数据挖掘从大量的资料中自动搜索隐藏于其中的有着特殊关联性信息的过程。
- 数据挖掘通常通过统计、在线分析处理、情报检索、专家系统（依靠过去的经验法则）和模式识别等诸多方法来实现目标。

故事：Target超市预测女孩怀孕：“大数据”智慧，还是愚蠢？

2012年2月16日，《纽约时报》刊登了Charles Duhigg撰写的一篇题为《这些公司是如何知道您的秘密的》（How Companies Learn Your Secrets）的报道。文中介绍了这样一个故事

一天，一位男性顾客怒气冲冲地来到一家折扣连锁店Target（中文常译作“塔吉特”，为仅次于沃尔玛的全美第二大零售商），向经理投诉，因为该店竟然给他还在读高中的女儿，邮寄婴儿服装和孕妇服装的优惠券。

但随后，这位父亲与女儿进一步沟通发现，自己女儿真的已经怀孕了。于是致电Target道歉，说他误解商店了，女儿的预产期是8月份。

How Companies Learn Your Secrets

By CHARLES DUHIGG FEB. 16, 2012

Email

Share

Tweet

Pin

Save

More

mistress
america
august 14

Andrew Pole had just started working as a statistician for Target in 2002, when two colleagues from the marketing department stopped by his desk to ask an odd question: "If we wanted to figure out if a customer is pregnant, even if she didn't want us to know, can you do that?"

Pole has a master's degree in statistics and another in economics, and has been obsessed with the intersection of data and human behavior most of his life. His parents were teachers in North Dakota, and while other kids were going to 4-H, Pole was doing algebra and writing computer programs. "The stereotype of a math nerd is true," he told me when I spoke with him last year. "I kind of like going out and evangelizing analytics."

As the marketers explained to Pole — and as Pole later explained to me, back when we were still speaking and before



Antonio Bolfo/Reportage for The New York Times

大数据文摘

一家零售商是如何比一位女孩的亲生父亲更早得知其怀孕消息的呢？这里需要用到“**关联规则+预测推荐**”技术。

事实上，每位顾客初次到Target刷卡消费时，都会自动获得一个**唯一顾客识别编号**（ID）。以后，顾客再次光临Target消费时，计算机系统就会**自动记录顾客购买的商品、时间等信息**。再加上从其它管道取得的统计资料，Target便能形成一个庞大数据库，运用于**分析顾客的喜好与需求**。

有了数据，特别是有了“大”容量的数据，后面的问题就简单了。Target的数据分析师，开发了很多预测模型，其中**怀孕预测模型**（pregnancy-prediction model）就是其中的一个。Target通过分析这位女孩的购买记录——**无味湿纸巾和补镁药品**，就预测到了这为女顾客可能怀孕了，而怀孕了，**未来就有可能需要购置婴儿服装和孕妇服装**，多么贴心的商店。




第六章 样本及抽样分布

故事：谷歌流感预测

2009年2月，谷歌公司的工程师们在国际著名学术期刊《自然》上发表了一篇非常有意思的论文：《**利用搜索引擎查询数据检测流感流行趋势**》，并设计了大名鼎鼎的流感预测系统（Google Flu Trends, GFT，访问网址为：www.google.org/flutrends/）。


GFT预测H1N1流感的原理非常朴素：如果在某一个区域某一个时间段，有大量的有关流感的搜索指令，那么，就可能存在一种潜在的关联：在这个地区，就有很大的可能性存在对应的流感人群，相关部门就值得发布流感预警信息。

GFT监测并预测流感趋势的过程仅需一天，有时甚至可缩短至数个小时。相比而言，美国疾病控制与预防中心（Center for Disease Control and Prevention, CDC）同样也能利用采集来的流感数据，发布预警信息。但CDC的流感预测结果，通常需要滞后两周左右才能得以发布。但对于一种飞速传播的疾病（如禽流感等），疫情预警滞后发布，后果可能是致命的。



人脸识别

- 人脸识别的应用非常广泛，
- 人脸识别将人脸看作一个眼睛鼻子嘴的特征及其位置的几何关系的二维像素矩阵
- 从统计的角度，通过分析大量人脸样本，构造人脸模式空间，然后再根据相似度识别不同人脸。



引言

随机变量及其所伴随的概率分布全面描述了随机现象的统计性规律。

- ◆ 概率论的许多问题中，随机变量的概率分布通常是已知的，或者假设是已知的，而一切计算与推理都是在这已知是基础上得出来的。
- ◆ 但实际中，情况往往并非如此，一个随机现象所服从的分布可能是完全不知道的，或者知道其分布概型，但是其中的某些参数是未知的。

第六章 样本及抽样分布

例如：

某公路上行驶车辆的速度服从什么分布是未知的；

电视机的使用寿命服从什么分布是未知的；

产品是否合格服从两点分布，但参数——合格率 p 是未知的；

数理统计的任务则是以概率论为基础，根据试验所得到的数据，对研究对象的客观统计规律性做出合理的推断。

学习的基本内容

从现在开始，我们学习**数理统计**的基础知识。主要有**参数估计**、**假设检验**等内容.本章主要介绍数理统计的一些基本术语、基本概念、重要的统计量及其分布，它们是后面各章的基础。

第六章、样本及抽样分布

第一节：随机样本

第二节：抽样分布

第一节 随机样本

- 总体和样本
- 小结

一、总体与样本

1、总体与个体

一个统计问题总有它明确的研究对象。

研究对象的全体称为**总体**，总体中每个成员称为**个体**

总体中所包含的个体的个数称为总体的**容量**。



总体 {
有限总体
无限总体

研究某批灯泡的质量

第六章 样本及抽样分布

我们关心的是总体中的个体的某项指标(如人的身高、灯泡的寿命, 汽车的耗油量...) .

由于每个个体的出现是随机的, 所以相应的数量指标的出现也带有随机性. 从而**可以把这种数量指标看作一个随机变量 X** , 因此随机变量 X 的分布就是该数量指标在总体中的分布.

总体就可以用一个随机变量及其分布来描述.

因此在理论上可以把总体与概率分布等同起来.

例如:研究某批灯泡的寿命时,关心的数量指标就是寿命,那么,此**总体**就可以用**随机变量 X** 表示,或用其**分布函数 $F(x)$** 表示.



某批
灯泡的寿命



寿命 X 可用一概率
(指数) 分布来刻画



寿命总体是指数分布总体


鉴于此,常用**随机变量的记号**
或用**其分布函数表示总体**. 如
说总体 X 或总体 $F(x)$.

类似地，在研究某地区中学生的营养状况时，若关心的数量指标是身高和体重，我们用 X 和 Y 分别表示身高和体重，那么此总体就可用二维随机变量 (X, Y) 或其联合分布函数 $F(x, y)$ 来表示。

统计中，总体这个概念的要旨是：
总体就是一个随机变量(向量)或一个概率分布。

2、样本

总体中**抽出**若干个体而成的集体,称为**样本**。
样本中所含个体的个数, 称为**样本容量**。



从国产轿车中抽5辆
进行耗油量试验
样本容量为5

抽到哪5辆是随机的

研究的对象是整体, 而观察的是局部

第六章 样本及抽样分布

注1：所谓样本就是 n 个与总体同分布的随机变量。


对总体 X 在相同的条件下，进行 n 次重复、独立观察，其结果依次记为 $X_1, X_2, \dots, X_n$ 。

这样得到的随机变量 $X_1, \dots, X_n$ 是来自总体的随机样本，与总体**同分布**。

一旦**取定**一组样本 $X_1, \dots, X_n$ ，得到 n 个**具体的数** $(x_1, x_2, \dots, x_n)$ ，称为样本的一次观察值，简称**样本值**。

最常用的一种抽样叫作“简单随机抽样”，其特点：

1. 代表性： $X_1, X_2, \dots, X_n$ 中每一个与所考察的总体有相同的分布.
2. 独立性： $X_1, X_2, \dots, X_n$ 是相互独立的随机变量.



抽样中的泰坦尼克事件

在抽样调查中，**样本的选择是至关重要的**，样本能否代表总体，直接影响着统计结果的可靠性。下面的故事是一次著名的失败的统计调查，它可以帮助我们理解为什么一个好的样本如此重要。

在**1936**年美国总统选举前，《Literary Digest》杂志的工作人员做了一次民意调查。调查兰顿（当时任堪萨斯州州长）和罗斯福（当时的总统）中谁将当选下一届总统。为了了解公众意向，调查者通过**电话簿和车辆登记簿上的名单**给**1000**万人发了调查表（注意在**1936**年电话和汽车只有少数富人拥有）。通过分析收回的**230**万份调查表，**显示兰顿非常受欢迎**，于是杂志预测兰顿将在选举中获胜。

实际上选举结果正好相反，最后罗斯福在选举中获胜，其数据如下：



候选人	预测结果	选举结果
罗斯福	4 3	6 2
兰顿	5 7	3 8

第六章 样本及抽样分布

原因是：用于统计推断的样本来自少数富人，只能代表富人的观点，不能代表全体选民的观点（样本不具有代表性）。



F . D . Roosevelt

A . Landon

1. 我们常常根据样本得到结果来推测总体的结果。不同的抽样可能得到不同的结果。

2. 为了使结果更具准确性，抽样时，样本的容量要合理，样本的个体要有代表性。



定义:

设 X 是具有分布函数 F 的随机变量，若 $X_1, X_2, \dots, X_n$ 是具有同一分布函数 F 的、相互独立的随机变量，则称 $X_1, X_2, \dots, X_n$ 为从分布函数 F （或总体 F 、或总体 X ）得到的容量为 n 的简单随机样本，简称样本，它们的观察值 $x_1, x_2, \dots, x_n$ 称为样本值，又称为 X 的 n 个独立的观察值

由简单随机抽样得到的样本称为简单随机样本，它可以用与总体独立同分布的 n 个相互独立的随机变量 $X_1, X_2, \dots, X_n$ 表示.

若总体的分布函数为 $F(x)$ 、概率密度函数为 $f(x)$,则其简单随机样本的联合分布函数为

$$F^*(x, x_2, \dots, x_n) = F(x_1) F(x_2) \dots F(x_n)$$

其简单随机样本的联合概率密度函数为

$$f^*(x, x_2, \dots, x_n) = f(x_1) f(x_2) \dots f(x_n)$$

简单随机样本是应用中最常见的情形，今后，当说到“ $X_1, X_2, \dots, X_n$ 是取自某总体的样本”时，若不特别说明，就指简单随机样本。


3. 总体、样本、样本值的关系

事实上我们抽样后得到的资料都是**具体的、确定的值**。

如我们从某班大学生中抽取10人测量身高,得到10个数, 它们是样本**取到的值**而不是样本。

我们只能**观察到随机变量取的值**而见不到随机变量。

第六章 样本及抽样分布



统计是从手中已有的资料--**样本值**，去**推断总体**的情况---总体分布 $F(x)$ 的性质.

样本是联系二者的桥梁

总体分布决定了样本取值的概率规律，也就是样本取到样本值的规律，因而可以**由样本值去推断总体**.

第六章 样本及抽样分布

为了研究总体分布的性质，人们通过试验得到很多观察值，一般来说这些数据是杂乱无章的。为了利用它们进行统计分析，将这些数据加以**整理**，还常**借助于表格或图形**对它们加以**描述**。

第二节：直方图和箱线图（略）



第六章 样本及抽样分布

样本是进行统计推断的依据。在应用时，往往不是直接使用样本本身，而是需要对样本值进行“**加工**”，针对不同的问题**构造样本的适当函数**，它把样本中所含的（某一方面）的信息集中起来，利用这些样本的函数进行统计推断。

如何对样本进行加工？

——**统计量**及其分布



第三节 抽样分布

- 统计量与经验分布函数
- 统计三大抽样分布
- 几个重要的抽样分布定理
- 小结

一、统计量与经验分布函数

1. 统计量

不含任何未知参数的样本的函数称为统计量。
它是完全由样本决定的量。

设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的一个样本， $g(X_1, X_2, \dots, X_n)$ 是 $X_1, X_2, \dots, X_n$ 的函数，若 g 中不含未知参数，则 $g(X_1, X_2, \dots, X_n)$ 称是一个统计量。

第六章 样本及抽样分布

例 设总体 X 服从两点分布 $b(1, p)$, 其中 p 是未知参数, $X_1, \dots, X_5$ 是来自 X 的简单随机样本. 试指出 $X_1 + X_2$, $\max_{1 \leq i \leq 5} X_i$, $X_5 + 2p$, $(X_5 - X_1)^2$ 之中哪些是统计量, 哪些不是统计量, 为什么?

解:

例 设总体 X 服从两点分布 $b(1, p)$, 其中 p 是未知参数, $X_1, \dots, X_5$ 是来自 X 的简单随机样本. 试指出 $X_1 + X_2$, $\max_{1 \leq i \leq 5} X_i$, $X_5 + 2p$, $(X_5 - X_1)^2$ 之中哪些是统计量, 哪些不是统计量, 为什么?

解:

$X_1 + X_2, \max_{1 \leq i \leq 5} X_i, (X_5 - X_1)^2$ 都是统计量, 但

$X_5 + 2p$ 不是统计量 (因为 p 是未知数).

第六章 样本及抽样分布

例 设 $X_1, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的一个样本, 其中 μ 未知, σ^2 已知, 问下列随机变量中那些是统计量

$$\min(X_1, X_2, \dots, X_n); \frac{X_1 + X_n}{2}; \frac{X_1 + \dots + X_n}{n} - \mu; \\ \frac{(X_1 + X_n)^2}{\sigma^2}; \frac{(X_1 + \dots + X_n) - n\mu}{\sqrt{n}\sigma}.$$

第六章 样本及抽样分布

例 设 $X_1, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的一个样本, 其中 μ 未知, σ^2 已知, 问下列随机变量中那些是统计量

$$\min(X_1, X_2, \dots, X_n); \frac{X_1 + X_n}{2}; \frac{X_1 + \dots + X_n}{n} - \mu; \\ \frac{(X_1 + X_n)^2}{\sigma^2}; \frac{(X_1 + \dots + X_n) - n\mu}{\sqrt{n}\sigma}.$$

注意：

(1) 统计量：对样本的加工。是一个随机变量。

(2) 设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的一个样本, $x_1, x_2, \dots, x_n$ 是一个样本的观察值则 $f(x_1, x_2, \dots, x_n)$ 也是统计量 $f(X_1, X_2, \dots, X_n)$ 的观察值.

几个常见统计量

样本平均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

它反映了
总体均值的
信息

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

它反映了总体
方差的信息

$$= \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

样本标准差

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

第六章 样本及抽样分布

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} [\sum_{i=1}^n X_i^2 - n\bar{X}^2]$$

证明:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)$$

$$= \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2)$$

$$= \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - 2\bar{X}n\bar{X} + n\bar{X}^2)$$

$$= \frac{1}{n-1} [\sum_{i=1}^n X_i^2 - n\bar{X}^2]$$

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k=1,2,\dots$$

它反映了总体 k 阶矩的信息

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

$$k=1,2,\dots$$

它反映了总体 k 阶中心矩的信息

第六章 样本及抽样分布

它们的观察值分别为:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right]$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$a_k = \frac{1}{n} \sum_{i=1}^n x_i^k, \quad k = 1, 2, \dots$$

$$b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, \quad k = 1, 2, \dots$$

分别称为样本均值、样本方差、样本标准差、样本 k 阶原点矩、样本 k 阶中心矩的**观察值**。

结论： 设 $X_1, \dots, X_n$ 为来自总体 X 的一个样本，

$$EX = \mu, DX = \sigma^2,$$

则 $E\bar{X} = \mu, D\bar{X} = \frac{\sigma^2}{n}, ES^2 = \sigma^2.$

请记熟此结论！


证明：

$$E\bar{X} = E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{\sum_{i=1}^n EX_i}{n} = \mu$$

$$D\bar{X} = D\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{\sum_{i=1}^n DX_i}{n^2} = \frac{\sigma^2}{n}$$

$$\begin{aligned}
ES^2 &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} E\left[\sum_{i=1}^n X_i^2 - n\bar{X}^2\right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n EX_i^2 - nE\bar{X}^2\right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n (DX_i + (EX_i)^2) - n(D\bar{X} + (E\bar{X})^2)\right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right)\right] \\
&= \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2) = \sigma^2
\end{aligned}$$


例： 设总体 $X \sim N(52, 6.3^2)$ 中随机抽取一容量为 36 的样本，求样本均值 $\bar{X}$ 落在 50.8 和 53.8 之间的概率。



例： 设总体 $X \sim N(52, 6.3^2)$ 中随机抽取一容量为 36 的样本，求样本均值 $\bar{X}$ 落在 50.8 和 53.8 之间的概率。

解 $\therefore \bar{X} \sim N\left(52, \frac{6.3^2}{36}\right)$

$$\therefore \frac{\bar{X} - 52}{\frac{6.3}{\sqrt{36}}} \sim N(0, 1)$$



$$P(50.8 < \bar{X} \leq 53.8)$$

$$= P\left(\frac{50.8 - 52}{\frac{6.3}{\sqrt{36}}} < \frac{\bar{X} - 52}{\frac{6.3}{\sqrt{36}}} \leq \frac{53.8 - 52}{\frac{6.3}{\sqrt{36}}}\right)$$

$$= P\left(-1.14 < \frac{\bar{X} - 52}{\frac{6.3}{\sqrt{36}}} \leq 1.71\right)$$

$$= \phi(1.71) - \phi(-1.14) = 0.9564 - (1 - 0.8729) = 0.8293$$

请注意：

若总体 X 的 k 阶矩 $E(X^k) = \mu^k$ 存在，则当 $n \rightarrow \infty$ 时，

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{p} \mu^k \quad k = 1, 2, \dots.$$

事实上 由 $X_1, X_2, \dots, X_n$ 独立且与 X 同分布，
有 $X_1^k, X_2^k, \dots, X_n^k$ 独立且与 X^k 同分布， $E(X_i^k) = \mu^k$
 $k = 1, 2, \dots, n$ 再由辛钦大数定律可得上述结论。

再由依概率收敛性质知，可将上述性质推广为

$$g(A_1, A_2, \dots, A_k) \xrightarrow{p} g(\mu_1, \mu_2, \dots, \mu_k)$$

其中 g 为连续函数。

这就是矩估计法的理论根据。

2. 经验分布函数

设 $X_1, X_2, \dots, X_n$ 是总体 F 的一个样本, 用 $s(x)$ $|x| < \infty$ 表示 $x_1, x_2, \dots, x_n$ 中不大于 x 的随机变量的个数.

定义 经验分布函数为

$$F_n(x) = \frac{1}{n} s(x) \quad -\infty < x < \infty$$

例 设总体 F 具有一个样本值1,1,2, 则经验分布函数 $F_3(x)$ 的观察值为

$$F_3(x) = \begin{cases} 0, & \text{若 } x < 1 \\ \frac{2}{3}, & \text{若 } 1 \leq x < 2 \\ 1, & \text{若 } x \geq 2 \end{cases}$$

一般，设 $x_1, x_2, \dots, x_n$ 是总体的一个容量为 n 的样本值.将它们按大小次序排列如下： $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$
则经验分布函数 $F_n(x)$ 的观察值为

$$F_n(x) = \begin{cases} 0, & \text{若 } x < x_{(1)} \\ \frac{k}{n}, & \text{若 } x_{(k)} \leq x < x_{(k+1)}, \quad (k = 1, 2, \dots, n-1) \\ 1, & \text{若 } x \geq x_{(n)} \end{cases}$$

统计量是样本的函数，它是一个随机变量，

统计量的分布称为**抽样分布**。

在使用统计量进行统计推断时常需知道它的分布。

当总体的分布函数已知时，抽样分布是确定的。

然而要求出统计量的精确分布一般来说是困难的。

二、统计三大抽样分布

1、 χ^2 分布

χ^2 分布是由正态分布派生出来的一种分布.

定义: 设 $X_1, X_2, \dots, X_n$ 相互独立, 都服从正态分布 $N(0,1)$, 则称随机变量:

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

所服从的分布为自由度为 n 的 χ^2 分布.

记为 $\chi^2 \sim \chi^2(n)$

自由度: 上式右端包含的独立变量的个数。

$\chi^2(n)$ 的概率密度

$$f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$


Γ 函数 (Gamma function) 记为 $\Gamma(t)$, 即

$$\Gamma(t) = \int_0^{+\infty} x^{t-1} e^{-x} dx \quad (t > 0)$$

性质: $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha), \alpha > 0$

$$\Gamma(1) = 1 \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi} \quad \Gamma(n+1) = n\Gamma(n) = n!$$

概率密度图形的示意图



可以将绿色的曲线视为 $\chi^2(n)$ 概率密度的代表图形

χ^2 分布的性质:

1⁰ 若 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 且 X, Y 独立, 则有

$$X + Y \sim \chi^2(m + n)$$

这个性质叫 分布的可加性.

2⁰ 若 $\chi^2 \sim \chi^2(n)$, 则 $E\chi^2 = n$, $D\chi^2 = 2n$.

第六章 样本及抽样分布

2⁰ 若 $\chi^2 \sim \chi^2(n)$, 则 $E\chi^2 = n$, $D\chi^2 = 2n$.

证: $\chi^2 = X_1^2 + \cdots + X_n^2$

$$X_i \sim N(0,1), \quad EX_i = 0, \quad DX_i = 1,$$

$$EX_i^2 = DX_i + (EX_i)^2 = 1,$$

$$DX_i^2 = EX_i^4 - (EX_i^2)^2 = 3 - 1 = 2, \quad i = 1, 2, \cdots, n$$

所以 $E\chi^2 = E\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n EX_i^2 = n$

$$D\chi^2 = D\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n DX_i^2 = 2n$$

$$EX_i^4 = \int_{-\infty}^{+\infty} x^4 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$


$$= -x^3 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \Big|_{-\infty}^{+\infty} + 3 \int_{-\infty}^{+\infty} x^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$

$$= 3EX_i^2 = 3$$

3. 若 $\chi^2 \sim \chi^2(n)$, 则当 n 充分大时, $\frac{X - n}{\sqrt{2n}}$ 的分布近似正态分布 $N(0,1)$.

(应用中心极限定理可得)

4. χ^2 分布的分位点



$$\chi_{0.1}^2(25) = 34.382.$$

对于给定的 $\alpha (0 < \alpha < 1)$, 称满足条件:

$$P\{\chi^2 > \chi_{\alpha}^2(n)\} = \int_{\chi_{\alpha}^2(n)}^{\infty} f(y)dy = \alpha$$

的点 $\chi_{\alpha}^2(n)$ 为 $\chi^2(n)$ 分布的 上 α 分位点。

当 n 充分大时, $\chi_{\alpha}^2(n) \approx \frac{1}{2}(z_{\alpha} + \sqrt{2n-1})^2$
 z_{α} 是标准正态分布的上 α 分位点。

2. t分布

定义 6.2.5 设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$, 并且 X 与 Y 独立, 则称随机变量

$$T = \frac{X}{\sqrt{Y/n}}$$


所服从的分布为自由度为 n 的t分布,记为

$$T \sim t(n).$$

$t(n)$ 分布的概率密度为

$$f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{\pi n} \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, -\infty < t < \infty$$


注: $f(t)$ 是偶函数, 因此其图形关于 y 轴对称.




n 取不同值时t分布及 $N(0,1)$ 的概率密度的比较图

上 α 分位数 $t_\alpha(n)$

若 $T \sim t(n)$, 则有 $P\{T > t_\alpha(n)\} = \alpha$



由对称性知,有 $P\{|t| > t_{\frac{\alpha}{2}}(n)\} = \alpha$ 并且



t 分布的性质:

1. 具有自由度为 n 的 t 分布 $t \sim t(n)$,其数学期望与方差为: $E(t) = 0, D(t) = n/(n-2) \quad (n > 2)$
2. t 分布的密度函数关于 $t = 0$ 对称.当 n 充分大时,其图形近似于标准正态分布概率密度的图形,

再由 Γ 函数的性质有 $\lim_{n \rightarrow \infty} h(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}.$


即当 n 足够大时, $t \overset{\text{近似}}{\sim} N(0,1).$

3. t 分布的分位点

对于给定的 $\alpha, 0 < \alpha < 1$, 称满足条件

$$p\{t > t_{\alpha}(n)\} = \int_{t_{\alpha}(n)}^{\infty} h(t)dt = \alpha$$

的点 $t_{\alpha}(n)$ 为 $t(n)$ 分布的上 α 分位点. 如图所示.




t 分布的上 α 分位点的性质:

$$t_{1-\alpha}(n) = -t_{\alpha}(n)$$

t 分布的上 α 分位点 $t_{\alpha}(n)$ 可查表求得，例 $t_{0.025}(15) = 2.1315$.

当 $n > 45$ 时，对于常用的 α 的值，可用正态近似

$$t_{\alpha}(n) \approx z_{\alpha}$$



3、 F 分布


定义： 设 $U \sim \chi^2(n_1), V \sim \chi^2(n_2), U$ 与 V 相互独立，则称随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度为 n_1 及 n_2 的 F 分布， n_1 称为第一自由度， n_2 称为第二自由度，记作


$$F \sim F(n_1, n_2) .$$

由定义可见， $\frac{1}{F} = \frac{V/n_2}{U/n_1} \sim F(n_2, n_1)$



F分布密度函数的图形

$F(n_1, n_2)$ 分布的上 α 分位数记为 $F_\alpha(n_1, n_2)$



$F_\alpha(n_1, n_2),$

若 $F \sim F(n_1, n_2)$, F 的概率密度为

$$\varphi(y) = \begin{cases} \frac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2}) \Gamma(\frac{n_2}{2})} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} (y)^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} y\right)^{-\frac{n_1+n_2}{2}} & y > 0 \\ 0 & y \leq 0 \end{cases}$$

F 分布的性质

1. F 分布的数学期望为:

$$E(F) = \frac{n_2}{n_2 - 2} \quad \text{若 } n_2 > 2$$


即它的数学期望并不依赖于第一自由度 n_1 .

2. F 分布的分位数

对于给定的 $\alpha, 0 < \alpha < 1$, 称满足条件

$$p\{F > F_{\alpha}(n_1, n_2)\} = \int_{F_{\alpha}(n_1, n_2)}^{\infty} \varphi(y) dy = \alpha$$

的点 $F_{\alpha}(n_1, n_2)$ 为 $F(n_1, n_2)$ 分布的上 α 分位点. 如图所示.



F 分布的上 α 分位点的性质:

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

F 分布的上 α 分位点可查表求得. 例,

$$F_{0.95}(12, 9) = \frac{1}{F_{0.05}(9, 12)} = \frac{1}{2.80} = 0.357$$

由定义,若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$

所以

$$\alpha = P(F \geq F_\alpha(n_1, n_2)) = P\left(\frac{1}{F} \leq \frac{1}{F_\alpha(n_1, n_2)}\right)$$

$$= 1 - P\left(\frac{1}{F} \geq \frac{1}{F_\alpha(n_1, n_2)}\right)$$

$$\Rightarrow P\left(\frac{1}{F} \geq \frac{1}{F_\alpha(n_1, n_2)}\right) = 1 - \alpha$$

$$\Rightarrow F_{1-\alpha}(n_2, n_1) = \frac{1}{F_\alpha(n_1, n_2)}$$

三、几个重要的抽样分布定理

设总体 X 的均值为 μ ，方差为 σ^2 ， $X_1, X_2, \dots, X_n$ 是来自总体的一个样本，则样本均值 $\bar{X}$ 和样本方差 S^2 有

$$E(\bar{X}) = \mu,$$

$$D(\bar{X}) = \sigma^2/n,$$

$$E(S^2) = \sigma^2$$

事实上 $E(s^2) = E\left[\frac{1}{n-1}\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right]$

$$= \frac{1}{n-1}\left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)\right]$$
$$= \frac{1}{n-1}\left[\sum_{i=1}^n (\sigma^2 + \mu^2) - n(\sigma^2/n + \mu^2)\right] = \sigma^2$$

当总体为**正态分布**时，给出几个重要的抽样分布定理.

定理 1 (样本均值的分布)

设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(\mu, \sigma^2)$

的样本, $\bar{X}$ 是样本均值, 则有

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$


即
$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \Leftrightarrow \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

请注意：

在已知总体 μ ， σ^2 时，
可用本定理计算样
本均值 $\bar{X}$ 。

n 取不同值时样本
均值 $\bar{X}$ 的分布



定理 2 (样本方差的分布)

设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本,


$\bar{X}$ 和 S^2 分别为样本均值和样本方差, 则有

$$(1) \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

(2) $\bar{X}$ 与 S^2 独立.

n 取不同值时 $\frac{(n-1)S^2}{\sigma^2}$

的分布



定理 3 (样本均值的分布)

设 $X_1, X_2, \dots, X_n$ 是取自正态总体 $N(\mu, \sigma^2)$

的样本, $\bar{X}$ 和 S^2 分别为样本均值和样本方差,

则有
$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

证 由定理1、2,t分布的定义可得

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \text{ 且相互独立}$$

$$\text{则 } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \bigg/ \sqrt{\frac{(n-1)S^2}{\sigma^2}} \sim t(n-1)$$

在未知总体 σ^2 时, 可用本定理计算样本均值 $\bar{X}$.

定理 4 (两总体样本均值差、样本方差比的分布)

设 $X \sim N(\mu_1, \sigma^2)$, $Y \sim N(\mu_2, \sigma^2)$, 且 X 与 Y 独立,
 $X_1, X_2, \dots, X_{n_1}$ 是来自 X 的样本, $Y_1, Y_2, \dots, Y_{n_2}$ 是取自 Y 的样本,
 $\bar{X}$ 和 $\bar{Y}$ 分别是这两个样本的样本均值, S_1^2 和 S_2^2 分别是
这两个样本的样本方差, 则有

$$1、 \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$2、 \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

例 设总体 X 服从正态分布 $N(12, \sigma^2)$, 抽取容量为25的样本, 求样本均值 $\bar{X}$ 大于12.5的概率. 如果 (1) 已知 $\sigma = 2$; (2) σ 未知, 但已知样本方差 $S^2 = 5.57$.

解 (1)
$$P\{\bar{X} > 12.5\} = P\left\{\frac{\bar{X} - 12}{2/\sqrt{25}} > \frac{12.5 - 12}{2/\sqrt{25}}\right\}$$
$$= P\left\{\frac{\bar{X} - 12}{0.4} > 1.25\right\} = 1 - \Phi(1.25) = 0.1063$$

(2)
$$P\{\bar{X} > 12.5\} = P\left\{\frac{\bar{X} - 12}{S/\sqrt{25}} > \frac{12.5 - 12}{S/\sqrt{25}}\right\} = P\{T > 1.059\}$$

查自由度为24的 t 分布表, $t_{0.15}(24) = 1.059$, 即
 $P\{T > 1.059\} = 0.15$. 故有 $P\{\bar{X} > 12.5\} = 0.15$.

六、小结

在这一节中我们学习了统计量的概念,几个重要的统计量及其分布,即抽样分布.要求大家熟练地掌握它们.

常用的统计量

样本平均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

样本标准差

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

抽样分布

χ^2 分布 设 $X_1, \dots, X_n$ 相互独立, 且均服从正态分布 $N(0,1)$,

则称随机变量 $\chi^2 = \sum_{i=1}^n X_i^2$ 服从自由度为 n 的 χ^2 分布,

记为 $\chi^2 \sim \chi^2(n)$.

t 分布 设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则称

随机变量 $t = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布, 记为 $t \sim t(n)$.

F 分布 设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, U 与 V 相互独立, 则称

随机变量 $F = \frac{U/n_1}{V/n_2}$ 服从自由度为 (n_1, n_2) 的分布,

记为 $F \sim F(n_1, n_2)$.

抽样分布定理

样本均值的分布

设 $X \sim N(\mu, \sigma^2)$, $X_1, \dots, X_n$ 是来自总体 X 的样本, 则样本均值 $\bar{X}$ 有 $\bar{X} \sim N(\mu, \sigma^2/n)$.

样本方差、均值的分布

设 $X_1, \dots, x_n$ 是来自总体 $N(\mu, \sigma^2)$ 的样本, $\bar{X}, S^2$ 分别是样本均值和样本方差, 则有

$$(1) \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$(2) \quad \bar{X} \text{ 与 } S^2 \text{ 独立.}$$

$$(3) \quad \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

两总体样本均值差、样本方差比的分布

设 $X_1, \dots, X_{n_1}$ 与 $Y_1, \dots, Y_{n_2}$ 分别来自总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的样本，且这两个样本相互独立。 $\bar{X}, \bar{Y}$ 分别是这两个样本的样本均值； S_1^2, S_2^2 分别是这两个样本的样本方差，则有

$$1、 \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$2、 \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$