

第七章、参数估计

第一节：点估计

第三节：估计量的评选标准

第四节：区间估计

第五节：正态总体均值与方差的区间估计

第六节： $(0-1)$ 分布参数的区间估计

第七节：单侧置信区间

统计推断是数理统计理论的主要部分。现行的统计推断理论，是建立在概率论的基础上的。

- ✓ 所谓统计推断，就是根据从总体中抽出的**样本**，去**推断总体**的性质（概率分布）。
- ✓ 只有在**总体未知**或总体分布已知，但含有**未知参数**时，统计推断才有意义。
- ✓ 统计推断分为**参数估计**与**假设检验**。

(概念要点)


根据观测到的**样本数据**对**总体**作出推测.

这种**推测**伴随某种**不确定性**,

需要用**概率**来表示其**可靠程度**,

这是统计推断的一个重要**特点**.

统计推断的过程



参数估计

现在我们来介绍一类重要的统计推断问题：


参数估计问题是利用**从总体抽样得到的信息**来**估计总体**的某些参数或者参数的某些函数。



估计废品率

估计湖中鱼数

估计平均降雨量



抽样推断中的理论依据

1、大数定律（切比雪夫大数定律）

设 $X_1, X_2, \dots, X_n$ 是一列**两两相互独立的**随机变量, 服从**同一分布**, 且存在**有限的数学期望 μ 和方差 σ^2** , 则对于任意小的正数 $\varepsilon > 0$, 有:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\sum X}{n} - \mu\right| < \varepsilon\right) = 1$$


对于抽样推断: 随着样本容量 n 的增加, 样本平均数将接近于总体平均数。

- 2、中心极限定理：设从均值为 μ ，方差为 σ^2 的一个任意总体中抽取容量为 n 的样本，当 n 充分大时，样本均值的抽样分布近似服从均值为 μ 、方差为 σ^2/n 的正态分布。

在一定条件下，大量独立随机变量的平均数是以正态分布为极限的。


中心极限定理

中心极限定理： 设从均值为 μ ，方差为 σ^2 的一个任意总体中抽取容量为 n 的样本，当 n 充分大时，样本均值的抽样分布近似服从均值为 μ 、方差为 σ^2/n 的正态分布




中心极限定理

$\bar{X}$ 的分布趋于正态分布的过程



抽样分布与总体分布的关系



在参数估计问题中，假定总体分布形式已知，未知的仅仅是一个或几个参数.

参数估计 { 点估计
区间估计

第一节 点估计

一、点估计问题的提法

二、估计量的求法

三、估计量的评选标准

一、点估计问题的提法

设总体 X 的分布函数 $F(x; \theta)$ 形式已知, θ 是待估参数, $X_1, X_2, \dots, X_n$ 是 X 的一个样本, $x_1, x_2, \dots, x_n$ 是相应的一个样本值.

点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 θ .

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的估计量. } 通称估计,
 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计值. } 简记为 $\hat{\theta}$.

二、估计量的求法

由于估计量是样本的函数, 是随机变量, 故对不同的样本值, 得到的参数值往往不同, 求估计量的问题是关键问题.

估计量的求法: (两种)

矩估计法

最大似然估计法.

1. 矩估计法

它是基于一种简单的“**替换**”思想建立起来的一种估计方法。是英国统计学家**K.皮尔逊**最早提出的。其基本思想是**用样本矩估计总体矩**。

理论依据： 大数定律

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E(X) = \mu$$

设总体 X 的分布函数为 $F(x; \theta_1, \theta_2, \dots, \theta_r)$
其中 $\theta_1, \theta_2, \dots, \theta_r$ 为未知参数, 现在从总体 X
中抽取样本 $(X_1, X_2, \dots, X_n)$. 由**辛钦大数定律**
则对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - EX \right| \geq \varepsilon \right\} = 0.$$

可以推广为, 则对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i^k - EX^k \right| \geq \varepsilon \right\} = 0.$$

设 $X_1, X_2, \dots, X_n$ 来自总体 X 的样本

记总体 k 阶矩为 $\alpha_k = E(X^k)$

样本 k 阶矩为 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

记总体 k 阶中心矩为 $\mu_k = E[X - E(X)]^k$

样本 k 阶中心矩为 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

用样本矩来估计总体矩，用样本矩的连续函数来估计总体矩的连续函数，从而得出参数估计，这种估计法称为**矩估计法**。

矩估计法的具体步骤:

(1) 求出 $\alpha_l = E(X^l) = \alpha(\theta_1, \theta_2, \dots, \theta_k) \quad l = 1, 2, \dots, k$

(2) 令 $\alpha_l = A_l, \quad A_l = \frac{1}{n} \sum_{i=1}^n X_i^l; l = 1, 2, \dots, k$

这是一个包含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组

(3) 解出其中 $\theta_1, \theta_2, \dots, \theta_k$, 用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 表示.

(4) 用方程组的解 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量, 这种估计量称为矩估计量. 矩估计量的观察值称为矩估计值.

例 设总体 X 在 $[a, b]$ 上服从均匀分布其中 a , b 未知, $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, 求 a , b 的矩估计量

解 $\alpha_1 = E(X) = \frac{a+b}{2}, \quad \alpha_2 = E(X^2) = D(X) + [E(X)]^2 = \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4},$

$$\text{令 } \frac{a+b}{2} = A_1 = \frac{1}{n} \sum_{i=1}^n X_i, \quad \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4} = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2,$$

$$\text{即 } \begin{cases} a+b = 2A_1 \\ b-a = \sqrt{12(A_2 - A_1^2)} \end{cases}$$

解方程组得到 a, b 的矩估计量分别为

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

例3 设总体 X 的均值 μ 和方差 σ^2 都存在, 且有 $\sigma^2 > 0$, 但 μ 和 σ^2 均为未知, 又设 $X_1, X_2, \dots, X_n$ 是一个样本, 求 μ 和 σ^2 的矩估计量.

解

$$\alpha_1 = E(X) = \mu,$$
$$\alpha_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$
$$\text{令 } \begin{cases} \mu = A_1 \\ \sigma^2 + \mu^2 = A_2 \end{cases}$$

解方程组得到矩估计量分别为 $\hat{\mu} = A_1 = \bar{X}$,

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

上例表明:

总体均值与方差的矩估计量的表达式, 不因不同的总体分布而异.

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 即得 μ, σ^2 的矩估计量

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

矩法的优点是简单易行. 缺点是, 当总体类型已知时, 没有充分利用分布提供的信息. 一般场合下, 矩估计量不具有唯一性.

2. 最大（极大）似然估计法

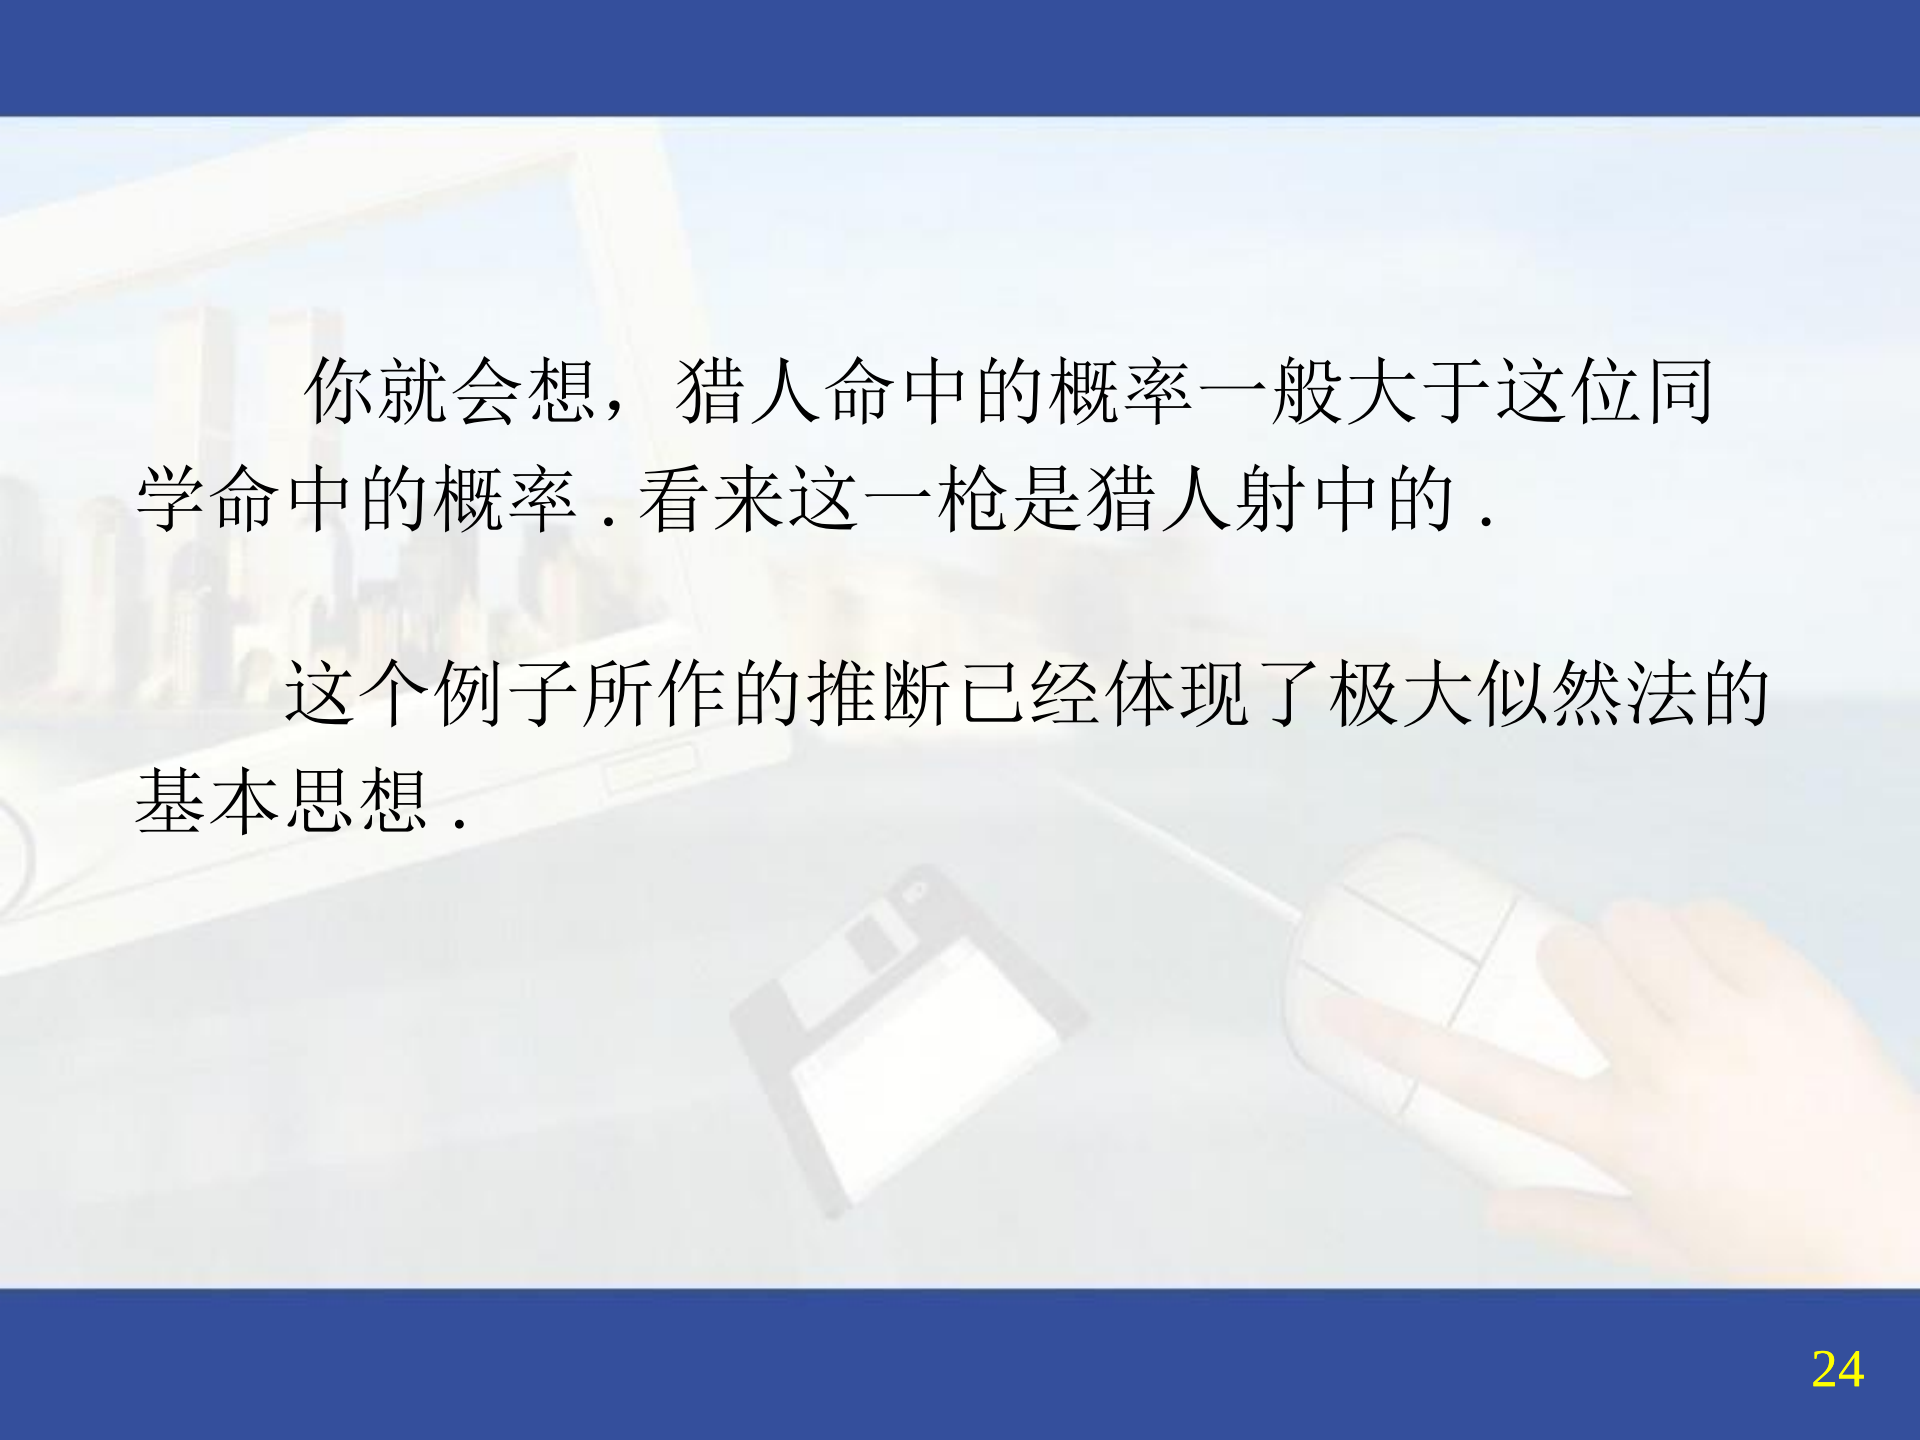
最大似然法是在总体类型已知条件下使用的一种参数估计方法。

它首先是由德国数学家**高斯**在1821年提出的。然而，这个方法常归功于英国统计学家**费歇**。费歇在1922年重新发现了这一方法，并首先研究了这种方法的一些性质。

极大似然法的基本思想：

某位同学与一位猎人一起外出打猎。一只野兔从前方窜过。只听一声枪响，野兔应声倒下。如果要你推测，是谁打中的呢？你会如何想呢？

思想方法：一次试验就出现的事件有较大的概率。



你就会想，猎人命中的概率一般大于这位同学命中的概率．看来这一枪是猎人射中的．

这个例子所作的推断已经体现了极大似然法的基本思想．



最大似然估计法，是建立在最大似然原理的基础上的求点估计量的方法。

最大似然原理的**直观想法**是：在试验中概率最大的事件最有可能出现。例如，一个试验如有若干个可能的结果 $A, B, C, \dots$

若在一次试验中，结果 A 出现，则一般认为 A 出现的概率最大。

极大似然估计法:

当给定样本 $X_1, X_2, \dots, X_n$ 时, 定义似然函数为:

$$\begin{aligned} L(\theta) &= L(\theta; x_1, \dots, x_n) \\ &= P(X_1 = x_1; \theta) P(X_2 = x_2; \theta) \cdots P(X_n = x_n; \theta) \end{aligned}$$

$$\begin{aligned} L(\theta) &= L(\theta; x_1, \dots, x_n) \\ &= f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) \end{aligned}$$

这里 $x_1, x_2, \dots, x_n$ 是样本的观察值.

$L(\theta)$ 看作参数 θ 的函数, 它可作为 θ 将以多大可能产生样本值 $x_1, x_2, \dots, x_n$ 的一种度量.

选择 θ , 使 **$L(\theta)$** 达到最大值.

似然函数

若总体 X 属**离散型**, 其分布律为 $P\{X = x\} = p(x; \theta)$,
 $\theta \in \Theta$ 形式已知, θ 为待估参数, $(X_1, X_2, \dots, X_n)$
是总体 X 的一个样本, 则样本 $X_1, X_2, \dots, X_n$ 的
分布律为 $\prod_{i=1}^n p(x_i; \theta)$, 当给定样本值 $(x_1, x_2, \dots, x_n)$
后, 则样本 $X_1, X_2, \dots, X_n$ 取到观察值 $x_1, x_2, \dots, x_n$
的概率为 $L(\theta) = \prod_{i=1}^n p(x_i; \theta)$, $\theta \in \Theta$
它是 θ 的函数, 称 $L(\theta)$ 为样本的**似然函数**.

若总体 X 属连续型, 其概率密度函数为 $f(x; \theta)$,
 $\theta \in \Theta$ 形式已知, θ 为待估参数, $(X_1, X_2, \dots, X_n)$
是总体 X 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的联合
密度为 $\prod_{i=1}^n f(x_i; \theta)$, 设 $x_1, x_2, \dots, x_n$ 是相应于样本
 $X_1, X_2, \dots, X_n$ 的一个样本值, 则 $(X_1, X_2, \dots, X_n)$
落在点 $(x_1, x_2, \dots, x_n)$ 的邻域内的概率近似为

$$\prod_{i=1}^n f(x_i; \theta) dx_i, \quad \theta \in \Theta$$

因 $\prod_{i=1}^n dx_i$ 不随 θ 而变, 故只需考虑 $\prod_{i=1}^n f(x_i; \theta)$

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$

则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的最大似然估计值.

若将上式中样本值 $(x_1, x_2, \dots, x_n)$ 替换成样本 $(X_1, X_2, \dots, X_n)$, 则得 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 称为参数 θ 的最大似然估计量.

由于 $L(\theta)$ 与 $\ln L(\theta)$ 在同一 θ 处达到最大值, 因此, $\hat{\theta}$ 为最大似然估计的必要条件为

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

称为似然方程

求最大似然估计量的一般步骤为：

(1) 求似然函数 $L(\theta)$

(2) 一般地，求出 $\ln L(\theta)$ 及似然方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

(3) 解似然方程得到最大似然估计值

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$$

(4) 最后得到最大似然估计量

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$$

例4 设 $X \sim B(1, p)$, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 求 p 的最大似然估计量.

解 设 $x_1, x_2, \dots, x_n$ 为相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值,

X 的分布律为 $P\{X = x\} = p^x (1-p)^{1-x}, x = 0, 1$

似然函数
$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$$
$$= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i},$$

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

$$\text{令 } \frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0,$$

$$\text{解得 } p \text{ 的最大似然估计值 } \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

$$p \text{ 的最大似然估计量为 } \hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.

例5 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, $x_1, x_2, \dots, x_n$ 是来自 X 的一个样本值, 求 μ 和 σ^2 的最大似然估计量.

解 X 的概率密度为

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

X 的似然函数为

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}},$$

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

$$\text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0 \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases}$$

$$\text{由 } \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0 \text{ 解得 } \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\text{由 } -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \text{ 解得}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

故 μ 和 σ^2 的最大似然估计量分别为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

它们与相应的矩估计量相同.

例6 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a, b 未知, $x_1, x_2, \dots, x_n$ 是来自总体 X 的一个样本值, 求 a, b 的最大似然估计量.

解 记 $x_{(1)} = \min(x_1, x_2, \dots, x_n),$

$$x_{(n)} = \max(x_1, x_2, \dots, x_n),$$

X 的概率密度为

$$p(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其它} \end{cases}$$

因为 $a \leq x_1, x_2, \dots, x_n \leq b$ 等价于 $a \leq x_{(1)}, x_{(n)} \leq b$,

作为 a, b 的函数的似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)} \\ 0, & \text{其它} \end{cases}$$

于是对于满足条件 $a \leq x_{(1)}, b \geq x_{(n)}$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$

即似然函数 $L(a, b)$ 在 $a = x_{(1)}$, $b = x_{(n)}$ 时
取到最大值 $(x_{(n)} - x_{(1)})^{-n}$,

a, b 的最大似然估计值

$$\hat{a} = x_{(1)} = \min_{1 \leq i \leq n} x_i, \quad \hat{b} = x_{(n)} = \max_{1 \leq i \leq n} x_i,$$

a, b 的最大似然估计量

$$\hat{a} = \min_{1 \leq i \leq n} X_i, \quad \hat{b} = \max_{1 \leq i \leq n} X_i .$$

说明：用求导方法求参数的最大似然估计有时行不通，这时要用极大似然原则来求。

小结

两种求点估计的方法: $\left\{ \begin{array}{l} \text{矩估计法} \\ \text{最大似然估计法} \end{array} \right.$

在统计问题中往往先使用最大似然估计法, 在最大似然估计法使用不方便时, 再用矩估计法.

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

第三节 估计量的评价标准

一、无偏性

二、有效性

三、相合性

问题的提出

从前一节可以看到, 对于同一个参数, 用不同的估计方法求出的估计量可能不相同, 那么那一个估计量好? 好坏的标准是什么?

下面介绍几个常用标准.

一、无偏性（无偏估计）

若 $X_1, X_2, \dots, X_n$ 为总体 X 的一个样本,
 $\theta \in \Theta$ 是包含在总体 X 的分布中的待估参数,
(Θ 是 θ 的取值范围)

若估计量 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 的数学期望
 $E(\hat{\theta})$ 存在, 且对于任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$, 则称
 $\hat{\theta}$ 是 θ 的无偏估计量.

无偏性是对估计量的一个常见而重要的要求 .

无偏估计的实际意义：无系统误差.

例1 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$) 存在, 又设 $X_1, X_2, \dots, X_n$ 是 X 的一个样本, 试证明不论总体服从什么分布, k 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计.

证 因为 $X_1, X_2, \dots, X_n$ 与 X 同分布,

故有 $E(X_i^k) = E(X^k) = \mu_k, \quad i = 1, 2, \dots, n.$

即 $E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k.$

故 k 阶样本矩 A_k 是 k 阶总体矩 μ_k 的无偏估计.

特别地:

不论总体 X 服从什么分布,

只要它的数学期望存在,

$\bar{X}$ 总是总体 X 的数学期望 $\mu_1 = E(X)$ 的无偏估计量

例2 设总体 X 服从参数为 θ 的指数分布概率密

度 $p(x;\theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其它} \end{cases}$, 其中参数 $\theta > 0$, 又设

$X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 $\bar{X}$ 和
 $nX_{(1)} = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计

证 因为 $E(\bar{X}) = E(X) = \theta$,
所以 $\bar{X}$ 是 θ 的无偏估计量.

而 $X_{(1)} = \min(X_1, X_2, \dots, X_n)$ 具有概率密度

$$p_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0 \\ 0, & \text{其它} \end{cases}$$

故知 $E(X_{(1)}) = \frac{\theta}{n}$, $E(nX_{(1)}) = \theta$,

所以 $nX_{(1)}$ 也是 θ 的无偏估计量.

由以上两例可知, 同一个参数可以有不同的无偏估计量.

无偏性虽然是评价估计量的一个重要标准，而且在许多场合是合理的、必要的。然而，有时一个参数的无偏估计可能不存在或者不合理。

于是，人们又在无偏性的基础上增加了对方差的要求。若估计量的方差越小。表明该估计量的取值（即估计值）围绕着待估参数的波动就越小，也就是更为理想的估计量。为此，引入最小方差无偏计。

二、有效性（最小方差无偏估计）

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 与 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计量，若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ ，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

由于方差是随机变量取值与其数学期望的偏离程度，所以无偏估计以方差小者为好。

例3 (续例2)

试证当 $n > 1$ 时, θ 的无偏估计量 $\bar{X}$ 较 $nX_{(1)}$ 有效.

证明 由于 $D(X) = \theta^2$, 故有 $D(\bar{X}) = \frac{\theta^2}{n}$,

又因为 $D(X_{(1)}) = \frac{\theta^2}{n^2}$, 故有 $D(nX_{(1)}) = \theta^2$,

当 $n > 1$ 时, $D(nX_{(1)}) > D(\bar{X})$,

故 θ 的无偏估计量 $\bar{X}$ 较 $nX_{(1)}$ 有效.

定义

如果存在 θ 的一个无偏估计量 $\hat{\theta}_0$, 使得对于 θ 的任意无偏估计量 $\hat{\theta}$, 都有

$$D(\hat{\theta}_0) \leq D(\hat{\theta})$$

则称 $\hat{\theta}_0$ 是 θ 的最小方差无偏估计(量), 缩写为 ***MVUE***.

说明 最小方差无偏估计是一种最优估计.

三、相合性（相合估计）

有时候我们不仅要求估计量有较小的方差，还希望当样本容量 n 充分大时，估计量能在某种意义下收敛于被估计参数，这就是所谓相合性（或一致性）概念。

定义 设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 是未知参数 θ 估计序列，如果 $\hat{\theta}_n$ 依概率收敛于 θ ，即对任 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| < \varepsilon\} = 1$$

或
$$\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} = 0$$

则 $\hat{\theta}_n$ 称是 θ 的相合估计量（或一致估计）。

定理 设 $\hat{\theta}_n$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad \text{且} \quad \lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计 (或一致估计)。

证明: 由于 $0 \leq P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} \leq \frac{1}{\varepsilon^2} E(\hat{\theta}_n - \theta)^2$

$$= \frac{1}{\varepsilon^2} E[\hat{\theta}_n - E(\hat{\theta}_n) + E(\hat{\theta}_n) - \theta]^2$$
$$= \frac{1}{\varepsilon^2} [D(\hat{\theta}_n) + (E(\hat{\theta}_n) - \theta)^2]$$

令 $n \rightarrow \infty$ 且由定理的假设, 得 $\lim_{n \rightarrow \infty} P\left\{|\hat{\theta}_n - \theta| \geq \varepsilon\right\} = 0$

即 $\hat{\theta}_n$ 是 θ 的相合估计

小结

估计量的评选的三个标准 { 无偏估计
最小方差无偏估计
相合估计

相合性是对估计量的一个基本要求, 不具备相合性的估计量是不予以考虑的.

由最大似然估计法得到的估计量, 在一定条件下也具有相合性. 估计量的相合性只有当样本容量相当大时, 才能显示出优越性, 这在实际中往往难以做到, 因此, 在工程中往往使用无偏性和有效性这两个标准.

- 例：设 $X_1, X_2, \dots, X_n$ 是来自参数为 λ 的泊松分布总体的一个样本,试求 λ 的最大似然估计量和矩估计量.

解:由于 $X \sim \pi(\lambda)$, 其分布律为: $P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x = 0, 1, 2, \dots$

则似然函数为:

$$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda}$$

对数似然函数为:

$$\ln L(\lambda) = \sum_{i=1}^n x_i \ln \lambda - n\lambda - \sum_{i=1}^n \ln x_i$$

似然方程为: $\frac{\ln L(\lambda)}{d\lambda} = \frac{\sum_{i=1}^n x_i}{\lambda} - n = 0$

解得: $\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$ 为 λ 的最大似然估计值. 从而 λ 的最大

似然估计量为

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

因为总体 $X \sim \pi(\lambda)$, 则 $E(X) = \lambda$, 故 $\hat{\lambda} = \bar{X}$ 即为 λ 的矩估计量.

- 随机地取8只活塞,测得它们的直径为(以mm计)

74.001 74.005 74.003 74.001 74.000 73.998 74.006 74.002

试求总体均值 μ 及方差 σ^2 的矩估计值,并求样本方差 s^2 .

解: 设活塞环的直径为 X ,由矩估计法知:

$$\begin{cases} \mu_1 = E(X) = \bar{X} \\ \mu_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2 \end{cases}$$

以 A_1, A_2 代替 μ_1, μ_2 ,得 μ 和 σ^2 的估计量分别为:

$$\hat{\mu} = A_1 = \bar{X} \quad \hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

代入数据计算得:

$$\hat{\mu} = A_1 = \bar{X} = \frac{1}{8} \sum_{i=1}^8 x_i = 74.002$$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = 6 \times 10^{-6}$$

- 随机地取8只活塞,测得它们的直径为(以mm计)

74.001 74.005 74.003 74.001 74.000 73.998 74.006 74.002

试求总体均值 μ 及方差 σ^2 的矩估计值,并求样本方差 s^2 .

样本方差为:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{7} \sum_{i=1}^n (x_i - \bar{x})^2 = 6.86 \times 10^{-6}$$

- 例：设总体 X 具有分布律

X	1	2	3
p_k	θ^2	$2\theta(1-\theta)$	$(1-\theta)^2$

其中 $\theta(0<\theta<1)$ 为未知参数.已知取得了样本值 $x_1=1, x_2=2, x_3=1$.试求 θ 的矩估计值和最大似然估计量.

解：依题意总体 X 的均值为：

$$E(X) = 1 \times \theta^2 + 2 \times 2\theta(1-\theta) + 3 \times (1-\theta)^2 = 3 - 2\theta$$

由矩估计法知, $3 - 2\hat{\theta} = \bar{X}$, 得 θ 的矩估计量为: $\hat{\theta} = \frac{3 - \bar{X}}{2}$

代入样本均值的观测值, 得 θ 的矩估计值为:

$$\hat{\theta} = \frac{3 - \bar{X}}{2} = \frac{3 - 4/3}{2} = \frac{5}{6}$$

(2)因为样本值1取得2次,2取得1次,故似然函数为:

$$L(\theta) = \prod_{i=1}^n P(x_i; \theta) = \theta^4 2\theta(1-\theta) = 2\theta^5(1-\theta)$$

对数似然函数为: $L(\theta) = \ln 2 + 5\ln \theta + \ln(1-\theta)$

对数似然方程为: $\frac{dL(\theta)}{d\theta} = \frac{5}{\theta} + \frac{1}{1-\theta} = 0$

解得: $\hat{\theta} = 5/6$ 为 θ 的最大似然估计值.

浙大版教材第六章

2

3

6

7

9