



Ch.1 Basic Concepts of Probability

第一章 概率论的基本概念

上节回顾



- 条件概率 $P(B|A) = \frac{P(AB)}{P(A)}$


- 事件独立 $P(AB) = P(A)P(B)$

- 加法公式

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum P(A_i) - \sum P(A_i A_j) + \sum P(A_i A_j A_k) - \dots + (-1)^{n-1} P(A_1 A_2 \dots A_n)$$

- 乘法公式

$$P(A_1 A_2 \dots A_n) = P(A_1) P(A_2|A_1) P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1})$$





Example 5(聚众问题) 假设每个人的呼吸道中有感冒病毒的概率为0.002, 且每个人是否带有感冒病毒是相互独立的。

求: 在有1500人看演唱会的会场中有感冒病毒的概率。

解: 事件 A_i : 第 i 个人带有感冒病毒 ($i=1,2,\dots, 1500$) , 所求概率为

$$\begin{aligned} P\left(\bigcup_{i=1}^{1500} A_i\right) &= 1 - P(\overline{A}_1 \overline{A}_2 \cdots \overline{A}_{1500}) \\ &= 1 - P(\overline{A}_1)P(\overline{A}_2) \cdots P(\overline{A}_{1500}) \\ &= 1 - (1 - 0.002)^{1500} \\ &= 1 - 0.998^{1500} \\ &\approx 0.95 \end{aligned}$$

可见: 虽然每人带感冒病毒的可能性很小, 但许多人聚集在一起时, 空气中含有感冒病毒的概率可能会很大。

这种现象称为**小概率事件的聚众效应**



Example 6 (系统可靠性问题) 设某型号的计算机服务器可靠性为85%，现在采用冗余配置(并行工作)，欲使得系统的可靠性达到99.99%，问至少应配多少台这样的服务器？设不同机器是否正常工作是相互独立的。

解： 假设共需要 n 台这样的服务器才能使得系统的可靠性达到99.99%。

A 系统工作正常， A_i = 第 i 台服务器工作正常

$$A = \cup A_i$$

$$P(A) = P(\cup A_i) \geq 99.99\%$$

注意到 A_i 是可以同时发生，不具备互斥性，无法直接分解成概率的和。但是 $\bar{A}_i$ 是独立的，也就是 n 台服务器是否down机是独立的。考虑如何把 A_i 和事件表达分解为 $\bar{A}_i$ 的交事件。



Example 6 (系统可靠性问题)

$$\begin{aligned}P(A) &= 1 - P\left(\bigcap_{i=1}^n \bar{A}_i\right) \\&= 1 - P(\bar{A}_1)P(\bar{A}_2) \cdots P(\bar{A}_n) \\&= 1 - (1 - 85\%)^n \\&= 1 - 0.15^n \\&\geq 99.99\%\end{aligned}$$

解题技巧

并事件：事件互斥
交事件：事件独立

$$0.0001 \geq 0.15^n$$

$n \geq 4.85$ 至少需要5台机器。



区分互斥、对立、独立三个概念；

互斥： $A \cap B = \Phi$

对立： $A \cap B = \Phi$ 且 $A \cup B = S$

独立： $P(AB) = P(A)P(B)$

互斥与独立之间是什么关系呢？

独立 vs 互斥



A、B独立: $P(AB)=P(A)P(B)$

A、B互斥: $A \cap B = \Phi$

从定义上讲: $A \cap B = \Phi \Rightarrow P(AB)=0$

当 $P(A) \neq 0$ 且 $P(B) \neq 0$, 则必定 $P(A)P(B) \neq 0$, 那么 $P(AB) \neq P(A)P(B)$, 即互斥必定不独立。

如何理解: 独立是指两个事件发生与否没有任何关系或制约; 而互斥意味着A发生了B就不能发生。




下列说法中正确的是

- | | |
|---|-------------------------------------|
| A | $P(A)=P(B)=0.6$, 则A,B独立 |
| B | A,B独立, 则A,B互斥 |
| C | A,B互斥, 则A,B独立 |
| D | $P(A)=P(B)=0.6$, 则A,B不互斥 |
| E | 如果A,B,C两两独立, 则A、B、C独立 |
| F | 如果A、B、C独立, 则A,B,C两两独立 |
| G | 如果 $P(ABC)=P(A)P(B)P(C)$, 则A、B、C独立 |

提交

全概率公式



[定义]: 空间S的划分

设S为随机试验E的样本空间, $B_1, B_2, \dots, B_n$ 为E的一组事件, 如果

[1] $B_1, B_2, \dots, B_n$ 是两两互斥的事件 不重

[2] $B_1 \cup B_2 \cup \dots \cup B_n = S$ 不漏

则称 $B_1, B_2, \dots, B_n$ 称为样本空间S的一个划分。

例如: 掷骰子, $B_1 = \{1, 3\}$, $B_2 = \{2, 4, 5\}$, $B_3 = \{6\}$ 构成一个划分。

全概率公式



[定理] 设 S 为随机试验 E 的样本空间, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且 $P(B_i) > 0, i = 1, 2, \dots, n$ 。则任意事件 A 的概率可表示为

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

Remark: 上述称为**全概率公式**, 它事实上是先把一个复杂样本空间 S 上事件 A 的概率分解为若干个小的子空间上的概率之和

$$P(A) = P(AB_1) + P(AB_2) + \dots + P(AB_n)$$

再把在每个子空间上的概率分解为条件概率的乘积

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$


现实意义: 现实中 A 是一个复杂事件, 其原因众多。我们可以逐个分析造成 A 的原因, 再将其合起来。

全概率公式的图示



设 $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分

设 $P(B_j) = p_j, P(A | B_j) = q_j, j = 1, 2, \dots, n.$



$$\text{则 } P(A) = \sum_{j=1}^n p_j q_j.$$

注意：运用全概率公式的关键是构造合适的划分。



Example1 有一批产品是由甲、乙、丙三厂同时生产

	甲厂	乙厂	丙厂
产品百分比	15%	80%	5%
产品次品率	2%	1%	3%

如果从这批产品中随机抽取一件，试计算该产品是次品的概率多大？

解： 设 B_1 、 B_2 、 B_3 分别表示抽得产品是甲厂、乙厂、丙厂生产的，
 A 表示抽得产品为次品。

对于随机抽取一件产品这个试验，
 B_1 、 B_2 、 B_3 构成了样本空间的一个划分

$$A = (A \cap B_1) \cup (A \cap B_2) \cup (A \cap B_3)$$

$$P(A) = P(A \cap B_1) + P(A \cap B_2) + P(A \cap B_3)$$

$$= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + P(A|B_3)P(B_3)$$

$$= 0.02 \times 0.15 + 0.01 \times 0.8 + 0.03 \times 0.05$$

$$= 0.0125$$



甲乙丙分别操纵三门炮向一飞机射击。设他们的命中率分别为0.4、0.5、0.7；如只有一人射中，飞机坠毁的概率为0.2，如两个射中，飞机坠毁的概率为0.6，如三人都射中，则飞机必坠毁。

三人同时射击时飞机坠毁的概率为 [填空1]

作答



Example2: 甲乙丙分别操纵三门炮向一飞机射击。设他们的命中率分别为0.4、0.5、0.7；如只有一人射中，飞机坠毁的概率为0.2，如两个射中，飞机坠毁的概率为0.6，如三人都射中，则飞机必坠毁。

求：三人同时射击时飞机坠毁的概率？

解： A = 飞机坠毁

B_0 = 0人射中；

B_1 = 有1人射中；

B_2 = 有2人射中；

B_3 = 有3人射中；

$P(A|B_0) = 0$; $P(A|B_1) = 0.2$; $P(A|B_2) = 0.6$; $P(A|B_3) = 1$

C_1 = 甲射中, C_2 = 乙射中, C_3 = 丙射中

对于三人同时射击这个试验，
 B_0 、 B_1 、 B_2 、 B_3 构成了样本空间的一个划分



由全概率公式知：

$$P(A) = P(A|B_0)P(B_0) + P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + P(A|B_3)P(B_3)$$

现在要求出 B_0 、 B_1 、 B_2 、 B_3 的概率

$$P(B_0) = P(\text{有0个中}) = (1-0.4)(1-0.5)(1-0.7) = 0.09$$

$$\begin{aligned} P(B_1) &= P(\text{有1个中}) = P(C_1\bar{C}_2\bar{C}_3) + P(\bar{C}_1C_2\bar{C}_3) + P(\bar{C}_1\bar{C}_2C_3) \\ &= 0.4(1-0.5)(1-0.7) + (1-0.4)0.5(1-0.7) + (1-0.4)(1-0.5)0.7 \\ &= 0.36 \end{aligned}$$

$$\begin{aligned} P(B_2) &= P(\text{有2个中}) = P(C_1C_2\bar{C}_3) + P(C_1\bar{C}_2C_3) + P(\bar{C}_1C_2C_3) \\ &= 0.4 \times 0.5(1-0.7) + 0.4(1-0.5)0.7 + (1-0.4)0.5 \times 0.7 \\ &= 0.41 \end{aligned}$$

$$P(B_3) = P(\text{3个全中}) = 0.4 \times 0.5 \times 0.7 = 0.14$$

带入公式，求出 $P(A) = 0.458$

贝叶斯公式



	甲厂	乙厂	丙厂
产品百分比	15%	80%	5%
产品次品率	2%	1%	3%

一类实际问题：“已知原因看结果”

全概率公式

已知导致结果A发生的各个原因，通过逐个分析原因，求出结果A发生的概率大小。例如，由上表的数据来求抽到次品的概率。

另一类实际问题：“已知结果看原因”

贝叶斯公式

已知结果A发生的前提下，去分析导致它发生的原因，或者分析各种原因作用的大小。例如，已知抽到次品，求这个次品来自甲工厂的概率；这个次品最有可能来自哪个工厂。

贝叶斯公式



注意：事件A发生后，我们希望知道导致这个事件发生的各个原因的可能性大小。所有原因 B_1 、 B_2 、 B_3 事实上构成了样本空间S的一个划分。

[Bayes定理]：设试验E的样本空间为S， $B_1, B_2, \dots, B_n$ 为样本空间S的一个划分，A为E的事件， $P(A) > 0$, $P(B_i) > 0$ ($i = 1, 2, \dots, n$)，则

$$P(B_i|A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \quad i = 1, 2, \dots, n$$

贝叶斯公式



Proof:
$$P(B_i | A) = \frac{P(B_i A)}{P(A)} \quad i = 1, 2, \dots, n$$

注意到 $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分

$$P(A) = \sum_{j=1}^n P(AB_j) = \sum_{j=1}^n P(A | B_j)P(B_j) \quad \text{全概率公式}$$

同时 $P(B_i A) = P(A | B_i) P(B_i)$ 条件概率定义

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \quad i = 1, 2, \dots, n$$


Remark 1: 该公式于1763年由贝叶斯(Bayes)给出，故称贝叶斯公式。它是在观察到事件A已发生的条件下，寻找导致A发生的各个原因的的概率，故也称为**逆概率公式**。

贝叶斯公式图示



设 $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分

设 $P(B_j) = p_j, P(A | B_j) = q_j, j = 1, 2, \dots, n$.



$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^n P(B_j)P(A | B_j)} = \frac{p_i q_i}{\sum_{j=1}^n p_j q_j}$$

Remark 2: 注意贝叶斯公式对于任意事件 B (不一定要是 B_i)成立

$$P(B | A) = \frac{P(A | B)P(B)}{\sum_{j=1}^n P(A | B_j)P(B_j)}$$



	甲厂	乙厂	丙厂
产品百分比	15%	80%	5%
产品次品率	2%	1%	3%

已知抽到一件次品，则该次品是甲工厂生产的概率为 [填空1]

作答



[贝叶斯公式的应用1--敏感性调查]

如果我们提出这样一个问题：“你考试作弊过吗？”恐怕我们得不到正确的回答。对此，我们的另一种做法是列出如下两个问题（其中一个是无关系要的）：

S: 你考试作弊过吗？

T可以换成其他常识性的问题，

T: 你的电话号码末尾是偶数吗？

如：你的生日是在7月之前吗？

要求被提问者在无人旁观情况下投掷一个硬币，出现正面时正确回答 S，反面时正确回答 T。提问者并不知道被提问者回答的是哪个问题。在一次对 120 名学生的调查中，有 40 个回答“是”。试计算考试作弊的概率。



[贝叶斯公式的应用2—垃圾邮件过滤]

- 先准备两组已识别好的邮件，一组为垃圾邮件（4000封），另一组为正常邮件（4000封）。
- 统计各个词语在上述正常邮件和垃圾邮件中出现的频率。如：对于“广告”一词，在4000封垃圾邮件中，有200封包含了“广告”，那么 $P(\text{广告}|\text{垃圾})=0.05$ ；在4000封正常邮件中，有2封包含了“广告”，那么 $P(\text{广告}|\text{正常})=0.0005$ 。
- 对于一封待判别的邮件，先假定其为正常邮件或垃圾邮件的概率都为0.5，即 $P(\text{垃圾})=P(\text{正常})=0.5$ 。
- 解析该邮件中含有的词语，发现了“广告”一词，那么根据贝叶斯公式推算出，该封邮件为垃圾邮件的概率

$$P(\text{垃圾}|\text{广告}) = \frac{P(\text{广告}|\text{垃圾}) \times P(\text{垃圾})}{P(\text{广告}|\text{垃圾}) \times P(\text{垃圾}) + P(\text{广告}|\text{正常}) \times P(\text{正常})} \approx 0.99。$$

- 由于一封邮件包含多个词，一些词（如“广告”“促销”）预示这封邮件为垃圾邮件，但另一些词（如“创新”）预示这封邮件为正常邮件。处理的方法是：选出概率 $P(\text{垃圾}|\text{xx})$ 最高的15个，计算这15个概率的乘积，记为 λ 。如果 $\lambda \geq 0.9$ ，认定该邮件为垃圾邮件；否则，认定该邮件为正常邮件。

朴素贝叶斯分类法（Naïve Bayes classifier）

贝叶斯公式

B_i 可视为原因, A 可视为结果



$$P(B_i|A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \quad i = 1, 2, \dots, n$$

Remark 3: $P(B_i)$ 称为 **先验概率**, $P(B_i | A)$ 称为 **后验概率**
($P(A|B_i)$ 称为 **似然概率** *)

$P(B_i)$ ($i=1,2,\dots,n$) 是基于以往的统计, 人们对诸事件发生可能性大小的认识, 故称为先验概率。

当有了新的信息 (知道 A 发生) 后, 人们对诸事件发生可能性大小 $P(B_i | A)$ 有了新的估计, 故称为后验概率。贝叶斯公式从数量上刻划了这种变化。

比较 $P(B_1 | A)$ 、 $P(B_2 | A)$ 、.....、 $P(B_n | A)$ 的大小, 则知导致 A 发生的最可能的原因。


贝叶斯公式



Example3 (习题40 pp.29) 将A,B,C三个字母之一输入信道，输出为原字母的概率为 α ，而输出为其他一字母的概率均为 $(1-\alpha)/2$ 。今将字母串AAAA,BBBB,CCCC之一输入到信道，输入的概率分别为 p_1, p_2, p_3 ($p_1 + p_2 + p_3 = 1$)。假设信道传输各个字母的工作是独立的。

已知：输出为ABCA

问：(1)输入的是AAAA的概率是多少？ (2)最有可能的输入是什么？





第1问：已知输出为**ABCA**，则输入**AAAA**的概率为

$$P(AAAA|ABCA) = \frac{P(ABCA|AAAA)P(AAAA)}{P(ABCA)}$$

$$\begin{aligned} P(ABCA|AAAA)P(AAAA) &= \alpha \frac{(1-\alpha)}{2} \bullet \frac{(1-\alpha)}{2} \alpha p_1 \\ &= p_1 \alpha (1-\alpha)(1-\alpha) \alpha / 4 \end{aligned}$$

$$\begin{aligned} P(ABCA) &= P(ABCA|AAAA)P(AAAA) \\ &\quad + P(ABCA|BBBB)P(BBBB) \\ &\quad + P(ABCA|CCCC)P(CCCC) \\ &= p_1 \alpha (1-\alpha)(1-\alpha) \alpha / 4 \\ &\quad + p_2 \alpha (1-\alpha)(1-\alpha)(1-\alpha) / 8 \\ &\quad + p_3 \alpha (1-\alpha)(1-\alpha)(1-\alpha) / 8 \end{aligned}$$

$$\begin{aligned} P(AAAA|ABCA) &= 2p_1 \alpha / \{ 2p_1 \alpha + p_2 (1-\alpha) + p_3 (1-\alpha) \} \\ &= 2p_1 \alpha / \{ (3\alpha - 1)p_1 + (1-\alpha) \} \end{aligned}$$



第2问：若输出**ABCA**，最有可能的输入是**AAAA,BBBB,CCCC**中的哪个？

假设 $\alpha = 0.8$ ，取不同的 p_1, p_2, p_3 ，可以看到下面的结果：

先验概率			传输正 确概率	传输错 误概率	似然概率			后验概率		
$p_1(\text{AAAA})$	$p_2(\text{BBBB})$	$p_3(\text{CCCC})$	α	$(1-\alpha)/2$	$\text{ABCA} \text{AAAA}$	$\text{ABCA} \text{BBBB}$	$\text{ABCA} \text{CCCC}$	$\text{AAAA} \text{ABCA}$	$\text{BBBB} \text{ABCA}$	$\text{CCCC} \text{ABCA}$
0.3	0.4	0.3	0.8	0.1	0.0064	0.0008	0.0008	0.774194	0.129032	0.096774
0.1	0.8	0.1	0.8	0.1	0.0064	0.0008	0.0008	0.470588	0.470588	0.058824
0.05	0.9	0.05	0.8	0.1	0.0064	0.0008	0.0008	0.296296	0.666667	0.037037

- 从错误率来看，最像是**AAAA->ABCA**，即似然概率中 $P(\text{ABCA}|\text{AAAA})$ 最大。
- 但第三行中，后验概率中 $P(\text{BBBB}|\text{ABCA})$ 最大，即最有可能是由**BBBB->ABCA**。这是因为此时输入AAAA的先验概率太小了 ($p_1=0.05$)，体现了先验概率对于整个估计的影响。
- 在机器/统计学习中，第一种方法被称为 **最大似然方法**，第二种方法被称为 **最大后验方法**。
- 很多事实证明，最大后验方法比起最大似然方法预测效果很好。



甲乙丙分别操纵三门炮向一飞机射击。设他们的命中率分别为0.4、0.5、0.7；如只有一人射中，飞机坠毁的概率为0.2，如两个射中，飞机坠毁的概率为0.6，如三人都射中，则飞机必坠毁。

现三人同时射击，发现飞机坠毁了，那么甲击中的概率为 [填空1]

提示：思考这时的样本空间怎么划分

作答

思考题



根据以往的临床记录，某种诊断癌症的试验具有5%的假阳性及3%的假阴性，即

若设 A ={试验反应是阳性}， C ={被诊断者患有癌症}，则有

$$P(A|\bar{C}) = 5\%, P(\bar{A}|C) = 3\%,$$

现对自然人群进行普查，设患有癌症的概率为0.005， $P(C)=0.005$ ，问这种方法能否用于普查？

提示：计算 $P(C|A)$

本周任务



- 思考题
- 针对全概公式与贝叶斯公式，做教材课后习题的23、25、20、24 (不交)

本次课小调查

