



Chpt.5 Law of Large Number & Central Limit

第五章 大数定理及中心极限定理

上节回顾



- 协方差:


$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

- 相关系数:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

- 不相关 **vs** 独立:

X 与 Y 相互独立



X 与 Y 不相关

(X, Y) 服从正态分布, 则 X, Y 独立与 X, Y 不相关是等价的, 充要条件都是 $\rho = 0$



n 维正态随机变量具有以下四条重要性质(证略):

1° n 维正态随机变量 $(X_1, X_2, \dots, X_n)$ 的每一个分量 $X_i, i=1, 2, \dots, n$ 都是正态随机变量;反之,若 $X_1, X_2, \dots, X_n$ 都是正态随机变量,且相互独立,则 $(X_1, X_2, \dots, X_n)$ 是 n 维正态随机变量.

2° n 维随机变量 $(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布的充要条件是 $X_1, X_2, \dots, X_n$ 的任意的线性组合

$$l_1 X_1 + l_2 X_2 + \dots + l_n X_n$$

服从一维正态分布(其中 $l_1, l_2, \dots, l_n$ 不全为零).

3° 若 $(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布,设 $Y_1, Y_2, \dots, Y_k$ 是 X_j ($j=1, 2, \dots, n$) 的线性函数,则 $(Y_1, Y_2, \dots, Y_k)$ 也服从多维正态分布.

这一性质称为正态变量的线性变换不变性.

4° 设 $(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布,则“ $X_1, X_2, \dots, X_n$ 相互独立”与“ $X_1, X_2, \dots, X_n$ 两两不相关”是等价的.

n 维正态分布在随机过程和数理统计中常会遇到.

思考题



设随机变量 (X, Y) 服从二元正态分布 $N(0, 1; 1, 4; -\frac{1}{2})$, 求:

(1) $D(2X - Y)$; (2) $P(2X > Y)$; (3) (Z_1, Z_2) 的分布, $Z_1 = X + Y, Z_2 = X - Y$.



请同学们思考以下两个问题：

1. 如果想测得抛一枚硬币正面朝上的概率，你会怎么办？
这样做为什么是可行的？
2. 如果想知道南开大学所有学生的平均身高，你会怎么办？
这样做为什么是可行的？



本章工作目标包括两个：

- [1] 对概率论中的一些结论作出严格的证明；
- [2] 为后面的数理统计作出准备。

概率论早期发展的目的：揭示随机现象的规律性.

概率与频率之间的关系 → 大数定律：研究无穷随机试验序列，刻画事件发生的频率与它的概率之间的关系。

大量的相互独立的随机因素的综合影响 → 中心极限定理：将观察的误差看作大量独立微小误差的累加，其分布渐近正态。

5.1 Law of Large Number



问题：频率→概率，如何定义这里的“趋向于”？

在相同的条件下，进行 n 次独立试验，其中事件 A 发生的次数记为 n_A ，定义频率 $f_n(A) = \frac{n_A}{n}$ ，我们说 $f_n(A) \rightarrow p$ ， p 就是事件 A 发生的概率。

用数列极限的语言来描述就是：

$$\forall \varepsilon > 0, \exists N, \text{当 } n > N \text{ 时}, \left| \frac{n_A}{n} - p \right| \leq \varepsilon$$



$$\forall \varepsilon > 0, \exists N, \text{当 } n > N \text{ 时}, \left| \frac{n_A}{n} - p \right| \leq \varepsilon$$

其实这里的 n_A 是一个**随机变量**

因此, $\left| \frac{n_A}{n} - p \right| \leq \varepsilon$ 表示的是一个事件, 说 $n > N$ 时, **总有** $\left| \frac{n_A}{n} - p \right| \leq \varepsilon$

是不符合逻辑的, 只能说以**多大的概率**上式成立。因此, 我们改写为

$$P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} \rightarrow 1$$

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = 1 \quad \text{称 } \frac{n_A}{n} \text{ 依概率收敛于 } p$$



能否证明频率以概率收敛于概率？

证明：从 n 重实验看起（ n 重实验意味着：**独立同分布**）

定义指示变量

$$X_i = \begin{cases} 1 & \text{第}i\text{次实验中}A\text{出现} \\ 0 & \text{A未出现} \end{cases}$$

$$n_A = X_1 + X_2 + \cdots + X_n$$

$$Y_n = \frac{n_A}{n} = \frac{1}{n} (X_1 + X_2 + \cdots + X_n)$$

若设一次试验中，事件 A 发生的概率为 p ，则有：

$$E(X_i) = p, D(X_i) = p(1-p) = \sigma^2$$

$$E(Y_n) = p, \quad D(Y_n) = \frac{1}{n} \sigma^2$$

能否证明频率以概率收敛于概率？



$$P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = P\{|Y_n - p| \leq \varepsilon\}$$
$$\geq 1 - \frac{D(Y_n)}{\varepsilon^2} = 1 - \frac{1}{n} \left(\frac{\sigma^2}{\varepsilon^2} \right)$$

$$1 \geq P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = P\{|Y_n - p| \leq \varepsilon\} \geq 1 - \frac{1}{n} \left(\frac{\sigma^2}{\varepsilon^2} \right)$$

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = 1$$

[伯努利大数定理] 设 n_A 是 n 次独立试验中事件A发生的次数， p 是事件A在一次试验中发生的概率，则对任意的 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = 1$$

定义： 一个随机变量的序列 $Y_1, Y_2, \dots, Y_n, \dots$ ，如果对任意 $\varepsilon > 0$ ，有 $\lim_{n \rightarrow \infty} P\{|Y_n - p| \leq \varepsilon\} = 1$ ，则称序列 Y_n 依概率收敛到 p ，记为

$$Y_n \xrightarrow{P} p(n \rightarrow \infty)$$

Remark（大数定律含义之一）： Bernoulli大数定理说明事件A发生的频率 n_A / n 依概率收敛到事件A的概率 p 。以严格的数学形式表达了我们的直观看法。在实际应用中，**当试验次数足够大时，便可以用事件的频率来代替事件的概率 p （即如何求一个抽象的概率 p ）**



[**切比雪夫大数定理**] 设随机变量 $X_1, \dots, X_n, \dots$ 相互**独立**, 且具有**相**
同的数学期望与方差, 记为 $E(X_i) = \mu \quad D(X_i) = \sigma^2 (i = 1, 2, \dots, n, \dots)$ 。

则对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} (X_1 + \dots + X_n) - \mu \right| \leq \varepsilon \right\} = 1$$

也就是说, $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$, 当 $n \rightarrow +\infty$.

注: 伯努利大数定理是切比雪夫大数定理的特殊形式。



$D(X)$ 存在 $\Rightarrow E(X)$ 存在 

$D(X)$ 存在 $\Leftarrow E(X)$ 存在 

切比雪夫大数定理要求期望和方差都存在

如果期望存在，方差不存在会如何？



[辛钦大数定理] 设随机变量 $X_1, \dots, X_n, \dots$ 相互独立且同分布，数学期望存在，记为 μ 。则对任意的 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} (X_1 + \dots + X_n) - \mu \right| \leq \varepsilon \right\} = 1$$

也就是说， $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$ ，当 $n \rightarrow +\infty$ 。

注意：这里我们没有要求它的方差存在。如果方差不存在，也可以使用辛钦大数定理。



例题：

设随机变量 $X_1, X_2, \dots, X_n, \dots$, 相互独立同分布, $X_1 \sim U(-1, 1)$. 则

(1) $\frac{1}{n} \sum_{i=1}^n X_i$, (2) $\frac{1}{n} \sum_{i=1}^n |X_i|$, (3) $\frac{1}{n} \sum_{k=1}^n X_i^2$ 分别依概率收敛吗？

如果依概率收敛, 分别收敛于什么? (当 $n \rightarrow +\infty$ 时)



概括前面的几个定理，可以归结为两点：

1 频率稳定性： 事件A发生的频率依概率收敛到事件A的概率

事件A发生的概率为 p	$\Rightarrow \frac{n_A}{n} \xrightarrow{p} p (n \rightarrow \infty)$
进行n次独立试验，A出现 n_A	

2 算术均值稳定性：

随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立	$\Rightarrow \frac{1}{n} (X_1 + X_2 + \dots + X_n) \xrightarrow{p} \mu (n \rightarrow \infty)$
具有相同的期望 μ 和方差 σ^2 或者同分布且期望 μ 存在	



Remark (大数定律含义之二) :

满足一定条件的随机变量 $X_1, \dots, X_n, \dots$, 当 n 很大时, 算术平均 $\frac{1}{n}(X_1 + \dots + X_n)$ 接近于数学期望 $E(X_i) = \mu$ 。

■ 提供了求随机变量 X 的数学期望 $E(X)$ 的近似值的方法:
将随机变量 X 独立重复地观察 n 次, 记第 k 次观测值为 X_k ,
则 $X_1, X_2, \dots, X_n$ 相互独立, 且与 X 具有同样的分布。

那么, 当 $E(X)$ 存在时, 由辛钦大数定律, 可知当 n 充分大时, 可将 n 次的平均 $\frac{1}{n} \sum_{i=1}^n X_i$ 作为 $E(X)$ 的近似。

补充：依概率收敛的性质



依概率收敛的性质：

若 $X_n \xrightarrow{P} a$, $Y_n \xrightarrow{P} b$, 当 $n \rightarrow \infty$ 时, 函数 $g(x, y)$ 在点 (a, b) 处连续, 那么 $g(X_n, Y_n) \xrightarrow{P} g(a, b)$, 当 $n \rightarrow \infty$ 时.

如：当 $n \rightarrow \infty$ 时, $X_n + Y_n \xrightarrow{P} a + b$,
 $X_n \times Y_n \xrightarrow{P} a \times b$, $X_n / Y_n \xrightarrow{P} a / b$ ($b \neq 0$).

特别地, 若 $X_n \xrightarrow{P} a$, $f(x)$ 在点 a 连续, 则 $f(X_n) \xrightarrow{P} f(a)$, 当 $n \rightarrow \infty$ 时.



设随机变量 $X_1, X_2, \dots, X_n, \dots$ 独立同分布,

$X_1 \sim U(0, 1)$, 则 $\sqrt[n]{X_1 X_2 \dots X_n}$ 依概率收敛吗?

如果依概率收敛, 收敛于什么?



解：记 $Y_n = \sqrt[n]{X_1 \dots X_n}$ ，令 $Z_n = \ln Y_n = \frac{1}{n} (\ln X_1 + \dots + \ln X_n)$ 。

则 $\ln X_1, \dots, \ln X_n, \dots$ 相互独立同分布，又

$$E(\ln X_1) = \int_0^1 \ln x dx = -1, \quad \text{分部积分法}$$

那么由辛钦大数定律知，故 $Z_n \xrightarrow{P} -1$ ，当 $n \rightarrow +\infty$ 。

利用依概率收敛的性质，得

$$Y_n = e^{Z_n} \xrightarrow{P} e^{-1}, \quad \text{当 } n \rightarrow +\infty.$$

思考题



设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, $E(X_i) = \mu$, $D(X_i) = \sigma^2$, 令

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

求证: $S_n^2 \xrightarrow{P} \sigma^2$

中心极限定理




有许多随机变量，它们是由大量的相互独立的随机变量的综合影响所形成的，而其中每个个别的因素作用都很小，这种随机变量的往往服从或近似服从正态分布，或者说它的极限分布是正态分布，中心极限定理正是从数学上论证了这一现象，它在长达两个世纪的时期内曾是概率论研究的中心课题。

现象观察



X_1



$X_1 + X_2 = ?$

X_1 服从 $U(0,1)$

X_1, X_2 都服从 $U(0,1)$,
且 X_1 和 X_2 独立



若 X_1, X_2 都服从 $U(0,1)$ ，且 X_1 和 X_2 独立，求 X_1+X_2 的分布。


作答

现象观察




X_i 服从 $U(0,1)$


$$X_1$$




$$X_1 + X_2$$



$$X_1 + X_2 + X_3$$



$$X_1 + X_2 + X_3 + X_4$$





5.2 中心极限定理

记随机变量的和为 $Y_n = \sum_{k=1}^n X_k$ 此处没求 $1/n$ ，直接累加

考虑随机变量和的标准化形式

$$Z_n = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}}$$

可知 $E(Z_n) = 0$, $D(Z_n) = 1$

问题： Z_n 的极限分布是什么呢？



[定理1]: 德莫佛—拉普拉斯定理 (独立同分布的中心极限定理)

如果随机变量 $X_1, \dots, X_n, \dots$ 独立同分布, 数学期望与方差存

在, $E(X_i) = \mu$, $D(X_i) = \sigma^2 (i = 1, 2, \dots, n, \dots)$, 记 $Y_n = \sum_{i=1}^n X_i$

其标准化变量 $Z_n = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}} = \frac{Y_n - n\mu}{\sqrt{n\sigma^2}}$, 其分布函数记为 $F_n(x) = P\{Z_n \leq x\}$

那么对于任意 x 满足

$$F(x) = \lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \Phi(x)$$

也就是说, Z_n 的分布的极限为标准正态分布。(证明略)

推论: 当 n 充分大时, 近似有

$$\begin{aligned} \text{令 } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad & \frac{Y_n - n\mu}{\sqrt{n\sigma^2}} \sim N(0,1) \quad \Rightarrow \quad Y_n \sim N(n\mu, n\sigma^2) \\ & \downarrow \\ & \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1) \quad \Rightarrow \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \end{aligned}$$

定理1表明:



- n 个均值为 μ ，方差为 σ^2 独立同分布的随机变量之和 $\sum_{i=1}^n X_i$ ，当 n 充分大时，近似地服从均值为 $n\mu$ ，方差为 $n\sigma^2$ 正态分布。
- n 个均值为 μ ，方差为 σ^2 独立同分布的随机变量的算术平均 $\frac{1}{n} \sum_{i=1}^n X_i$ ，当 n 充分大时，近似地服从均值为 μ ，方差为 σ^2/n 正态分布。



若 X_i 不是同分布的，也有类似的定理成立。

[定理2 (Lyapunov李雅普诺夫定理)] 如随机变量 $X_1, \dots, X_n, \dots$ **相互独立**，数学期望 $E(X_i) = \mu_i$ 与方差 $D(X_i) = \sigma_i^2 \neq 0$ ($i = 1, 2, \dots, n, \dots$)，记 $Y_n = \sum_{k=1}^n X_k$

$$B_n^2 = D(Y_n) = \sum_{k=1}^n \sigma_k^2 \quad Z_n = \frac{Y_n - E(Y_n)}{B_n} = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}}$$

分布函数 $F_n(x) = P\{Z_n \leq x\}$ ，如果存在正数 $\delta > 0$ 使 $n \rightarrow \infty$ 时

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{(X_k - \mu_k)^{2+\delta}\} \rightarrow 0 \quad \text{那么分布函数列的极限为}$$

$$F(x) = \lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \Phi(x)$$



定理2说明:

当 n 充分大时, $Z_n = \frac{Y_n - E(Y_n)}{D(Y_n)}$ 近似地服从标准正态分布 $N(0,1)$ 。

由此, 当 n 很大时, $Y_n = \sum_{k=1}^n X_k$ 近似地服从正态分布 $N(\sum_{k=1}^n \mu_k, \sum_{k=1}^n \sigma_k^2)$

总结: 独立的随机变量 $X_1, \dots, X_n, \dots$, 不管 X_k 本身是什么样的分布, 只要满足一定的条件, 当 n 充分大时, n 个随机变量的和 $\sum_{k=1}^n X_k$ 都近似地服从正态分布。



[1] 在客观的实际应用中，所考虑的对象往往是由大量的相互独立的随机因素的综合影响形成（往往是和的形式），尽管这诸多的因素之分布是未知的，但是它们的和往往近似服从正态分布，例如误差服从正态分布；

[2] 在实际应用中，我们进行分析往往是观察值的和或平均，而由上述定理保证当样本个数足够大时，和或平均趋于正态分布，这在后面的统计推断中是极其重要的。

正是上述定理所陈述的是分布的极限，以及它们在应用统计中的重要性（或中心地位），Polya在1920年给它取名为“中心极限定理”



Example 设一次贝努里试验中成功的概率为 p ($0 < p < 1$), 令 S_n 表示 n 重贝努里试验中成功的次数, 那么 $S_n \sim B(n, p)$.

在实际问题中, 人们常常对成功次数介于整数 α 、 β 之间($\alpha < \beta$)的概率感兴趣, 即要计算

$$P\{\alpha \leq S_n \leq \beta\} = \sum_{\alpha \leq k \leq \beta} B(k, n, p)$$

这一和式往往涉及很多项, 直接计算相当困难. 然而我们注意到

$S_n = X_1 + X_2 + \cdots + X_n$, 其中 X_i 表示第 i 次试验的结果, X_i 独立同分布, $E(X_i) = p$, $D(X_i) = p(1-p)$, $E(S_n) = np$, $D(S_n) = np(1-p)$, 则有

[定理3]: 二项分布近似于正态分布

$$\frac{S_n - E(S_n)}{\sqrt{D(S_n)}} = \frac{S_n - np}{\sqrt{np(1-p)}} \quad \text{近似服从 } N(0, 1)$$

这个定理表示二项分布的标准化变量依分布收敛于标准正态分布.

因此, **二项分布渐近于正态分布**. S_n 近似服从 $N(np, np(1-p))$

S_n 近似服从 $N(np, np(1-p))$




$$P\{\alpha \leq S_n \leq \beta\} \approx \int_{\alpha}^{\beta} f(x) dx$$

$f(x)$ 是正态分布 $N(np, np(1-p))$ 的密度函数

它的含义可用下图显示：

- 作相邻小矩形，各小矩形的底边中心为 k ($\alpha \leq k \leq \beta$)，底边长为1，高度为 $b(k; n, p)$ ，那么这些小矩形面积之和即为 $P(\alpha \leq S_n \leq \beta)$.
- 再作正态分布 $N(np, np(1-p))$ 的密度曲线，其在 $[\alpha, \beta]$ 之间曲线覆盖的面积为上式右边的值.

可见，小矩形面积之和与密度曲线在 $[\alpha, \beta]$ 之间覆盖得面积非常相近。



泊松定理 vs 中心极限定理



[泊松(Poisson)定理] 如果存在正常数 λ ，当 $n \rightarrow \infty$ 时有 $np_n \rightarrow \lambda$ ，则

$$\lim_{n \rightarrow \infty} b(k, n, p) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0,1,2,\dots$$

Remark: 泊松定理与定理3是没有矛盾的. 因为泊松定理要求 $\lim_{n \rightarrow \infty} np_n = \lambda$ 而定理3中的 p 是固定的常数.

实际应用中，当 n 很大时

[1] 若 p 大小适中，可以用正态分布去逼近;

[2] 如果 p 接近0, 且 np 较小，则二项分布的图形偏斜度太大，用正态分布去逼近效果就不好，此时用泊松分布去估计精度会更高.



定理3的直接应用是:

n 重贝努里实验中, 成功次数介于整数 α 、 β 之间的概率,
当 n 很大, p 的大小适中时, 可用正态分布近似计算:

$$P\{\alpha \leq S_n \leq \beta\} = P\left\{\frac{\alpha - np}{\sqrt{np(1-p)}} \leq \frac{S_n - np}{\sqrt{np(1-p)}} \leq \frac{\beta - np}{\sqrt{np(1-p)}}\right\}$$
$$\approx \Phi\left(\frac{\beta - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{\alpha - np}{\sqrt{np(1-p)}}\right)$$

本次课小调查2024

