



Chpt.6 Sampling and Distribution

第六章 样本及抽样分布



思考题：某保险公司发行一年期的保险索赔金分别为1万元与2万元的两种人身意外险. 索赔概率 q_k 及投保人数 n_k 如下表所示（金额单位：万元）

类别 k	索赔概率 q_k	索赔额 b_k	投保数 n_k
类别1	0.02	1	500
类别2	0.02	2	500
类别3	0.10	1	300
类别4	0.10	2	500

保险公司希望**只有0.05的可能使索赔金额超过所收取的保费总额**. 设该保险公司按期望值原理进行保费定价，即收取的保费应为索赔金额期望的函数，即保单 i 的保费 $\pi(X_i)=(1+\theta)E(X_i)$. 要求估计 θ .



设第*i*笔保单的索赔额为 X_i ，则索赔总额为 $S = \sum_{i=1}^{1800} X_i$

$$ES = \sum_{i=1}^{1800} EX_i = \sum_{k=1}^4 n_k b_k q_k \quad \text{总索赔的期望}$$

$$= 500 \cdot 1 \cdot 0.02 + 500 \cdot 2 \cdot 0.02 + 300 \cdot 1 \cdot 0.10 + 500 \cdot 2 \cdot 0.10 = 160,$$

$$\begin{aligned} VarS &= \sum_{i=1}^{1800} VarX_i = \sum_{k=1}^4 n_k b_k^2 q_k (1 - q_k) \\ &= 500 \cdot 1^2 \cdot 0.02 \cdot 0.98 + 500 \cdot 2^2 \cdot 0.02 \cdot 0.98 \\ &\quad + 300 \cdot 1^2 \cdot 0.10 \cdot 0.90 + 500 \cdot 2^2 \cdot 0.10 \cdot 0.90 \\ &= 256 \end{aligned}$$

总索赔的方差



由此得保费总额

$$\pi(S) = (1 + \theta)ES = 160(1 + \theta).$$

依题意，我们有

$$P(S \leq (1 + \theta)ES) \geq 0.95$$

也即

$$P\left(\frac{S - ES}{\sqrt{\text{Var}S}} \leq \frac{\theta ES}{\sqrt{\text{Var}S}}\right) = P\left(\frac{S - ES}{\sqrt{\text{Var}S}} \leq 10\theta\right) \geq 0.95$$

由Lyapunov中心极限定理， $\frac{S - E(S)}{\sqrt{D(S)}}$ 近似服从标准正态分布，所以
 $\Phi(10\theta) \geq 0.95$

查表可得， $10\theta = 1.645$ ，故 $\theta = 0.1645$

思考题



设随机变量 X 的分布函数为 $F(x)$ ，且 $F(x)$ 是连续函数，令 $Y=F(X)$ ，求随机变量 Y 的分布函数。

设 X 是一个随机变量， $F(x)$ 是 X 的分布函数，且为连续函数。令 $Y=F(X)$ 。

求 Y 的分布。

解： $F_Y(y) = P(Y \leq y) = P(F(X) \leq y)$

若 $y < 0$, $F_Y(y) = P(F(X) \leq y) = 0$

若 $y \geq 1$, $F_Y(y) = P(F(X) \leq y) = 1$

若 $0 < y < 1$, 见右图, 取 $\sup\{x | F(x) = y\} = x_0$
 $F(x_0) = y$

$$\begin{aligned} F_Y(y) &= P(F(X) \leq y) \\ &= P(X \leq x_0) \\ &= F(x_0) = y \end{aligned}$$

分布函数

$$\therefore F_Y(y) = \begin{cases} 0 & y \leq 0 \\ y & 0 < y < 1 \\ 1 & y \geq 1 \end{cases}$$

密度函数

$$f_Y(y) = \begin{cases} 1 & 0 < y < 1 \\ 0 & \text{其他} \end{cases}$$

$$Y = F(X) \sim U[0, 1]$$

由 $F(x)$ 的性质知:

$$F(+\infty) = 1, F(-\infty) = 0$$

$F(x)$ 单调不减

由条件知 $F(x)$ 连续




图1




图2

解释: $F_Y(0) = \lim_{\varepsilon \rightarrow 0^+} F_Y(\varepsilon) = \lim_{\varepsilon \rightarrow 0^+} \varepsilon = 0$
 (分布函数是右连续的)



概率论：

- 假设已知随机变量服从某一分布，研究它的性质、特点与规律，如求数字特征、随机变量函数的分布，介绍常用的各种分布等；

但是：

- 概率论中所描述的知识是如何获取的？
比如，假如 X 服从正态分布，如何获取其参数？
- 实际中，如何判断一个随机变量是否服从某一分布？
比如，如何判断 X 是否为正态分布？



数理统计:

- 随机变量其分布未知或者不完全知道(如: 是正态分布, 但不知参数), 希望通过重复的、独立的观察得到许多数据, 以概率论为理论基础, 通过对这些数据的分析, 对所研究的随机变量的分布做出种种推断。
- 统计需要进行抽样、推断, 这些工作形成了统计推断理论



□ 大数定理

1 频率稳定性：事件A发生的频率以概率收敛到概率p

$$\frac{n_A}{n} \xrightarrow{p} p \quad (n \rightarrow \infty)$$

2 算术均值稳定性： $\frac{1}{n}(X_1 + X_2 + \cdots + X_n) \xrightarrow{p} \mu \quad (n \rightarrow \infty)$

□ 中心极限定理

大量相互独立的随机因素，尽管这诸多的因素的分布是未知的，但是它们的和近似服从正态分布。

总体、个体



[定义]：在数理统计中，我们一般研究数量指标

- 对某一个数量指标进行随机实验或观察，试验的全部观察值称为总体。
- 每个观察值称为个体
- 总体中所包含的个体的数目称为总体的容量。容量有限的称为有限总体，容量无限的称为无限总体。

总体是对象某些指标的所有观察值：

- 扔硬币1000次，观察正面朝上的情况，得到1000个数值。
- 200位南开大学学生的身高。
- 天津市每天的最高气温。



随机变量 vs 总体:

区别: 随机变量包含一组互异的值, 以及对应每个值(或一个区间)出现的可能性大小。随机变量是从概率角度看的。

总体是将所有试验结果一一罗列, 可能出现大量相等的值。总体是从统计的角度看的。

Example: 随机抛一枚硬币1000次, 随机变量X表示正面朝上的次数。

X	0	...	i	...	1000
P	$C_{1000}^0 \left(\frac{1}{2}\right)^{1000}$	...	$C_{1000}^i \left(\frac{1}{2}\right)^{1000}$	...	$C_{1000}^{1000} \left(\frac{1}{2}\right)^{1000}$

抛硬币, 观察1000次, 0表示正面朝上, 1表示反面朝上, 总体为

实验序号	1	2	3	4	...	1000
观察值	0	1	0	0	...	1

随机变量 vs 总体：



上例中的总体对应哪个随机变量？

0-1分布的随机变量

联系： 总体中的每个值是对某个随机变量的观察值，也就是说一个总体对应一个随机变量；

总体的研究 $\longleftrightarrow$ 随机变量的研究

随机变量的分布、数字特征就称为总体的分布、数字特征

总结：从理论角度来看，随机变量和总体是不一样的
从实操角度来看，把它们看成是同一个对象

注：在今后的数理统计学习中，将不区分总体与对应的随机变量，统称为**总体X**



在实际中总体的分布是未知的，你觉得应如何研究？

- ☐ A 逐个观察总体中的每个个体
- ☐ B 选取有代表性的个体

提交



从总体中抽取样本必须满足：

抽样是从总体中抽取部分个体，用于推断总体的特性。
被抽出的部分个体称为总体的一个**样本**。

(1) **随机性** 为使样本具有充分的代表性，抽样必须是随机的，应使总体中的**每一个个体都有同等的机会被抽取到**。

(2) **独立性** 各次抽样必须是相互独立的，即每次抽样的结果既不影响其它各次抽样的结果，也不受其它各次抽样结果的影响。

称这种随机的、独立的抽样为**简单随机抽样**
由此得到的样本称为**简单随机样本**。



对有限总体做有放回抽样是简单随机抽样吗？

- ☐ A 是
- ☐ B 不是

提交



对有限总体做无放回抽样是简单随机抽样吗？

- ☐ A 是
- ☐ B 不是

提交



- 对有限总体进行放回抽样，属于简单随机抽样。
- 对有限总体进行不放回抽样，理论上不是简单随机抽样。
- 当总体容量 N 很大而样本容量 n 较小($n/N \leq 10\%$)时，在实际中可将不放回抽样近似看作简单随机抽样。
- 对于无限总体，一般采取不放回抽样。



6.1 样本概念

从总体中抽取 n 个样本，就是对总体所对应的随机变量 X 独立地进行 n 次观测，**每次观测的结果仍可以看作一个随机变量。**

记 n 次观测结果对应 n 个随机变量： $X_1, \dots, X_n$ ，它们相互独立，并与总体 X 服从相同的分布。

实际中抽样一经完成，就会得到一组实数值 $x_1, x_2, \dots, x_n$ ，称为样本值。

若将样本 $X_1, \dots, X_n$ 看作一个 n 维随机向量 $(X_1, \dots, X_n)$ ，则

(1) 当总体 X 是离散随机变量，且概率分布为 $p(x)$ 时， $(X_1, \dots, X_n)$ 的联合分布律为

$$p(x_1, \dots, x_n) = p(x_1)p(x_2) \cdots p(x_n)$$

(2) 当总体 X 是连续随机变量，且概率密度为 $f(x)$ 时， $(X_1, \dots, X_n)$ 的联合概率密度为

$$f(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n)$$

6.2 统计量



来自总体 X 的 n 个样本 $X_1, \dots, X_n$ 构成 n 维随机向量 $(X_1, \dots, X_n)$,
若 n 元函数 g 中不含任何未知参数, 则称 $g(X_1, \dots, X_n)$ 为
统计量。

Remark: 统计量 $g(X_1, \dots, X_n)$ 本质上是一个随机变量。

设样本 $X_1, \dots, X_n$ 的一组观测值为 $x_1, \dots, x_n$, 算得的函数值
 $g(x_1, \dots, x_n)$ 称为统计量 $g(X_1, \dots, X_n)$ 的观测值。

- 研究理论规律时要视为随机变量
- 实际应用中可以直接用观测值

常用统计量及其观测值：

(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 观测值为 $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$

(2) 样本方差 $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$

观测值为 $s^2 = \frac{1}{n-1} \sum_{k=1}^n (x_i - \bar{x})^2$

为什么这里
分母是n-1?

(3) 样本标准差 $S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2}$

观测值为 $s = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_i - \bar{x})^2}$

常用统计量及其观测值：

(4) 样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

观测值为 $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$

(5) 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

观测值为 $b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$

样本方差 vs 样本的二阶中心矩



样本方差

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$$

样本的二阶中心矩

$$B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Example 设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, $E(X_i) = \mu$, $D(X_i) = \sigma^2$ 令,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

求证: $S_n^2 \xrightarrow{P} \sigma^2$ 统计中的重要观点!

由此可以推出: $S^2 \xrightarrow{P} \sigma^2$

思考题: 设 X 是一个随机变量, 其均值为 μ , 方差为 σ^2 , $X_1, X_2, \dots, X_n$ 是 X 的简单随机样本, S^2 为样本方差, 即

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

证明: $E(S^2) = \sigma^2$.

经验分布函数



经验分布函数 我们还可以作出与总体分布函数 $F(x)$ 相应的统计量——经验分布函数. 它的作法如下: 设 $X_1, X_2, \dots, X_n$ 是总体 F 的一个样本, 用 $S(x)$, $-\infty < x < \infty$ 表示 $X_1, X_2, \dots, X_n$ 中不大于 x 的随机变量的个数. 定义经验分布函数 $F_n(x)$ 为

落入区间 $(-\infty, x)$ 的样本的个数

$$F_n(x) = \frac{1}{n} S(x), \quad -\infty < x < \infty.$$

例: 设总体 F 具有一个样本值 1, 2, 3, 则经验分布函数 $F_3(x)$ 的观察值为

$$F_3(x) = \begin{cases} 0, & \text{若 } x < 1, \\ \frac{1}{3}, & \text{若 } 1 \leq x < 2, \\ \frac{2}{3}, & \text{若 } 2 \leq x < 3, \\ 1, & \text{若 } x \geq 3. \end{cases}$$

经验分布函数



经验分布函数 我们还可以作出与总体分布函数 $F(x)$ 相应的统计量——经验分布函数. 它的作法如下: 设 $X_1, X_2, \dots, X_n$ 是总体 F 的一个样本, 用 $S(x)$, $-\infty < x < \infty$ 表示 $X_1, X_2, \dots, X_n$ 中不大于 x 的随机变量的个数. 定义经验分布函数 $F_n(x)$ 为

$$F_n(x) = \frac{1}{n} S(x), \quad -\infty < x < \infty.$$



可以证明:

对于任一实数 x , 当 $n \rightarrow \infty$ 时 $F_n(x)$ 以概率 1 一致收敛于分布函数 $F(x)$, 即

$$P\left\{\lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0\right\} = 1.$$

因此, 对于任一实数 x 当 n 充分大时, 经验分布函数的任一个观察值 $F_n(x)$ 与总体分布函数 $F(x)$ 只有微小的差别, 从而在实际上可当作 $F(x)$ 来使用^①.

直方图，箱形图



见教材130-135页，请同学们自学



例题1: 设总体X的一组样本值为:

4.5, 2, 1, 1.5, 3.5, 4.5, 6.5, 5, 3.5, 4

求样本均值, 样本方差, 经验分布函数。

$$\text{解: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{10} (4.5 + 2 + 1 + 1.5 + 3.5 + 4.5 + 6.5 + 5 + 3.5 + 4) \\ = 3.6$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{9} \left((4.5-3.6)^2 + (2-3.6)^2 + (1-3.6)^2 + (1.5-3.6)^2 \right. \\ \left. + (3.5-3.6)^2 + (4.5-3.6)^2 + (6.5-3.6)^2 + (5-3.6)^2 \right. \\ \left. + (3.5-3.6)^2 + (4-3.6)^2 \right) \\ \approx 2.88$$

将样本值按从小到大排序:

$$1 < 1.5 < 2 < 3.5 = 3.5 < 4 < 4.5 = 4.5 < 5 < 6.5$$

$$F_{10}(x) = \begin{cases} 0 & x < 1 \\ \frac{1}{10} & 1 \leq x < 1.5 \\ \frac{2}{10} & 1.5 \leq x < 2 \\ \frac{3}{10} & 2 \leq x < 3.5 \\ \frac{5}{10} & 3.5 \leq x < 4 \\ \frac{6}{10} & 4 \leq x < 4.5 \\ \frac{8}{10} & 4.5 \leq x < 5 \\ \frac{9}{10} & 5 \leq x < 6.5 \\ 1 & x \geq 6.5 \end{cases}$$



$$E(S^2) = \sigma^2$$

例题2：设 $X_1, X_2, \dots, X_n$ 是来自正态分布总体 $N(\mu, \sigma^2)$ 的简单随机样本，记统计量 $T = \frac{1}{n} \sum_{i=1}^n X_i^2$ ，求 $E(T)$ 。

例题3：设 $X_1, X_2, \dots, X_n$ 是来自二项分布总体 $B(n, p)$ 的简单随机样本， $\bar{X}$ 和 S^2 为样本均值和样本方差，记统计量 $T = \bar{X} - S^2$ 。求 $E(T)$



例题2: 设 $X_1, X_2, \dots, X_n$ 是来自正态分布总体 $N(\mu, \sigma^2)$ 的简单随机样本, 记统计量 $T = \frac{1}{n} \sum_{i=1}^n X_i^2$, 求 $E(T)$ 。

$X_1, X_2, \dots, X_n$ 来自正态分布 $N(\mu, \sigma^2)$ 的简单随机样本.

$$T = \frac{1}{n} \sum_{i=1}^n X_i^2$$

求 $E(T)$.

$$\begin{aligned} \text{解: } E(T) &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) \\ &= \frac{1}{n} \sum_{i=1}^n [D(X_i) + (E(X_i))^2] \\ &= \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) \\ &= \sigma^2 + \mu^2. \end{aligned}$$



例题3：设 $X_1, X_2, \dots, X_n$ 是来自二项分布总体 $B(n, p)$ 的简单随机样本， $\bar{X}$ 和 S^2 为样本均值和样本方差，记统计量 $T = \bar{X} - S^2$ 。求 $E(T)$

$X_1, X_2, \dots, X_m$ 为来自二项分布总体 $B(n, p)$ 的简单随机样本.

$\bar{X}, S^2$ 为样本均值和样本方差.

$$T = \bar{X} - S^2.$$

求 $E(T)$.

$$\begin{aligned} \text{解: } E(T) &= E(\bar{X}) - E(S^2) \\ &= E(X) - D(X) \\ &= np - np(1-p) \\ &= np^2 \end{aligned}$$

本次课小调查2024

