



Chpt.6 Sampling and Distribution

第六章 样本及抽样分布

上节回顾



■ 概率论 vs 数理统计

概率论：理论，已知服从某种分布，研究性质与规律

数理统计：实践，不知分布或不知分布的参数，通过收集数据，分析数据做统计推断

简单随机抽样 无放回抽样不是简单随机抽样

■ 总体 X $\xrightarrow{\text{抽样}}$ 样本 $X_1, X_2, \dots, X_n$ ，独立同分布（与 X 同分布）
样本观测值 $x_1, x_2, \dots, x_n$

■ 统计量 $g(X_1, X_2, \dots, X_n)$

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$
 $\bar{X} \xrightarrow{P} E(X)$ $E(\bar{X}) = E(X)$ $D(\bar{X}) = \frac{1}{n} D(X)$

- 样本二阶中心矩 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
- 样本方差 $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$
 $S^2 \xrightarrow{P} D(X)$ $E(S^2) = D(X)$



$$E(S^2) = \sigma^2$$

例题4：设总体X的概率密度为 $f(x) = \frac{1}{2}e^{-|x|}$, $-\infty < x < \infty$, $X_1, X_2, \dots, X_n$ 为总体X的简单随机样本， S^2 为样本方差。求 $E(S^2)$ 。

例题5：求总体N(20,3)的容量分别为10, 15的两个独立样本均值差的绝对值大于0.3的概率。



例题4：设总体 X 的概率密度为 $f(x) = \frac{1}{2}e^{-|x|}$, $-\infty < x < \infty$, $X_1, X_2, \dots, X_n$ 为总体 X 的简单随机样本, S^2 为样本方差。求 $E(S^2)$ 。

$$X. f(x) = \frac{1}{2}e^{-|x|}, -\infty < x < \infty$$

$X_1, X_2, \dots, X_n$ 为总体 X 的简单随机样本, S^2 为样本方差。

求 $E(S^2)$ 。

$$\text{解: } ES^2 = DX = E(X^2) - E(X)^2$$

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx = \int_{-\infty}^{\infty} \frac{1}{2}xe^{-|x|} dx = 0$$

$$\begin{aligned} E(X^2) &= \int_{-\infty}^{\infty} x^2 f(x) dx = \int_{-\infty}^{\infty} x^2 \frac{1}{2}e^{-|x|} dx \\ &= \int_0^{\infty} x^2 e^{-x} dx \\ &= \int_0^{\infty} -x^2 d(e^{-x}) \\ &= -x^2 e^{-x} \Big|_0^{\infty} + \int_0^{\infty} 2xe^{-x} dx \\ &= \int_0^{\infty} -2x d(e^{-x}) \\ &= -2xe^{-x} \Big|_0^{\infty} + \int_0^{\infty} 2e^{-x} dx \\ &= -2e^{-x} \Big|_0^{\infty} \\ &= 2. \end{aligned}$$

$$ES^2 = 2 - 0 = 2.$$



例题5：求总体 $N(20,3)$ 的容量分别为10, 15的两个独立样本均值差的绝对值大于0.3的概率。

求总体 $N(20,3)$ 的容量分别为 10, 15 的两独立样本均值差的绝对值大于 0.3 的概率

解：设 $\bar{X}$ 是容量为 10 的样本均值， $\bar{X} \sim N(20, \frac{3}{10})$
 $\bar{Y}$ 是容量为 15 的样本均值， $\bar{Y} \sim N(20, \frac{3}{15})$

$\bar{X} - \bar{Y}$ 也是正态变量， $\bar{X} - \bar{Y} \sim N(0, \frac{1}{2})$

$$\begin{cases} E(\bar{X} - \bar{Y}) = E(\bar{X}) - E(\bar{Y}) = 0 \\ D(\bar{X} - \bar{Y}) = D(\bar{X}) + D(\bar{Y}) = D(\bar{X}) + D(\bar{Y}) = \frac{1}{2} \end{cases}$$

$$\begin{aligned} P(|\bar{X} - \bar{Y}| > 0.3) &= P\left(\left|\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{1}{2}}}\right| > 0.3 \times \sqrt{2}\right) \\ &= 1 - P\left(\left|\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{1}{2}}}\right| \leq 0.3 \times \sqrt{2}\right) \\ &= 1 - [2\Phi(0.3 \times \sqrt{2}) - 1] \\ &= 2 - 2\Phi(0.3 \times \sqrt{2}) \\ &\approx 2 - 2\Phi(0.4243) \\ &= 2 - 2 \times 0.6628 \\ &= 0.6744 \end{aligned}$$

6.3 抽样分布



样本是随机变量

统计量是样本的函数，从而统计量也是随机变量

统计量的分布称为**抽样分布**

为什么要研究抽样分布：

- 一般而言，总体分布已知，抽样分布也是知道的，但是确切得到是困难的；
- 从另外一个角度，我们希望由统计量（特别是在观测值得到后），去估计和推断总体的一些特征。



一.样本均值分布

假设总体 X 分布的均值与方差都是已知的，那么可以对来自总体的多个样本 $X_1, X_2, \dots, X_n$ 的均值 $\bar{X}$ 做出估计。

$$E(\bar{X}) = E(X)$$
$$D(\bar{X}) = \frac{1}{n}D(X)$$

假设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的独立样本，样本均值为

$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 由独立同分布的中心极限定理可知，

当 n 充分大时， $\bar{X} \overset{\text{近似地}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$ $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \overset{\text{近似地}}{\sim} N(0, 1)$

假设 $X_1, \dots, X_n$ 是来自**正态总体** $X \sim N(\mu, \sigma^2)$ 的独立样本，

则样本均值 $\bar{X}$ 服从正态分布 $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$

标准量服从标准正态分布 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$



例1：从正态分布总体 $N(3.4, 6^2)$ 中抽取容量为 n 的样本，如果要求其样本均值位于区间 $(1.4, 5.4)$ 内的概率不小于0.95，问样本容量 n 至少应取多大？

z	1.28	1.645	1.96	2.33
$\Phi(z)$	0.900	0.950	0.975	0.990

作答



z	1.28	1.645	1.96	2.33
$\Phi(z)$	0.900	0.950	0.975	0.990

例: 从正态总体 $N(3.4, 6^2)$ 中抽取 n 个样本,
要求样本均值 $\bar{X} \in (1.4, 5.4)$ 的概率 ≥ 0.95 ,
问样本容量 n 至少多大?

解. $X \sim N(3.4, 6^2)$
 $\bar{X} \sim N(3.4, \frac{6^2}{n})$

$$P(1.4 < \bar{X} < 5.4) = P\left(\left|\frac{\bar{X} - 3.4}{\sqrt{\frac{6^2}{n}}}\right| < \frac{\sqrt{n}}{3}\right) \\ = 2\Phi\left(\frac{\sqrt{n}}{3}\right) - 1 \geq 0.95$$

$$\Phi\left(\frac{\sqrt{n}}{3}\right) \geq 0.975$$

$$\frac{\sqrt{n}}{3} \geq 1.96.$$

$$n \geq (1.96 \times 3)^2 \approx 34.57$$

n 至少取 35.

二. χ^2 分布



[定理6.3] 设随机变量 $X_1, \dots, X_n$ 是来自标准正态总体

$X \sim N(0,1)$ 的独立样本。则随机变量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$


服从自由度为 n 的 χ^2 分布，记为 $\chi^2(n)$ ，其概率密度：

$$f_{\chi^2}(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

其中， $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$



$\chi^2(n)$ 分布的密度函数图像



Remark 1: χ^2 分布具有可加性，也就是说，

$\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$ 且它们相互独立，

则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$

Remark 2: $\chi^2 \sim \chi^2(n)$

为什么？

则 $E(\chi^2) = n$, $D(\chi^2) = 2n$

证明 $D(\chi^2(n)) = 2n$



- 设 $X \sim N(0,1)$, 若证明 $D(X^2) = 2$, 则可说明 $D(\chi^2(n)) = 2n$

用平方关系来算, $D(X^2) = E(X^4) - (E(X^2))^2$

先算 $E(X^4)$, 令 $f(x)$ 是 $N(0,1)$ 的密度函数

思考: 利用上述方法,
求 $E(X^k)$, $D(X^k)$

$$E(X^4) = \int_{-\infty}^{+\infty} x^4 f(x) dx = \int_{-\infty}^{+\infty} x^3 \cdot x f(x) dx$$

由 $f(x)$ 的式子可知: $f'(x) = f(x) \left(-\frac{x^2}{2} \right)' = -x f(x)$

$$\begin{aligned} E(X^4) &= \int_{-\infty}^{+\infty} -x^3 \cdot f'(x) dx = -x^3 \cdot f(x) \Big|_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} -3x^2 \cdot f(x) dx \\ &= 0 - \int_{-\infty}^{+\infty} -3x \cdot x f(x) dx = - \int_{-\infty}^{+\infty} 3x \cdot f'(x) dx \\ &= -3x \cdot f(x) \Big|_{-\infty}^{+\infty} + 3 \int_{-\infty}^{+\infty} f(x) dx = 3 \end{aligned}$$

$$E(X^2) = D(X) + E^2(X) = 1 + 0 = 1 \text{ 所以 } (E(X^2))^2 = 1$$

$$\text{则 } D(X^2) = E(X^4) - (E(X^2))^2 = 3 - 1 = 2$$



例2：设 $X_1, X_2, \dots, X_{10}$ 是来自标准正态分布的一组简单随机样本，

$$Y = \frac{1}{2} \sum_{i=1}^{10} X_i^2 + \sum_{i=1}^5 X_{2i-1} X_{2i}$$

则Y服从_____分布，参数是_____。

作答



例题2 $X_1, X_2, \dots, X_{10}$ 是来自标准正态分布总体的样本

$$Y = \frac{1}{2} \sum_{i=1}^{10} X_i^2 + \sum_{i=1}^5 X_{2i-1} X_{2i}$$

则 $EY = \underline{\hspace{1cm}}$, Y 服从 $\underline{\hspace{1cm}}$ 分布, 参数为 $\underline{\hspace{1cm}}$.

解: $E(X_i) = 0$

$$E(X_i^2) = D(X_i) + E^2(X_i) = 1 + 0 = 1.$$

$$E(Y) = 5.$$

$$Y = \frac{1}{2} \left(\sum_{i=1}^{10} X_i^2 + 2 \sum_{i=1}^5 X_{2i-1} X_{2i} \right)$$

$$= \frac{1}{2} \sum_{i=1}^5 (X_{2i-1} + X_{2i})^2$$

$$= \sum_{i=1}^5 \left(\frac{X_{2i-1} + X_{2i}}{\sqrt{2}} \right)^2$$

$$\therefore \frac{X_{2i-1} + X_{2i}}{\sqrt{2}} \sim N(0, 1)$$


$$\therefore Y \sim \chi^2(5).$$

上 α 分位点



[定义] 随机变量 X , 对一个正数 α ($0 < \alpha < 1$), 若能找到数 x_α 满足 $P\{X > x_\alpha\} = \alpha$, 则称 x_α 为 X 的**上 α 分位点**.

标准正态分布的上 α 分位点定义




一般用 z_α 表示标准正态分布的上 α 分位点

对于实数 $\alpha(0 < \alpha < 1)$, 称满足下式

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{\infty} f(x)dx = \alpha$$

的数 $\chi_\alpha^2(n)$ 为 χ^2 分布的上 α 分位点。



- 对于 $n \leq 40$, $\chi^2(n)$ 分布的上 α 分位点的值可参考教材的附表5
- 对于 $n > 40$, $\chi^2(n)$ 分布的上 α 分位点可以利用下面的近似关系求解

$$\chi_\alpha^2(n) \approx \frac{1}{2}(z_\alpha + \sqrt{2n-1})^2$$

其中 z_α 是标准正态分布的上 α 分位点



假设正态分布 $X \sim N(\mu, \sigma^2)$, n 个样本 $X_1, \dots, X_n$, 则

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

(注意: χ^2 分布要求 $X \sim N(0,1)$)

□ μ 已知, 可估计 σ ; 或 σ 已知, 可估计 μ 。

□ 当均值 μ 与方差 σ 都未知时, 该如何估计?

考虑用 $(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2$ 来代替 $\sum_{i=1}^n (X_i - \mu)^2$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

[定理6.4] S^2 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的 n 个样本的方

差，那么：
$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\Leftrightarrow \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$$

证明见教材第145-146页



三. T分布


[定义] 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布. 记为 $t \sim t(n)$.

t 分布又称学生氏 (Student) 分布. $t(n)$ 分布的概率密度函数为

$$h(t) = \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty$$



Remark :

- t 分布的密度曲线关于 $t = 0$ 对称;
- n 充分大时, 近似于标准正态分布。

$$\lim_{n \rightarrow \infty} h(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$$

三. T分布的上 α 分位点


对于给定的 α ($0 < \alpha < 1$), 满足条件

$$P\{t > t_{\alpha}(n)\} = \int_{t_{\alpha}(n)}^{\infty} f_t(t) dt = \alpha$$

的 $t_{\alpha}(n)$ 值称为**t分布的上 α 分位点**。

由 $f_t(t)$ 的对称性知:

$$t_{1-\alpha}(n) = -t_{\alpha}(n)$$



t 分布的上 α 分位点可自附表 4 查得. 在 $n > 45$ 时, 对于常用的 α 的值, 就用正态近似 $t_{\alpha}(n) \approx z_{\alpha}$.

三. T分布（中心极限定理 VS T分布）

当总体均值与方差已知 $E(X) = \mu, D(X) = \sigma^2$, $\{X_i\}$

是来自总体的独立样本，我们知道 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ 近似为标

准正态分布 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \rightarrow N(0,1)$

如果X是正态分布，那就可以确切得到 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$

□ 已知 σ ，可以估计 μ ；反过来，已知 μ ，可以估计 σ

□ 那如果 μ 和 σ 都未知，该如何估计？

考虑用样本标准差S来代替 σ

三. T分布



[定理6.1] 若总体服从正态分布 $X \sim N(\mu, \sigma^2)$, $\{X_i\}, S$

分别是来自总体的样本与样本标准差, $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$

那么随机变量 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 服从自由度为 $n-1$ 的 t 分布 $t \sim t(n-1)$

其概率密度为:

$$f_t(t) = \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)\sqrt{(n-1)\pi}} \left(1 + \frac{t^2}{n-1}\right)^{-\frac{n}{2}}, \quad -\infty < t < +\infty$$

Remark1: 其中伽玛函数 $\Gamma(\alpha) = \int_0^{\infty} u^{\alpha-1} e^{-u} du \quad (\alpha > 0)$,

有如下性质:

$$(1) \quad \Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$$

$$(2) \quad \Gamma(n) = (n-1)!$$

$$(3) \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Remark2: 由定理可以知道总体为正态分布 $X \sim N(\mu, \sigma^2)$,

随机变量 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 服从自由度为 $n-1$ 的 t 分布。

$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 中如果 μ 和 σ 未知, 由对 t 的分析可以估计出 μ ,

从而估计 σ 。



例题3：设X和Y相互独立，都服从正态分布 $N(0,9)$ ，而 $X_1, X_2, \dots, X_9$ 和 $Y_1, Y_2, \dots, Y_9$ 分别是来自总体X和Y的简单随机样本，则统计量

$$U = \frac{X_1 + X_2 + \dots + X_9}{\sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}}$$

服从什么分布，参数为多少？

作答



例题3 X, Y 相互独立, 服从 $N(0, 9)$,
 $X_1, X_2, \dots, X_9, Y_1, \dots, Y_9$ 分别是来自总体 X, Y
的样本. 统计量

$$D = \frac{X_1 + X_2 + \dots + X_9}{\sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}}$$

服从 _____ 分布, 参数为 _____.

解: $X_i \sim N(0, 9)$

$$\Rightarrow X_1 + \dots + X_9 \sim N(0, 9 \times 9)$$

$$\Rightarrow \frac{X_1 + \dots + X_9}{9} \sim N(0, 1)$$

$$Y_i \sim N(0, 9)$$

$$\Rightarrow \frac{Y_i}{3} \sim N(0, 1)$$

$$\Rightarrow \frac{Y_1^2 + \dots + Y_9^2}{9} \sim \chi^2(9)$$

$$\begin{aligned} \therefore D &= \frac{X_1 + \dots + X_9}{\sqrt{Y_1^2 + \dots + Y_9^2}} \\ &= \frac{\frac{X_1 + \dots + X_9}{9}}{\sqrt{\frac{Y_1^2 + \dots + Y_9^2}{9}}} \sim t(9) \end{aligned}$$

即 D 服从 t 分布, 参数为 9.

四. F分布




[定义] 若随机变量 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, U 与 V 独立, 则随机变量 $F = \frac{U/n_1}{V/n_2}$ 服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$ 。

其概率密度为

$$f_F(z) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} n_1^{\frac{n_1}{2}} n_2^{\frac{n_2}{2}} \frac{z^{\frac{n_1}{2}-1}}{(n_1 z + n_2)^{\frac{n_1+n_2}{2}}} & z > 0 \\ 0 & z \leq 0 \end{cases}$$

四. F分布

$F \sim F(n_1, n_2)$ n_1 为第一自由度； n_2 为第二自由度。



Remark 1: 如果 $X \sim F(m, n)$, 则 $\frac{1}{X} \sim F(n, m)$ 。


四. F分布

F分布的分位点 对于给定的 $\alpha, 0 < \alpha < 1$, 称满足条件

$$P\{F > F_{\alpha}(n_1, n_2)\} = \int_{F_{\alpha}(n_1, n_2)}^{\infty} \psi(y) dy = \alpha$$

称 $F_{\alpha}(n_1, n_2)$ 为F分布的上 α 分位点。

注：F分布的上 α 分位点可以查附录6



Remark 2:

$$F_{\alpha}(n_1, n_2) = \frac{1}{F_{1-\alpha}(n_2, n_1)}.$$

思考题：如何证明？



思考题：设在总体 $X \sim N(\mu, \sigma^2)$ 中抽样一容量为**16**的样本，这里 μ, σ^2 均为未知。

(1) 求概率 $P\left\{\frac{S^2}{\sigma^2} \leq 2.041\right\}$, 其中 S^2 为样本方差; (2) 求 $D(S^2)$