


统计推断的过程



参数估计

现在我们来介绍一类重要的统计推断问题：

参数估计问题是利用**从总体抽样得到的信息**来**估计总体的某些参数或者参数的某些函数**。

第七章、参数估计

第一节：点估计

取某值的概率

第三节：估计量的评选标准

第四节：区间估计

在某范围取值的概率


第五节：正太总体均值与方差的区间估计

第六节：(0-1)分布参数的区间估计

第七节：单侧置信区间

最常用的一种抽样叫作“简单随机抽样”，其特点：

1. 代表性： $X_1, X_2, \dots, X_n$ 中每一个与所考察的总体有相同的分布.
2. 独立性： $X_1, X_2, \dots, X_n$ 是相互独立的随机变量.



若总体的分布函数为 $F(x)$ 、概率密度函数为 $f(x)$,则其简单随机样本的联合分布函数为

$$F^*(x, x_2, \dots, x_n) = F(x_1) F(x_2) \dots F(x_n)$$

其简单随机样本的联合概率密度函数为

$$f^*(x, x_2, \dots, x_n) = f(x_1) f(x_2) \dots f(x_n)$$

简单随机样本是应用中最常见的情形，今后，当说到“ $X_1, X_2, \dots, X_n$ 是取自某总体的样本”时，若不特别说明，就指简单随机样本。

分组讨论



问题：

大数定律和中心极限定理（第五章）在估计（第七章）中的作用？

1, 大数定律的概念

概率论中用来阐明大量随机现象**平均结果的稳定性**的一系列定理，称为大数定律（law of large number）

三个大数定律：

- (1) 切比雪夫大数定律、
- (2) 辛钦大数定律
- (3) 伯努利大数定律

它们之间既有区别也有联系。

大数定律

伯努利
大数定律

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| < \varepsilon\right\} = 1$$

$$n_A \sim b(n, p)$$

切比雪夫
大数定律

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right\} = 1$$

$$\begin{cases} E(X_k) = \mu \\ D(X_k) = \sigma^2 \end{cases}$$

辛钦
大数定律

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right\} = 1$$

$$E(X_k) = \mu$$

大数定律以严格的数学形式表达了随机现象最根本的性质之一：**平均结果的稳定性**

抽样推断中的理论依据

1、大数定律（切比雪夫大数定律）

设 $X_1, X_2, \dots, X_n$ 是一列**两两相互独立的**随机变量, 服从**同一分布**, 且存在**有限的数学期望 μ 和方差 σ^2** , 则对于任意小的正数 $\varepsilon > 0$, 有:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\sum X}{n} - \mu\right| < \varepsilon\right) = 1$$

对于抽样推断: 随着样本容量 n 的增加, 样本平均数将接近于总体平均数。

请注意：

若总体 X 的 k 阶矩 $E(X^k) = \mu^k$ 存在，则当 $n \rightarrow \infty$ 时，

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{p} \mu^k \quad k = 1, 2, \dots.$$

事实上 由 $X_1, X_2, \dots, X_n$ 独立且与 X 同分布，
有 $X_1^k, X_2^k, \dots, X_n^k$ 独立且与 X^k 同分布， $E(X_i^k) = \mu^k$
 $k = 1, 2, \dots, n$ 再由辛钦大数定律可得上述结论。

再由依概率收敛性质知，可将上述性质推广为

$$g(A_1, A_2, \dots, A_k) \xrightarrow{p} g(\mu_1, \mu_2, \dots, \mu_k)$$

其中 g 为连续函数。


这就是矩估计法的理论根据。

- 2、中心极限定理：设从均值为 μ ，方差为 σ^2 的一个任意总体中抽取容量为 n 的样本，当 n 充分大时，样本均值的抽样分布近似服从均值为 μ 、方差为 σ^2/n 的正态分布。

在一定条件下，大量独立随机变量的平均数是以正态分布为极限的。


中心极限定理

中心极限定理： 设从均值为 μ ，方差为 σ^2 的一个任意总体中抽取容量为 n 的样本，当 n 充分大时，样本均值的抽样分布近似服从均值为 μ 、方差为 σ^2/n 的正态分布




中心极限定理

$\bar{X}$ 的分布趋于正态分布的过程



抽样分布与总体分布的关系



在参数估计问题中，假定总体分布形式已知，未知的仅仅是一个或几个参数.

参数估计 { 点估计
区间估计

第一节 点估计

一、点估计问题的提法

二、估计量的求法

三、估计量的评选标准

想象中掀起刘海



实际上



想象与现实的不同！

点估计问题

想象：未知参数----给出估计值

事实：先构造一个**统计量**，作为**估计量**

再用它的**观察值**估计**未知参数**

很
不
同
！

一、点估计问题的提法

设总体 X 的分布函数 $F(x; \theta)$ 形式已知, θ 是待估参数, $X_1, X_2, \dots, X_n$ 是 X 的一个样本, $x_1, x_2, \dots, x_n$ 是相应的一个样本值.

点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 θ .

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的估计量. } 通称估计,
 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计值. } 简记为 $\hat{\theta}$.

二、估计量的求法

由于估计量是样本的函数, 是随机变量, 故对不同的样本值, 得到的参数值往往不同, 求估计量的问题是关键问题.

估计量的求法: (两种)

矩估计法

最大似然估计法.

1. 矩估计法

它是基于一种简单的“**替换**”思想建立起来的一种估计方法.是英国统计学家**K.皮尔逊**最早提出的.其基本思想是**用样本矩估计总体矩**.

理论依据： 大数定律

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E(X) = \mu$$

设总体 X 的分布函数为 $F(x; \theta_1, \theta_2, \dots, \theta_r)$

其中 $\theta_1, \theta_2, \dots, \theta_r$ 为未知参数，现在从总体 X 中抽取样本 $(X_1, X_2, \dots, X_n)$. 由**辛钦大数定律**

则对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - EX \right| \geq \varepsilon \right\} = 0.$$

可以推广为，则对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i^k - EX^k \right| \geq \varepsilon \right\} = 0.$$

设 $X_1, X_2, \dots, X_n$ 来自总体 X 的样本

记总体 k 阶矩为 $\alpha_k = E(X^k)$

样本 k 阶矩为 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

记总体 k 阶中心矩为 $\mu_k = E[X - E(X)]^k$

样本 k 阶中心矩为 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

用样本矩来估计总体矩, 用样本矩的连续函数来估计总体矩的连续函数, 从而得出参数估计, 这种估计法称为矩估计法.

矩估计法的具体步骤:

(1) 求出 $\alpha_l = E(X^l) = \alpha(\theta_1, \theta_2, \dots, \theta_k) \quad l = 1, 2, \dots, k$

(2) 令 $\alpha_l = A_l, \quad A_l = \frac{1}{n} \sum_{i=1}^n X_i^l; l = 1, 2, \dots, k$

这是一个包含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组.

(3) 解出其中 $\theta_1, \theta_2, \dots, \theta_k$, 用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 表示.

(4) 用方程组的解 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量, 这种估计量称为矩估计量. 矩估计量的观察值称为矩估计值.

例 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a , b 未知, $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, 求 a , b 的矩估计量.

解

$$\alpha_1 = E(X) = \frac{a+b}{2}, \quad \alpha_2 = E(X^2) = D(X) + [E(X)]^2 = \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4},$$

$$\text{令 } \frac{a+b}{2} = A_1 = \frac{1}{n} \sum_{i=1}^n X_i, \quad \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4} = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2,$$

$$\text{即 } \begin{cases} a+b = 2A_1 \\ b-a = \sqrt{12(A_2 - A_1^2)} \end{cases}$$

解方程组得到 a , b 的矩估计量分别为

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

例3 设总体 X 的均值 μ 和方差 σ^2 都存在, 且有 $\sigma^2 > 0$, 但 μ 和 σ^2 均为未知, 又设 $X_1, X_2, \dots, X_n$ 是一个样本, 求 μ 和 σ^2 的矩估计量.

解

$$\alpha_1 = E(X) = \mu,$$

$$\alpha_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$

$$\text{令} \begin{cases} \mu = A_1 \\ \sigma^2 + \mu^2 = A_2 \end{cases}$$

解方程组得到矩估计量分别为 $\hat{\mu} = A_1 = \bar{X}$,


$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

上例表明:

总体均值与方差的矩估计量的表达式, 不因不同的总体分布而异.

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 即得 μ, σ^2 的矩估计量

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$



总结1:

样本一定，矩估计量是唯一的吗？

设总体X服从参数为

$$\lambda$$

的泊松 (Poisson) 分布,由于

$$\lambda = E(X) = D(X)$$

故由矩估计法知:

$$\hat{\lambda}_1 = \bar{X} \quad , \quad \hat{\lambda}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

都为参数

$$\lambda$$

的矩估计量.

矩法的优点是简单易行。缺点是，当总体类型已知时，没有充分利用分布提供的信息。一般场合下，矩估计量不具有唯一性。

哪个好？——第三节

总结2:

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

$\hat{\mu}, \hat{\sigma}^2$: 由样本对未知参数作的估计?

是一个统计量?

有随机性, 跟样本有关?



总结3:

未知常数

不等于
等于

随机变量

一般，不论总体服从什么分布，**总体期望**与**方差**存在，则它们的矩估计量分别为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

2. 最大（极大）似然估计法

最大似然法是在总体类型已知条件下使用的一种参数估计方法。

- ⌘ 极大似然估计法(maximum likelihood estimation, 简记MLE)是费歇尔在1912年提出的一种**参数估计方法**
- ⌘ 其思想始于高斯的误差理论，
- ⌘ 它具有很多优良的性质，如它充分利用总体分布函数的信息，**克服**了矩法的**某些不足**，具有无偏性和有效性等。

□ 极大似然估计法

思想方法：一次试验就出现的事件有较大的概率

例如：有两外形相同的箱子,各装100个球

一箱	99个白球	1个红球
一箱	1个白球	99个红球

现从两箱中任取一箱, 并从箱中任取一球, 结果所取得的球是白球.

问：所取的球来自哪一箱？ 答：第一箱.

最(极)大似然估计法的基本思想

- ⌘ 在没有其它信息的情况下, 我们只能认为在一次随机实验中发生的事件具有最大的概率。反过来, 如果能够使事件发生的概率最大化, 该事件也就最有可能发生, 因此寻找使概率极大化的参数就是很自然的想法了, 极大似然法就是基于这样的想法.
- ⌘ 即: 如果随机试验的结果得到样本观测值 $x_1, x_2, \dots, x_n$, 则就当这样选取 θ 的值, 使这组观测值出现的可能性最大, 也就是使似然函数 $L(\theta)$ 达到极大值, 从而求得参数 θ 的估计值 θ .

极大似然估计法:

当给定样本 $X_1, X_2, \dots, X_n$ 时, 定义似然函数为:

$$\begin{aligned} L(\theta) &= L(\theta; x_1, \dots, x_n) \\ &= P(X_1 = x_1; \theta) P(X_2 = x_2; \theta) \cdots P(X_n = x_n; \theta) \end{aligned}$$

$$\begin{aligned} L(\theta) &= L(\theta; x_1, \dots, x_n) \\ &= f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) \end{aligned}$$

这里 $x_1, x_2, \dots, x_n$ 是样本的观察值.

$L(\theta)$ 看作参数 θ 的函数, 它可作为 θ 将以多大可能产生样本值 $x_1, x_2, \dots, x_n$ 的一种度量.

选择 θ , 使 $L(\theta)$ 达到最大值.

似然函数

若总体 X 属离散型, 其分布律为 $P\{X=x\}=p(x;\theta)$,

$\theta \in \Theta$ 形式已知, θ 为待估参数, $(X_1, X_2, \dots, X_n)$

是总体 X 的一个样本, 则样本 $X_1, X_2, \dots, X_n$ 的

分布律为 $\prod_{i=1}^n p(x_i; \theta)$, 当给定样本值 $(x_1, x_2, \dots, x_n)$

后, 则样本 $X_1, X_2, \dots, X_n$ 取到观察值 $x_1, x_2, \dots, x_n$

的概率为 $L(\theta) = \prod_{i=1}^n p(x_i; \theta)$, $\theta \in \Theta$

它是 θ 的函数, 称 $L(\theta)$ 为样本的似然函数.

若总体 X 属连续型, 其概率密度函数为 $f(x; \theta)$,

$\theta \in \Theta$ 形式已知, θ 为待估参数, $(X_1, X_2, \dots, X_n)$ 是总体 X 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的联合密度为 $\prod_{i=1}^n f(x_i; \theta)$, 设 $x_1, x_2, \dots, x_n$ 是相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值, 则 $(X_1, X_2, \dots, X_n)$ 落在点 $(x_1, x_2, \dots, x_n)$ 的邻域内的概率近似为

$$\prod_{i=1}^n f(x_i; \theta) dx_i, \quad \theta \in \Theta$$

因 $\prod_{i=1}^n dx_i$ 不随 θ 而变, 故只需考虑 $\prod_{i=1}^n f(x_i; \theta)$

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$

则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的**最大似然估计值**.

若将上式中样本值 $(x_1, x_2, \dots, x_n)$ 替换成样本 $(X_1, X_2, \dots, X_n)$, 则得 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 称为参数 θ 的**最大似然估计量**.

由于 $L(\theta)$ 与 $\ln L(\theta)$ 在**同一 θ 处达到最大值**,

因此, $\hat{\theta}$ 为最大似然估计的必要条件为

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

称为似然方程

求最大似然估计量的一般步骤为：

(1) 求似然函数 $L(\theta)$

(2) 一般地，求出 $\ln L(\theta)$ 及似然方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

(3) 解似然方程得到最大似然估计值

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$$

(4) 最后得到最大似然估计量

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$$

例 设 $X \sim B(1, p)$, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 求 p 的最大似然估计量.

解

例

设 $X \sim B(1, p)$, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 求 p 的最大似然估计量.

解

设 $x_1, x_2, \dots, x_n$ 为相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值 ,

X 的分布律为 $P\{X = x\} = p^x (1-p)^{1-x}, x = 0, 1$

似然函数
$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i},$$

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

令
$$\frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0, \quad \text{解得 } p \text{ 的最大似然估计值 } \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

p 的最大似然估计量为
$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.

例

设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数,
 $x_1, x_2, \dots, x_n$ 是来自 X 的一个样本值, 求 μ 和 σ^2
的最大似然估计量.

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

例 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数,
 $x_1, x_2, \dots, x_n$ 是来自 X 的一个样本值, 求 μ 和 σ^2
 的最大似然估计量.

解 X 的概率密度为 $p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$,


X 的似然函数为 $L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$,

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2, \quad \text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0 \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases} \quad \longrightarrow \quad \begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \end{cases}$$

故 μ 和 σ^2 的最大似然估计量分别为
 它们与相应的矩估计量相同.

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$



说明：用求导方法求参数的最大似然估计有时行不通，这时要用极大似然原则来求。

小结

两种求点估计的方法: $\left\{ \begin{array}{l} \text{矩估计法} \\ \text{最大似然估计法} \end{array} \right.$

在统计问题中往往先使用最大似然估计法, 在最大似然估计法使用不方便时, 再用矩估计法.

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

第三节 估计量的评价标准

一、无偏性

二、有效性

三、相合性

问题的提出

从前一节可以看到, 对于同一个参数, 用不同的估计方法求出的估计量可能不相同, 那么那一个估计量好? 好坏的标准是什么?

下面介绍几个常用标准.

一、无偏性（无偏估计）

若 $X_1, X_2, \dots, X_n$ 为总体 X 的一个样本，
 $\theta \in \Theta$ 是包含在总体 X 的分布中的待估参数，
(Θ 是 θ 的取值范围)

若估计量 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在, 且对于任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是 θ 的无偏估计量.

无偏性是对估计量的一个常见而重要的要求.

无偏估计的实际意义：无系统误差.

例1 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$) 存在, 又设 $X_1, X_2, \dots, X_n$ 是 X 的一个样本, 试证明不论总体服从什么分布, k 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计.

例1 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$) 存在, 又设 $X_1, X_2, \dots, X_n$ 是 X 的一个样本, 试证明不论总体服从什么分布, k 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计.

证 因为 $X_1, X_2, \dots, X_n$ 与 X 同分布, 故有 $E(X_i^k) = E(X^k) = \mu_k, \quad i = 1, 2, \dots, n.$

$$\text{即 } E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k.$$

故 k 阶样本矩 A_k 是 k 阶总体矩 μ_k 的无偏估计.

特别地:

不论总体 X 服从什么分布,

只要它的数学期望存在,

$\bar{X}$ 总是总体 X 的数学期望 $\mu_1 = E(X)$ 的无偏估计量.



同一个参数可以有不同的无偏估计量吗？

例 设总体 X 服从参数为 $1/\theta$ 的指数分布, 概率密

$$\text{度 } p(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其它} \end{cases}, \text{其中参数 } \theta > 0, \text{又设}$$

$X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 $\bar{X}$ 和 $nX_{(1)} = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计.

设总体 X 服从参数为 $1/\theta$ 的指数分布, 概率密

$$\text{度 } p(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其它} \end{cases} \text{ 其中参数 } \theta > 0, \text{ 又设}$$

$X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 $\bar{X}$ 和 $nX_{(1)} = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计.

$$\text{故知 } E(X_{(1)}) = \frac{\theta}{n}, \quad E(nX_{(1)}) = \theta,$$

证 因为 $E(\bar{X}) = E(X) = \theta$,

所以 $\bar{X}$ 是 θ 的无偏估计量.

所以 $nX_{(1)}$ 也是 θ 的无偏估计量.

而 $X_{(1)} = \min(X_1, X_2, \dots, X_n)$ 具有概率密度

$$p_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0 \\ 0, & \text{其它} \end{cases}$$

同一个参数可以有不同的无偏估计量.

无偏性虽然是评价估计量的一个重要标准，而且在许多场合是合理的、必要的。然而，有时一个参数的无偏估计可能不存在或者不合理。

于是，人们又在无偏性的基础上增加了对方差的要求。若估计量的方差越小。表明该估计量的取值（即估计值）围绕着待估参数的波动就越小，也就是更为理想的估计量。为此，引入最小方差无偏计。

二、有效性（最小方差无偏估计）

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 与 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计量，若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ ，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

由于方差是随机变量取值与其数学期望的偏离程度，所以无偏估计以方差小者为好。

设总体 X 服从参数为 $1/\theta$ 的指数分布, 概率密

$$\text{度 } p(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其它} \end{cases} \text{ 其中参数 } \theta > 0, \text{ 又设}$$

$X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 $\bar{X}$ 和 $nX_{(1)} = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计.

$$\text{故知 } E(X_{(1)}) = \frac{\theta}{n}, \quad E(nX_{(1)}) = \theta,$$

证 因为 $E(\bar{X}) = E(X) = \theta$,

所以 $\bar{X}$ 是 θ 的无偏估计量.

所以 $nX_{(1)}$ 也是 θ 的无偏估计量.

而 $X_{(1)} = \min(X_1, X_2, \dots, X_n)$ 具有概率密度

$$f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0 \\ 0, & \text{其它} \end{cases}$$

试证当 $n > 1$ 时, θ 的无偏估计量 $\bar{X}$ 较 $nX_{(1)}$ 有效.

例 (续)

试证当 $n > 1$ 时, θ 的无偏估计量 $\bar{X}$ 较 $nX_{(1)}$ 有效.

证明 由于 $D(X) = \theta^2$, 故有 $D(\bar{X}) = \frac{\theta^2}{n}$,

又因为 $D(X_{(1)}) = \frac{\theta^2}{n^2}$, 故有 $D(nX_{(1)}) = \theta^2$,

当 $n > 1$ 时, $D(nX_{(1)}) > D(\bar{X})$,

故 θ 的无偏估计量 $\bar{X}$ 较 $nX_{(1)}$ 有效.

定义

如果存在 θ 的一个无偏估计量 $\hat{\theta}_0$, 使得对于 θ 的任意无偏估计量 $\hat{\theta}$, 都有

$$D(\hat{\theta}_0) \leq D(\hat{\theta})$$

则称 $\hat{\theta}_0$ 是 θ 的最小方差无偏估计 (量), 缩写为 *MVUE*.

说明 最小方差无偏估计是一种最优估计.

三、相合性（相合估计）

有时候我们不仅要求估计量有较小的方差，还希望当样本容量 n 充分大时，估计量能在某种意义下收敛于被估计参数，这就是所谓相合性（或一致性）概念。

定义 设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 是未知参数 θ 估计序列，如果 $\hat{\theta}_n$ 依概率收敛于 θ ，即对任 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| < \varepsilon\} = 1$$

或
$$\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} = 0$$

则 $\hat{\theta}_n$ 称是 θ 的相合估计量（或一致估计）。

定理 设 $\hat{\theta}_n$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad \text{且} \quad \lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计 (或一致估计)。

证明: 由于 $0 \leq P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} \leq \frac{1}{\varepsilon^2} E(\hat{\theta}_n - \theta)^2$

$$= \frac{1}{\varepsilon^2} E[\hat{\theta}_n - E(\hat{\theta}_n) + E(\hat{\theta}_n) - \theta]^2$$
$$= \frac{1}{\varepsilon^2} [D(\hat{\theta}_n) + (E(\hat{\theta}_n) - \theta)^2]$$

令 $n \rightarrow \infty$ 且由定理的假设, 得 $\lim_{n \rightarrow \infty} P\left\{|\hat{\theta}_n - \theta| \geq \varepsilon\right\} = 0$

即 $\hat{\theta}_n$ 是 θ 的相合估计

证明： 为描述方便，换做随机变量 X 表示。 $f(x)$ 是变量 X 的密度函数

$$\begin{aligned} 0 \leq P \{ |X - \theta| \geq \varepsilon \} &= \int_{\{ |x - \theta| \geq \varepsilon \}} f(x) dx \\ &\leq \int_{\{ |x - \theta| \geq \varepsilon \}} \frac{(X - \theta)^2}{\varepsilon^2} f(x) dx \\ &\leq \int_{-\infty}^{+\infty} \frac{(X - \theta)^2}{\varepsilon^2} f(x) dx \\ &= \frac{1}{\varepsilon^2} E(X - \theta)^2 \end{aligned}$$

小结

估计量的评选的三个标准 { 无偏估计
最小方差无偏估计
相合估计

相合性是对估计量的一个基本要求, 不具备相合性的估计量是不予以考虑的.

由最大似然估计法得到的估计量, 在一定条件下也具有相合性. 估计量的相合性只有当样本容量相当大时, 才能显示出优越性, 这在实际中往往难以做到, 因此, 在工程中往往使用无偏性和有效性这两个标准.