

在前面的课程中，我们讨论了随机变量及其分布，如果知道了随机变量 X 的概率分布，那么 X 的全部概率特征也就知道了。

然而，在实际问题中，概率分布一般是较难确定的。而在一些实际应用中，人们并不需要知道随机变量的一切概率性质，只要知道它的某些数字特征就够了。

1, 期望是数还是变量?

2, 随机变量都有期望吗?

3, 核酸检测



搜狐号@博教师国际教育

例如：

判断棉花质量时, 既看纤维的**平均长度**, 又要看 **纤维长度与平均长度的偏离程度**, 平均长度越长, 偏离程度越小, 质量就越好;



考察天津市居民的家庭收入情况, 我们既想知道家庭的年**平均**收入, 又要研究贫富之间的差异程度;



考察一射手的水平, 既要看他**的平均环数**是否高, 还要看他弹着点的范围是否小, 即**数据的波动**是否小.



由上面例子看到, 与随机变量有关的某些数值, 虽不能完整地描述随机变量但能清晰地描述随机变量在某些方面的重要特征, 这些数字特征在理论和实践上都具有重要意义.

因此，在对随机变量的研究中，确定某些数字特征是重要的。而所谓的数字特征就是用数字表示随机变量的分布特点。

在这些数字特征中，最常用的是

数学期望、方差、协方差和相关系数

随机变量某一方面的概率特性 都可用**数字**来描写

本章内容

- 随机变量的平均取值——**数学期望**
- 随机变量取值平均偏离均值的情况——**方差**
- 描述两随机变量间的某种关系的数——**协方差与相关系数**

第一节

数学期望

- 离散型随机变量的数学期望
- 连续型随机变量的数学期望
- 随机变量函数的数学期望
- 数学期望的性质
- 小结

一、离散型随机变量的数学期望

引例1: 某7人的数学成绩为90, 85, 85, 80, 80, 75, 60, 则他们的平均成绩为

$$\begin{aligned} & \frac{90 + 85 \times 2 + 80 \times 2 + 75 + 60}{7} \\ &= 90 \times \frac{1}{7} + 85 \times \frac{2}{7} + 80 \times \frac{2}{7} + 75 \times \frac{1}{7} + 60 \times \frac{1}{7} \\ &\approx 79.3 \end{aligned}$$

以频率为权重的加权平均

数学期望(Expectation)的定义

定义 2.2.1 设离散型随机变量 X 的分布律是

$$p_i = P(X = x_i), i = 1, 2, \dots, n, \dots$$

如果 $\sum_{i=1}^{+\infty} x_i p_i$ 绝对收敛, 则称随机变量的数学期望存

在, 并称 $\sum_{i=1}^{+\infty} x_i p_i$ 为随机变量 X 的**数学期望**, 简称**期望**

或**均值**, 记作 $E(X)$. 即

$$E(X) = \sum_{i=1}^{+\infty} x_i p_i$$

说明:

(1) 随机变量 X 的数学期望 $E(X)$ 是一个**常量**, 它是从概率的角度来计算随机变量 X 所有可能取值的平均值, 具有重要的统计意义.

(2) 级数的**绝对收敛性**保证了级数的和不随级数各项次序的改变而改变.

定义2.2.2 设连续型随机变量 X 的概率密度为 $f(x)$,
若积分

$$\int_{-\infty}^{\infty} xf(x)dx$$

绝对收敛,则称 $\int_{-\infty}^{\infty} xf(x)dx$ 的值为 X 的**数学期望**,记为 $E(X)$,即有

$$E(X) = \int_{-\infty}^{\infty} xf(x)dx$$

数学期望简称为**期望**,又称为**均值**.

例2 设随机变量 X 服从参数为 p 的0-1分布，试求 X 的数学期望.

解 由题意知 X 的分布律为

X	0	1
P	$1-p$	p

故

$$E(X) = 0 \times (1-p) + 1 \times p = p$$



例3 设 X 服从参数为 λ 的泊松分布,求 X 的数学期望.

例3 设 X 服从参数为 λ 的泊松分布,求 X 的数学期望.

解 由于 X 的分布律为

故

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k = 0, 1, 2, \dots$$

$$E(X) = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

$$\left(\because e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} = \sum_{k=1}^{\infty} \frac{x^{k-1}}{(k-1)!} \right)$$

例4 设 $X \sim U[a, b]$, 求 $E(X)$

解 由于 X 的概率密度为

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{else} \end{cases}$$

故

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} xf(x)dx = \int_a^b \frac{x}{b-a} dx \\ &= \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{a+b}{2} \end{aligned}$$




例5 设随机变量 X 服从参数为 $1/\lambda$ 的指数分布,求 $E(X)$.

例5 设随机变量 X 服从参数为 $1/\lambda$ 的指数分布, 求 $E(X)$.


解

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{else} \end{cases}$$



$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

例6 设随机变量 $X \sim N(\mu, \sigma^2)$
求 $E(X)$.



例6 设随机变量 $X \sim N(\mu, \sigma^2)$, 求 $E(X)$.

解

$$E(X) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

则

$$\text{令 } u = \frac{x-\mu}{\sigma}$$

$$E(X) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} (\sigma u + \mu) e^{-\frac{u^2}{2}} du$$

$$= \frac{\sigma}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u e^{-\frac{u^2}{2}} du + \frac{\mu}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du = \mu$$

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$$

不是任何随机变量的期望都是存在的

柯西分布(Cauchy distribution)的数学期望不存在

设随机变量 X 服从柯西分布, 则其概率密度为

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, -\infty < x < +\infty$$

由于

$$\int_{-\infty}^{+\infty} |x| \cdot \frac{1}{\pi} \frac{1}{1+x^2} dx = \frac{2}{\pi} \int_0^{+\infty} \frac{x}{1+x^2} dx = \frac{1}{\pi} \ln(1+x^2) \Big|_0^{+\infty} = +\infty$$

故 $E(X)$ 不存在.

重要分布的数学期望

- 1、 设 $X \sim b(n, p)$, 则 $E(X) = np$
- 2、 设 $X \sim \pi(\lambda)$, 则 $E(X) = \lambda$
- 3、 设 $X \sim U(a, b)$, 则 $E(X) = \frac{a+b}{2}$
- 4、 设 $X \sim N(\mu, \sigma^2)$, 则 $E(X) = \mu$
- 5、 设 X 服从参数为 θ 的指数分布, 则 $E(X) = \frac{1}{\theta}$

随机变量函数的数学期望

在很多实际问题中，经常遇到求随机变量函数的数学期望问题。


1. 问题的提出:

设已知随机变量 X 的分布，我们需要计算的不是 X 的期望，而是 X 的某个函数的期望，比如说 $g(X)$ 的期望。那么应该如何计算呢？

一种方法是，因为 $g(X)$ 也是随机变量，故应有概率分布，它的分布可以由已知的 X 的分布求出来。一旦我们知道了 $g(X)$ 的分布，就可以按照期望的定义把 $E[g(X)]$ 计算出来。

使用这种方法必须先求出随机变量函数 $g(X)$ 的分布，一般是比较复杂的。

那么是否可以不先求 $g(X)$ 的分布而只根据 X 的分布求得 $E[g(X)]$ 呢？



下面两个定理给出了求随机变量函数的数学期望的简便方法。利用这二个定理可以省略求随机变量函数的分布。

定理 1

设 $Y=g(X)$, $g(x)$ 是连续函数,

(1) 若 X 的分布律为 $P_k = P\{X = x_k\} \quad k = 1, 2, \dots$

且 $\sum_{k=1}^{\infty} P_k g(x_k)$ 绝对收敛, 则 $E(Y) = \sum_{k=1}^{\infty} P_k g(x_k)$

(2). 若 X 的概率密度为 $f(x)$, 且 $\int_{-\infty}^{\infty} g(x)f(x)dx$ 绝对收敛,

则 $E(Y) = \int_{-\infty}^{\infty} g(x)f(x)dx$ 。

证 设 X 是连续型随机变量, 且 $y=g(x)$ 满足第二章 § 5 中定理的条件.
由第二章 § 5 中的 (5.2) 式知道随机变量 $Y=g(X)$ 的概率密度为

$$f_Y(y) = \begin{cases} f_X[h(y)] |h'(y)|, & \alpha < y < \beta, \\ 0, & \text{其他,} \end{cases}$$

$$\begin{aligned} y &= g(x) \\ x &= h(y) \end{aligned}$$

于是

$$E(Y) = \int_{-\infty}^{\infty} y f_Y(y) dy = \int_{\alpha}^{\beta} y f_X[h(y)] |h'(y)| dy.$$

当 $h'(y)$ 恒 > 0 时

$$E(Y) = \int_{\alpha}^{\beta} y f_X[h(y)] h'(y) dy = \int_{-\infty}^{\infty} g(x) f(x) dx.$$

当 $h'(y)$ 恒 < 0 时

$$\begin{aligned} E(Y) &= - \int_{\alpha}^{\beta} y f_X[h(y)] h'(y) dy \\ &= - \int_{-\infty}^{\infty} g(x) f(x) dx = \int_{-\infty}^{\infty} g(x) f(x) dx. \end{aligned}$$

综合上两式, (1.4) 式得证. □

$$E(Y) = E[g(X)] = \begin{cases} \sum_{k=1}^{\infty} g(x_k) p_k, & X \text{离散型} \\ \int_{-\infty}^{\infty} g(x) f(x) dx, & X \text{连续型} \end{cases}$$

该公式的重要性在于：当我们求 $E[g(X)]$ 时，不必知道 $g(X)$ 的分布，而只需知道 X 的分布就可以了。这给求随机变量函数的期望带来很大方便。

上述定理还可以推广到两个或两个以上随机变量的函数的情况。

定理 2

设 Z 是随机变量 X, Y 的函数 $Z = g(X, Y)$ (g 是连续函数)
 Z 是一维随机变量, 则

(1) 若 (X, Y) 是二维连续型, 概率密度为 $f(x, y)$, 则有

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

(2) 若 (X, Y) 是二维离散型, 概率分布为
 $P\{X = x_i, Y = y_j\} = p_{ij} (i, j = 1, 2, \dots)$ 则有

$$E(Z) = E[g(X, Y)] = \sum_{j=1}^{\infty} \sum_{i=1}^{\infty} g(x_i, y_j) p_{ij}$$

这里假定上两式右边的积分或级数都绝对收敛.



数学期望的性质

(1) 设 C 为常数,则有 $E(C) = C$

(2) 设 X 是随机变量, k 是常数,则

$$E(kX) = kE(X)$$

(3) 设 X, Y 是随机变量,则

$$E(X + Y) = E(X) + E(Y)$$

(4) 设 X, Y 是随机变量,则

$$E(aX + bY) = aEX + bEY \quad E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i EX_i$$

(5) 设 X, Y 是相互独立的随机变量,则

$$E(XY) = E(X)E(Y)$$

$$E(X + Y) = E(X) + E(Y)$$

证明:

设

$$(X, Y) \sim f(x, y)$$

$$\begin{aligned} E(X + Y) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x + y) f(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy + \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dx dy \\ &= E(X) + E(Y) \end{aligned}$$

推广: $E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E(X_i)$

设 X 、 Y 独立, 则 $E(XY)=E(X)E(Y)$;

证明: 设 $(X,Y) \sim f(x,y)$ 注: 该性质不是充要条件

$$\begin{aligned} E(XY) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x,y)dxdy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf_X(x)f_Y(y)dxdy \\ &= \int_{-\infty}^{\infty} x f_X(x)dx \int_{-\infty}^{\infty} y f_Y(y)dy = E(X)E(Y) \end{aligned}$$

推广: $E[\prod_{i=1}^n X_i] = \prod_{i=1}^n E(X_i)$ (当 X_i 独立时)

假设 X 是一个随机变量，有0.5的概率为1，有0.5的概率为-1，

令 $Y=|X|$

容易得到 $E(xy)=E(x)E(y)=0$ ，

但是 Y 是 X 的函数，所以 X 和 Y 不可能是独立的。

首先，我们可以列出 X 和 Y 的联合概率分布：

- $P(X = -1, Y = 1)$: 由于 $Y = |X|$, 当 $X = -1$ 时, Y 必定为 1。因此这个概率等同于 $X = -1$ 的概率, 即 0.8。
- $P(X = 1, Y = 1)$: 同理, 因为 $X = 1$ 时, Y 必为 1, 所以这个概率等同于 $X = 1$ 的概率, 即 0.2。

所以，联合概率分布为：

- $P(X = -1, Y = 1) = 0.8$
- $P(X = 1, Y = 1) = 0.2$

接下来，我们可以通过条件概率来分析 X 和 Y 是否相互独立。

在概率论中，如果对于两个随机变量 X 和 Y 来说，对于所有可能的 x 和 y 都满足 $P(X = x \mid Y = y) = P(X = x)$ ，这是 X 和 Y **相互独立的充要条件**。这意味着 Y 的任何值都不会影响 X 的概率分布，反之亦然。

独立性条件:

- 随机变量 X 和 Y 相互独立的条件是所有 x 和 y 的取值, $P(X = x \text{ and } Y = y) = P(X = x)P(Y = y)$ 。

我们知道 $Y = 1$ 的概率 $P(Y = 1) = 1$, 因为 Y 总是等于 1。

首先, 由于 $Y = |X|$ 总是等于 1, 这意味着 $P(Y = 1) = 1$ (因为无论 X 取何值, Y 总是 1)。这样, 我们可以计算条件概率:

- $P(X = -1 \mid Y = 1) = \frac{P(X=-1,Y=1)}{P(Y=1)} = \frac{0.8}{1} = 0.8$
- $P(X = 1 \mid Y = 1) = \frac{P(X=1,Y=1)}{P(Y=1)} = \frac{0.2}{1} = 0.2$

这实际上与 X 的边缘概率相符，因为：

- $P(X = -1) = 0.8$
- $P(X = 1) = 0.2$

因此，在这种情况下，尽管 Y 是 X 的绝对值，但是在给定 $Y = 1$ 的条件下 X 的条件概率与其边缘概率相同。

当一个随机变量完全由另一个随机变量的函数确定时，即使条件概率等于无条件概率，它们在函数关系上不是真正独立的。这种情况下，虽然在数学定义上看似独立，实际上存在着依赖关系。因此，在处理这种问题时，理解随机变量之间的底层关系非常重要。

- **独立性定义：**两个随机变量 X 和 Y 独立，意味着对所有的 x, y 组合，都有 $P(X = x \text{ and } Y = y) = P(X = x) \times P(Y = y)$ 。这也意味着 $P(X = x \mid Y = y) = P(X = x)$ 。

- **函数关系的特例：**当 Y 是 X 的函数时，例如 $Y = |X|$ ，尽管看起来 $P(X = x \mid Y = y) = P(X = x)$ 成立，实际上 Y 的取值直接由 X 决定，因此他们之间存在依赖关系，但这种依赖关系并不符合我们通常意义上的“独立性”。

假设随机变量 X

取值 $\{-1, 0, 1\}$, 概率分别为 $\frac{1}{4}, \frac{1}{2}, \frac{1}{4}$ 。定义 $Y = X^2$ 。则 Y 的可能取值为 $\{0, 1\}$, 概率分别为 $\frac{1}{2}$ 和 $\frac{1}{2}$ (因为当 $X = 0$ 时 $Y = 0$, 当 $X = \pm 1$ 时 $Y = 1$)。

计算 $E(X)$, $E(Y)$ 和 $E(XY)$

1. $E(X)$: $E(X) = (-1) \times \frac{1}{4} + 0 \times \frac{1}{2} + 1 \times \frac{1}{4} = 0$

2. $E(Y)$: $E(Y) = 0 \times \frac{1}{2} + 1 \times \frac{1}{2} = \frac{1}{2}$

3. $E(XY)$: 由于 $Y = X^2$, 则 $XY = X \cdot X^2 = X^3$ 。因此:

$$E(XY) = E(X^3) = (-1)^3 \times \frac{1}{4} + 0^3 \times \frac{1}{2} + 1^3 \times \frac{1}{4} = -\frac{1}{4} + 0 + \frac{1}{4} = 0$$

分析

- $E(XY) = 0$
- $E(X)E(Y) = 0 \times \frac{1}{2} = 0$

尽管 $E(XY) = E(X)E(Y)$ ，显然 X 和 Y 并不独立。实际上 Y 是 X 的函数，因此 Y 的值完全由 X 的值决定。这种情况下，尽管期望值的乘积等于期望值的乘积的期望，但 X 和 Y 明显存在函数依赖关系，因此他们不独立。

使用条件概率 $P(X = x \mid Y = y)$ 是否等于无条件概率 $P(X = x)$ 来检验。

从先前的定义：

- X 取值 $\{-1, 0, 1\}$, 概率分别为 $\frac{1}{4}, \frac{1}{2}, \frac{1}{4}$ 。
- $Y = X^2$ 因此 Y 取值 $\{0, 1\}$, 当 $X = 0$ 时 $Y = 0$ (概率 $\frac{1}{2}$) , 当 $X = \pm 1$ 时 $Y = 1$ (概率 $\frac{1}{2}$) 。

计算条件概率 $P(X = x \mid Y = y)$

1. $P(X = 0 \mid Y = 0)$

- $X = 0$ 且 $Y = 0$ 的概率 $P(X = 0, Y = 0) = P(X = 0) = \frac{1}{2}$ (因为只有当 $X = 0$ 时 $Y = 0$) 。
- $Y = 0$ 的概率 $P(Y = 0) = \frac{1}{2}$ 。
- 因此, $P(X = 0 \mid Y = 0) = \frac{P(X=0, Y=0)}{P(Y=0)} = \frac{\frac{1}{2}}{\frac{1}{2}} = 1$ 。

2. $P(X = 0 \mid Y = 1)$

- $Y = 1$ 时 X 不能是 0。
- 因此, $P(X = 0 \mid Y = 1) = 0$ 。

3. $P(X = -1 | Y = 1)$

- $P(X = -1, Y = 1) = P(X = -1) = \frac{1}{4}$ (因为只有当 $X = -1$ 或 $X = 1$ 时 $Y = 1$) 。
- $Y = 1$ 的概率 $P(Y = 1) = \frac{1}{2}$ 。
- 因此, $P(X = -1 | Y = 1) = \frac{P(X=-1, Y=1)}{P(Y=1)} = \frac{\frac{1}{4}}{\frac{1}{2}} = \frac{1}{2}$ 。

结论

由此, 我们看到 $P(X = 0 | Y = 1) = 0$ 不等于 $P(X = 0) = \frac{1}{2}$, 以及 $P(X = -1 | Y = 1) = \frac{1}{2}$ 不等于 $P(X = -1) = \frac{1}{4}$ 。这表明在给定 Y 的值时 X 的条件概率不等于其边缘概率。因此, X 和 Y 并不是相互独立的。

数学期望性质的应用

例 求二项分布的数学期望

若 $X \sim B(n, p)$,

则 X 表示 n 重伯努利试验中的“成功”次数.

现在我们来求 X 的数学期望.

$X \sim B(n, p)$, 则 X 表示 n 重伯努利试验中的“成功”次数.

$$\text{若设 } X_i = \begin{cases} 1 & \text{如第 } i \text{ 次试验成功} \\ 0 & \text{如第 } i \text{ 次试验失败} \end{cases} \quad i=1, 2, \dots, n$$

则 $X = X_1 + X_2 + \dots + X_n$




因为 $P(X_i = 1) = p, P(X_i = 0) = 1 - p$

$$E(X_i) = 1 \cdot p + 0 \cdot (1 - p) = p$$






所以 $E(X) = \sum_{i=1}^n E(X_i) = np$

可见, 服从参数为 n 和 p 的二项分布的随机变量 X 的数学期望是 np .

本题是将 X 分解成数个随机变量之和,
然后利用
随机变量和的数学期望等于随机变量数学期望的和
来求数学期望的,
此方法具有一定的意义.



数学期望的应用



应用

验血方案的选择

为普查某种疾病, n 个人需验血. 验血方案有如下两种:

- (1) **分别化验** 每个人的血, 共需化验 n 次;
- (2) **分组化验**, k 个人的血混在一起化验,
若结果为阴性, 则只需化验一次;

若为阳性, 则对 k 个人的血逐个化验, 找出有病者, 此时 k 个人的血需化验 $k + 1$ 次.

设每人血液化验**呈阳性的概率为 p** , 且每人化验结果是**相互独立的**. 试说明选择哪一方案较经济.

解 只须计算方案(2)所需化验次数的期望.为简单计,不妨设 n 是 k 的倍数, 共分成 n/k 组.

设第 i 组需化验的次数为 X_i , 则

$$\begin{aligned} E(X_i) &= (1-p)^k + (k+1)[1-(1-p)^k] \\ &= (k+1) - k(1-p)^k \end{aligned}$$

X_i	1	$k+1$
P	$(1-p)^k$	$1-(1-p)^k$

$$E(X) = \sum_{i=1}^{n/k} E(X_i) = \frac{n}{k} \left[(k+1) - k(1-p)^k \right] = n \left[1 - \left((1-p)^k - \frac{1}{k} \right) \right]$$

若 $\left((1-p)^k - \frac{1}{k} \right) > 0$, 则 $E(X) < n$

$$\text{例, } n=1000, p=0.001, k=10, E(X) = 1000 \left[1 - \left(0.999^{10} - \frac{1}{10} \right) \right] \approx 110 \ll 1000.$$

当 $(1-p)^k < 1/k$ 时, 选择方案(2) 较经济.

第二次世界大战期间，数千万美国应征者在入伍前都进行了梅毒检测，预计大概有几千人感染了这种病。化验血样是一个非常耗时和昂贵的过程。哈佛经济学家Robert Dorfman想出了一个聪明的主意。他建议把所有人分成不同群组，将每一组所有人的血都混合成一份血样。如果这一份血样化验出来是阴性的，那么这一整组的人就都是健康的。如果这一份血样化验出来是阳性的，那么这一组中的人就要分开-再做一次检查。

小结

这一讲，我们介绍了随机变量的数学期望，它反映了随机变量取值的平均水平，是随机变量的一个重要的数字特征.