


研究背景

在研究子女与父母的相象程度时，有一项是关于父亲的身高和其成年儿子身高的关系。



这里有两个变量，一个是父亲的身高，一个是成年儿子身高。为了研究二者关系，英国统计学家皮尔逊收集了1078个父亲及其成年儿子身高的数据，画出了一张散点图。




那么要问：父亲及其成年儿子身高是一种什么关系呢？

类似的问题有：

吸烟和患肺癌有什么关系？

受教育程度和失业有什么关系？

高考入学分数和大学学习成绩有什么关系？




为了研究诸如此类的两变量的相互关系问题，我们需要从理论上对两变量的相互关系加以研究.

研究背景

对于二维随机变量 (X, Y) :

已知联合分布



边缘分布

对二维随机变量, 除每个随机变量各自的概率特性外, 相互之间可能还有某种联系.

问题: 用一个怎样的数去反映这种联系.



$E(xy) - E(x)E(y)$

Y和X之间的关系

①

设 X 、 Y 独立，
则 $E(XY) = E(X)E(Y)$

假设 X 是一个随机变量，有0.5的概率为1，有0.5的概率为-1，

令 $Y=|X|$

容易得到 $E(xy)=E(x)E(y)=0$,

②

但是 Y 是 X 的函数，所以 X 和 Y 不可能是独立的。

$$\begin{aligned} D(X+Y) &= E[X+Y-E(X+Y)]^2 \\ &= E(X-EX)^2 + E(Y-EY)^2 + 2E[(X-EX)(Y-EY)] \\ &= D(X) + D(Y) + 2[E(XY) - EX \cdot EY] \end{aligned}$$

若 X, Y 相互独立,
这项为零

③ 若这项不为零, 则不相互独立, 那么 X 与 Y 之间存在什么关系?

两个变量之间的关系

独立，没有
影响

不独立，有
影响

★
线性相
关关系

其他关
系

下面，我们将介绍刻画两随机变量间线性相关程度的重要的数字特征：

协方差、相关系数

一、协方差 (Covariance)

1.定义

$E\{[X-E(X)][Y-E(Y)]\}$ 称为随机变量 X 和 Y 的协方差,记为 $Cov(X,Y)$, 即

$$Cov(X,Y)=E\{[X-E(X)][Y-E(Y)]\}$$

2.协方差性质

(1) $Cov(X, Y) = Cov(Y, X);$

(2) $Cov(X, X) = D(X); Cov(X, c) = 0;$

(3) $Cov(aX, bY) = abCov(X, Y)$, 其中 a, b 为常数;

(4) $Cov(X+Y, Z) = Cov(X, Z) + Cov(Y, Z);$

(5) $D(C_1X + C_2Y) = C_1^2 DX + C_2^2 DY + 2C_1C_2Cov(X, Y)$

3、计算协方差的一个简单公式

由协方差的定义及期望的性质，可得

$$\begin{aligned}Cov(X,Y) &= E\{[X-E(X)][Y-E(Y)]\} \\&= E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y) \\&= E(XY) - E(X)E(Y)\end{aligned}$$

即

$$Cov(X,Y) = E(XY) - E(X)E(Y)$$

可见，若 X 与 Y 独立， $Cov(X,Y) = 0$.

特别地 $Cov(X,X) = E(X^2) - E(X)^2 = D(X)$

4、随机变量和的方差与协方差的关系

$$D(X+Y) = D(X) + D(Y) + 2Cov(X,Y)$$

二、相关系数 (Correlation coefficient)

协方差的大小在一定程度上反映了 X 和 Y 相互间的关系，但它还受 X 与 Y 本身度量单位的影响。

为了克服这一缺点，对协方差进行标准化：

$$\frac{Cov(X, Y)}{\sqrt{D(X)D(Y)}} = \frac{E\{[X - E(X)][Y - E(Y)]\}}{\sqrt{D(X)D(Y)}}$$

这就引入了**相关系数**。

相关系数 (Correlation coefficient)

定义： 设 $D(X)>0, D(Y)>0$ ， 称

消除量纲影响

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)D(Y)}}$$

为随机变量 X 和 Y 的相关系数。

在不致引起混淆时，记 ρ_{XY} 为 ρ 。

定义： 相关系数 $\rho_{XY} = 0$ ， 则称 X 与 Y 不（线性）相关；

关于相关系数，我们有下面的定理

1. 任意两个随机变量的相关系数的绝对值不大于1，即 $|\rho_{XY}| \leq 1$

证明 我们考虑随机变量 $Z = X^* \pm Y^*$ ，其中

$$X^* = \frac{X - E(X)}{\sqrt{D(X)}}, Y^* = \frac{Y - E(Y)}{\sqrt{D(Y)}};$$

由

$$D(Z) = D(X^*) + D(Y^*) \pm 2Cov(X^*, Y^*)$$

$$D(X^*) = D\left[\frac{X - E(X)}{\sqrt{D(X)}}\right] = \frac{1}{D(X)} D[X - E(X)] = \frac{1}{D(X)} D(X) = 1,$$

同理 $D(Y^*) = 1$ 所以有 $D(Z) = 2 \pm 2\rho_{XY} = 2(1 \pm \rho_{XY})$.

因为方差不能为负，所以有 $1 \pm \rho_{XY} \geq 0$ ，即 $|\rho_{XY}| \leq 1$.

$$Cov(X,Y)=E(XY) - E(X)E(Y)$$

2. X 和 Y 独立时, $\rho = 0$, 但其逆不真.

由于当 X 和 Y 独立时, $Cov(X,Y)=0$.

$$\text{故 } \rho = \frac{Cov(X,Y)}{\sqrt{D(X)D(Y)}} = 0$$

但由 $\rho = 0$ 并不一定能推出 X 和 Y 独立.

注意 $\rho = 0$, 即 $Cov(X,Y)=0$ 时, 仅表示 X 与 Y

不存在线性关系, 但它们可能存在其他关系。

例 设 X 服从 $(-1/2, 1/2)$ 内的均匀分布, 而 $Y=\cos X$,
不难求得 $Cov(X,Y)=0$,

事实上, X 的密度函数

$$f(x) = \begin{cases} 1 & -\frac{1}{2} < x < \frac{1}{2} \\ 0 & \text{其它} \end{cases} \quad \text{可得 } E(X) = 0$$

$$E(XY) = E(X \cos X) = \int_{-\frac{1}{2}}^{\frac{1}{2}} x \cos x f(x) dx = 0$$

$$Cov(X,Y) = E(XY) - E(X)E(Y) = 0$$

因而 $\rho=0$, 即
 X 和 Y 不(线性)相关.

但 Y 与 X 有严格的函数关系,
即
 X 和 Y 不独立.

例： $X \sim N(0,1)$, 令 $Y = X^2$, 证明 X 与 Y 不相关。

证： $E(X) = 0$, 所以, $E(X)E(Y) = 0$,

$$E(XY) = E(X^3) = \int_{-\infty}^{+\infty} \frac{x^3}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = 0$$

$$\therefore E(XY) = E(X)E(Y)$$

$$\text{Cov}(X, Y) = 0 \Rightarrow \rho_{XY} = 0 \quad X \text{ 与 } Y \text{ 不相关}$$

但是, 显然, X 与 Y 不是相互独立的。

不相关： X 与 Y 之间没有线性关系, 并不表示它们之间没有其他关系。

独立： X 与 Y 之间没有任何关系。

说明:

相关系数 ρ_{XY} 是 X 与 Y 之间线性关系的一种度量.

$|\rho_{XY}| \rightarrow 1$, X 与 Y 的线性关系越显著;

$|\rho_{XY}| \rightarrow 0$, X 与 Y 的线性关系越不显著;

定义: 相关系数 $\rho_{XY} = 0$, 则称 X 与 Y 不相关;

下列命题等价:

1) $\rho_{XY} = 0$,

2) $Cov(X, Y) = 0$;

3) $E(XY) = E(X)E(Y)$; 4) $D(X \pm Y) = D(X) + D(Y)$.

注: 相互独立 $\xrightarrow{\text{green}} \xleftarrow{\text{red}}$ 不相关

相关系数 ρ 是随机变量X和Y之间线性相关程度的一个度量。

$\rho > 0$ 表示正相关；

$\rho < 0$ 表示负相关；

ρ 接近于0表示X和Y之间几乎没有线性关系，但它们之间可能有其他关系。

3. $|\rho| = 1 \iff$ 存在常数 $a, b (b \neq 0)$, 使 $P\{Y = a + bX\} = 1$,

即 X 和 Y 以概率 1 线性相关.

相关系数刻画了 X 和 Y 间 “线性相关” 的程度.

相关系数刻画了 X 和 Y 间“线性相关”的程度.

考虑以 X 的线性函数 $a+bX$ 来近似表示 Y ,

以均方误差

$$e = E\{[Y-(a+bX)]^2\}$$

来衡量以 $a + b X$ 近似表示 Y 的好坏程度：

e 值越小表示 $a + b X$ 与 Y 的近似程度越好.

用微积分中求极值的方法，求出使 e 达到最小时的 a, b

$$e = E\{[Y-(a+bX)]^2\} = E(Y^2) + b^2E(X^2) + a^2 - 2bE(XY) + 2abE(X) - 2aE(Y)$$

这样求出的
最佳逼近为

$$\begin{cases} \frac{\partial e}{\partial a} = 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial e}{\partial b} = 2bE(X^2) - 2E(XY) + 2aE(X) = 0 \end{cases}$$

解得

$$\begin{cases} b_0 = \frac{\text{Cov}(X, Y)}{D(X)} \\ a_0 = E(Y) - b_0E(X) \end{cases}$$

$$L(X) = a_0 + b_0X$$

$$E[(Y-L(X))^2] = D(Y)(1-\rho^2)$$

$$E[(Y-(a_0+b_0X))^2] = D[Y-a_0-b_0X] + [E(Y-a_0-b_0X)]^2$$

$$= D(Y-b_0X) + \left[-\frac{1}{2} \frac{\partial e}{\partial a} \bigg|_{\substack{a=a_0 \\ b=b_0}} \right]^2 = D(Y-b_0X) + 0$$

$$= D(Y) + b_0^2 D(X) - 2b_0 \text{Cov}(X, Y) = D(Y) + \frac{\text{Cov}^2(X, Y)}{D(X)} - 2 \frac{\text{Cov}^2(X, Y)}{D(X)}$$

$$= D(Y) \left[1 - \frac{\text{Cov}^2(X, Y)}{D(X)D(Y)} \right] = (1-\rho_{XY}^2) D(Y).$$

这样求出的最佳逼近为 $L(X)=a_0+b_0X$

$$E[(Y-L(X))^2]=D(Y)(1-\rho^2)$$

可见，若 $\rho = \pm 1$ ， Y 与 X 有严格线性关系；

若 $\rho = 0$ ， Y 与 X 无线性关系；

若 $0 < |\rho| < 1$ ，

$|\rho|$ 的值越接近于1， Y 与 X 的线性相关程度越高；

$|\rho|$ 的值越接近于0， Y 与 X 的线性相关程度越弱。

小结

协方差和相关系数

相关系数是刻画两个变量间**线性相关程度**的一个重要的数字特征.

它取值在-1到1之间.

如果两个变量之间存在**强相关**, 则已知一个变量的值对预测另一个变量的值将很有帮助.

如果两个变量之间只有**很弱的相关**, 则关于一个变量的信息对猜测另一个变量的值没有多大帮助.

注意独立与不相关并不是等价的.

但是

当 (X, Y) 服从二维正态分布时, 有

X 与 Y 独立 $\Leftrightarrow X$ 与 Y 不相关

期望、方差、协方差的性质对比

期望	方差	协方差
$E(c)=C$	$D(c)=0$	$Cov(c,X)=0$
$E(aX)=aE(X),$	$D(aX)=a^2D(X),$	$Cov(aX,bY)$ $=abCov(X,Y)$
$E(X+Y)$ $=E(X)+E(Y)$ 当X与Y独立时 $E(XY)=E(X)E(Y)$	$D(X+Y)=D(X)+$ $D(Y)+2Cov(X,Y)$	$Cov(X+Y,Z)$ $=Cov(X,Z)$ $+Cov(Y,Z)$

第四节 矩、协方差矩阵

- 原点矩 中心矩
- 协方差矩阵
- n 元正态分布的概率密度
- 小结

一、 原点矩 中心矩

定义 设 X 和 Y 是随机变量，若

$$E(X^k), k = 1, 2, \dots$$

存在，称它为 X 的 k 阶**原点矩**，简称 k 阶矩

若 $E\{[X - E(X)]^k\}, k = 2, 3, \dots$

存在，称它为 X 的 k 阶**中心矩**

可见，均值 $E(X)$ 是 X 一阶原点矩，

方差 $D(X)$ 是 X 的二阶中心矩。

设 X 和 Y 是随机变量，若

$$E(X^k Y^L) \quad k, L=1, 2, \dots \text{ 存在,}$$

称它为 X 和 Y 的 $k+L$ 阶混合（原点）矩.

若 $E\{[X - E(X)]^k [Y - E(Y)]^L\}$ 存在,

称它为 X 和 Y 的 $k+L$ 阶混合中心矩.

可见,

协方差 $Cov(X, Y)$ 是 X 和 Y 的二阶混合中心矩.

二、协方差矩阵

将二维随机变量 (X_1, X_2) 的四个二阶中心矩

$$c_{11} = E\{[X_1 - E(X_1)]^2\}$$

都存在

$$c_{12} = E\{[X_1 - E(X_1)][X_2 - E(X_2)]\}$$

$$c_{21} = E\{[X_2 - E(X_2)][X_1 - E(X_1)]\}$$

$$c_{22} = E\{[X_2 - E(X_2)]^2\}$$

排成矩阵的形式: $\begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{pmatrix}$

这是一个
对称矩阵

称此矩阵为 (X_1, X_2) 的协方差矩阵.

类似定义 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵.

若
$$\begin{aligned} c_{ij} &= \text{Cov}(X_i, X_j) \\ &= E\{[X_i - E(X_i)][X_j - E(X_j)]\} \\ &\quad (i, j=1, 2, \dots, n) \end{aligned}$$

都存在, 称

矩阵
$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

为 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵

三、 n 维正态分布的概率密度

设 $X'=(X_1, X_2, \dots, X_n)$ 是一个 n 维随机向量,
若它的概率密度为

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} \exp \left\{ -\frac{1}{2} (X - \mu)' C^{-1} (X - \mu) \right\}$$

则称 X 服从 n 维正态分布.

其中 C 是 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵.

$|C|$ 是它的行列式, C^{-1} 表示 C 的逆矩阵,

X 和 μ 是 n 维列向量, X' 表示 X 的转置.

N 维正态分布的几条重要性质

1. $X=(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布



对一切不全为0的实数 $a_1, a_2, \dots, a_n$,
 $a_1 X_1 + a_2 X_2 + \dots + a_n X_n$ 均服从正态分布.

2. 正态变量的线性变换不变性.

若 $X=(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布,
 $Y_1, Y_2, \dots, Y_k$ 是 X_j ($j=1, 2, \dots, n$) 的线性函数,
则 $(Y_1, Y_2, \dots, Y_k)$ 也服从多维正态分布.

3. 设 $(X_1, X_2, \dots, X_n)$ 服从 n 维正态分布, 则

“ $X_1, X_2, \dots, X_n$ 相互独立”

等价于

“ $X_1, X_2, \dots, X_n$ 两两不相关”

例 已知随机变量(X,Y)的分布律如下表，
问X，Y是否（线性）相关？是否独立？

$Y \backslash X$	-2	0	2	$P_{\cdot j}$
-2	0	1/4	0	1/4
0	1/4	0	1/4	1/2
2	0	1/4	0	1/4
$P_{i \cdot}$	1/4	1/2	1/4	1

解 $E(X) = E(Y) = (-2) \times \frac{1}{4} + 0 \times \frac{1}{2} + 2 \times \frac{1}{4} = 0,$

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 \\ &= (-2)^2 \times \frac{1}{4} + 0^2 \times \frac{1}{2} + 2^2 \times \frac{1}{4} - 0 = 2, \end{aligned}$$

类似地有 $D(X) = 2$.

易知XY的分布为

XY	-4	0	4
P	0	1	0

于是 $E(XY) = (-4) \times 0 + 0 \times 1 + 4 \times 0 = 0$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0$$

所以X与Y不相干。

但 $P(X=0, Y=0) = 0 \neq P(X=0) P(Y=0) = 1/4$

故 X 与 Y 不相互独立。

$Y \backslash X$	-2	0	2	$P_{.j}$
-2	0	1/4	0	1/4
0	1/4	0	1/4	1/2
2	0	1/4	0	1/4
$P_{i.}$	1/4	1/2	1/4	1