


人工智能导论——知识图谱

目录

- 什么是知识图谱
- 本体
- 知识图谱的表示
- 知识图谱的存储与查询
- 知识图谱的构建
- 知识图谱的应用
- 典型知识图谱项目
- 开放知识图谱
- 扩展：认知图谱

什么是知识图谱



2009年，Markram在TED大会上，向公众宣布了一个惊人大计划：他要在了解大脑结构的基础上，用计算机创建一个复杂的数学模型，**模拟人脑的86亿个神经元和100万亿的突触。**

Markram表示，研究一旦成功将对整个人类带来极大意义：为老年痴呆等疾病带来革命性进展，研发出更智能认知能力更强的机器人，甚至帮助找到让计算机处理速度更快的方式。

欧盟政府牵头，联合多个国家和地区的科研机构，打算资助这个看起来极其炫酷的实验，他们重金押注，一出手就是13亿欧元，将蓝脑计划更名为“人类脑计划”，全称Human Brain Project，简称为**HBP**。

欧洲大脑计划“骗”了欧盟10亿欧元，模拟人脑10年后宣告失败

2019-07-31 09:00




人工智能与知识图谱




聪明的AI

感知
识别
判断



深度学习



有学识的AI

思考
语言
推理



知识图谱



未来的AI

联接 + 符号

学习 + 推理

感知 + 认知

人工智能大脑-知识图谱




知识图谱的提出

- 知识图谱由Google于2012年提出
- 知识工程，专家系统



Edward Feigenbaum
Father of KB
Turing Award



Tim Berners Lee
Father of WWW
Turing Award

谷歌知识图谱

特朗普

×

全部

新闻

图片

视频

地图

更多

设置

工具

找到约 179,000,000 条结果 (用时 0.51 秒)

焦点新闻

美国大选：最高法院驳回法律诉讼 特朗普挑战努力遭重挫

BBC.com · 23 小时前

"再干四年"- 美国亲特朗普选民的口号

RFI · 3 小时前

中国驻美使馆转特朗普不实推文，随后称帐号被黑

纽约时报 · 2 天前

→

查看全部

www.bbc.com › zhongwen › simp › world-55289499

美国大选：最高法院驳回法律诉讼特朗普挑战努力遭重挫- BBC ...

1 天前 — 美国最高法院驳回德州提出的推翻4个摇摆州选举结果的法律诉讼，对特朗普翻盘努力给予“象征性最后一击”。

www.rfi.fr › 法广 › 政治

“再干四年”- 美国亲特朗普选民的口号 - RFI

4 小时前 — 美国2020年大选的投票早已结束，但有关选举结果的争议对寻求连任的现总统特朗普而言仍是剪不断，理还乱。亲特朗普的美国选民则无畏Covid ...

news.sina.cn › news_zt › keyword.d.html › k=特朗普

特朗普_关键词专题页_新浪新闻_手机新浪网

新闻 特朗普 相关图集 ...

china.usembassy-china.org.cn › 设为首页 › 新闻与活动

总统唐纳德·特朗普Archives | 美国驻华大使馆和领事馆

唐纳德·特朗普

美国总统

唐纳德·约翰·特朗普，美国政治人物、企业家，纽约市皇后区人，现任美国总统。唐纳德·特朗普出生并成长于纽约州纽约市皇后区，为特朗普集团前任董事长兼总裁及特朗普娱乐公司的创办人，在全世界经营房地产、赌场和酒店。[维基百科](#)

当前职务

美国总统

以下职务的 2020 年候选人

美国总统

[查看选举结果](#)

来源: [The Associated Press](#)

子女: 伊万卡·特朗普, 小唐纳德·特朗普, 巴伦·特朗普, 蒂芙尼·特朗普, 埃里克·特朗普 热点

出生信息: 1946 年 6 月 14 日 (74 岁), [纽约纽约牙买加医院医疗中心](#)

身高: 6' 3"

资产净值: 25 亿美元 (2020 年) [福布斯](#)

配偶: [梅拉尼亚·特朗普](#) (结婚时间: 2005 年), [更多](#)

教育背景: [宾夕法尼亚大学沃顿商学院](#) (1966 年–1968 年), [更多](#)

资料来源: [Ballotpedia](#), [CTCL](#), [Wikipedia](#) [了解详情](#)

用户还搜索了


还有10+项

2021/12/23

8

知识图谱的定义


知识图谱 (Knowledge graph) 是一种以结构化的组织形式描述客观世界中概念、实体及其关系，将数据表达成更接近人类认知世界的形式。



全历史知识图谱



英雄联盟知识图谱




知识图谱，是一种揭示实体之间关系的语义网络。知识图谱是由一条条知识组成，每条知识表示为一个SPO三元组。

(Subject-Predicate-Object)

知识图谱的构建方式有两种，一种是**自顶向下(top-down)**的构建方式。自顶向下指的是先为知识图谱定义好本体与数据模式，再将实体加入到知识库。另外一种**自底向上(bottom-up)**的构建方式。自底向上指的是从一些开放链接数据中提取出实体，选择其中置信度较高的加入到知识库，再构建实体与实体之间的联系。

知识图谱在逻辑结构上可分为模式层与数据层两个层次，数据层主要是由一系列的事实组成，而知识将以事实为单位进行存储。模式层构建在数据层之上，主要是通过本体库来规范数据层的一系列事实表达。本体是结构化知识库的概念模板，通过本体库而形成的知识库不仅层次结构较强，并且冗余程度较小。

本体



本体 (ontology)

ontology

ontos + logic

“being” + “learning something”

本体 (ontology)



本体 (ontology)

PERIODIC TABLE OF THE ELEMENTS

1
IA

2
IIA

13
IIIA

14
IVA

15
VA

16
VIA

17
VIIA

18
VIIIA

1
H
Hydrogen
1.0079

2
He
Helium
4.0026

3
Li
Lithium
6.941

4
Be
Beryllium
9.0122

5
B
Boron
10.811

6
C
Carbon
12.011

7
N
Nitrogen
14.007

8
O
Oxygen
15.999

9
F
Fluorine
18.998

10
Ne
Neon
20.179

11
Na
Sodium
22.990

12
Mg
Magnesium
24.305

13
Al
Aluminium
26.982

14
Si
Silicon
28.086

15
P
Phosphorus
30.974

16
S
Sulphur
32.065

17
Cl
Chlorine
35.453

18
Ar
Argon
39.948

19
K
Potassium
39.098

20
Ca
Calcium
40.078

21
Sc
Scandium
44.956

22
Ti
Titanium
47.867

23
V
Vanadium
50.942

24
Cr
Chromium
51.996

25
Mn
Manganese
54.938

26
Fe
Iron
55.845

27
Co
Cobalt
58.933

28
Ni
Nickel
58.693

29
Cu
Copper
63.546

30
Zn
Zinc
65.39

31
Ga
Gallium
69.723

32
Ge
Germanium
72.64

33
As
Arsenic
74.922

34
Se
Selenium
78.96

35
Br
Bromine
79.904

36
Kr
Krypton
83.80

37
Rb
Rubidium
85.468

38
Sr
Strontium
87.62

39
Y
Yttrium
88.906

40
Zr
Zirconium
91.224

41
Nb
Niobium
92.906

42
Mo
Molybdenum
95.94

43
Tc
Technetium
(98)

44
Ru
Ruthenium
101.07

45
Rh
Rhodium
102.91

46
Pd
Palladium
106.42

47
Ag
Silver
107.87

48
Cd
Cadmium
112.41

49
In
Indium
114.82

50
Sn
Tin
118.71

51
Sb
Antimony
121.76

52
Te
Tellurium
127.60

53
I
Iodine
126.90

54
Xe
Xenon
131.29

55
Cs
Cesium
132.91

56
Ba
Barium
137.33

57-71
Lanthanide

72
Hf
Hafnium
178.49

73
Ta
Tantalum
180.95

74
W
Tungsten
183.84

75
Re
Rhenium
186.21

76
Os
Osmium
190.23

77
Ir
Iridium
192.22

78
Pt
Platinum
195.08

79
Au
Gold
196.97

80
Hg
Mercury
200.59

81
Tl
Thallium
204.38

82
Pb
Lead
207.2

83
Bi
Bismuth
208.98

84
Po
Polonium
(209)

85
At
Astatine
(210)

86
Rn
Radon
(222)

87
Fr
Francium
(223)

88
Ra
Radium
(226)

89-103
Actinide

104
Rf
Rutherfordium
(261)

105
Db
Dubnium
(262)

106
Sg
Seaborgium
(266)

107
Bh
Bohrium
(264)

108
Hs
Hassium
(277)

109
Mt
Meitnerium
(268)

110
Uun
Ununnilium
(281)

111
Uuu
Unununium
(272)

112
Uub
Unbibium
(285)

113
Uut
Ununtrium
(284)

114
Uuq
Ununquadium
(289)

115
Uup
Ununpentium
(288)

116
Uuh
Ununhexium
(291)

117
Uus
Ununseptium
(294)

118
Uuo
Ununoctium
(294)

14
IVA
Group IUPAC
Group CAS
Selected Oxidation States
Name
Electron Configuration
Atomic Mass



6
C
Carbon
12.011

Alkali Metals
Alkaline Earth Metals
Transition Metals
Metals
Metalloides
Nonmetals
Halogens
Noble Gases
Gas
Liquid
Solid
at 25C
Synthetic

Electron Shells						
1	K	2	S	P	D	F
2	L	8	2	6		
3	M	18	2	6	10	
4	N	32	2	6	10	14
5	O	32	2	6	10	14
6	P	18	2	6	10	
7	Q	8	2	6		
8	R	2	2			

Lanthanide														
57 ⁺³	58 ^{+3 +4}	59 ⁺³	60 ⁺³	61 ⁺³	62 ^{+2 +3}	63 ^{+2 +3}	64 ⁺³	65 ⁺³	66 ⁺³	67 ⁺³	68 ⁺³	69 ⁺³	70 ^{+2 +3}	71 ⁺³
La	Ce	Pr	Nd	Pm	Sm	Eu	Gd	Tb	Dy	Ho	Er	Tm	Yb	Lu
Lanthanum 138.91 2-8-18-18-9-2	Cerium 140.12 2-8-18-20-8-2	Praseodymium 140.91 2-8-18-21-8-2	Neodymium 144.24 2-8-18-22-8-2	Promethium (145) 2-8-18-23-8-2	Samarium 150.36 2-8-18-24-8-2	Europium 151.96 2-8-18-25-8-2	Gadolinium 157.25 2-8-18-25-9-2	Terbium 158.93 2-8-18-27-8-2	Dysprosium 162.50 2-8-18-28-8-2	Holmium 164.93 2-8-18-29-8-2	Erbium 167.26 2-8-18-30-8-2	Thulium 168.93 2-8-18-31-8-2	Ytterbium 173.04 2-8-18-32-8-2	Lutetium 174.97 2-8-18-32-9-2
Actinide														
89 ⁺³	90 ⁺⁴	91 ^{+4 +5}	92 ^{+3 +4 +5 +6}	93 ^{+3 +4 +5 +6}	94 ^{+3 +4 +5 +6}	95 ^{+3 +4 +5 +6}	96 ⁺³	97 ^{+3 +4}	98 ⁺³	99 ⁺³	100 ⁺³	101 ⁺³	102 ⁺³	103 ⁺³
Ac	Th	Pa	U	Np	Pu	Am	Cm	Bk	Cf	Es	Fm	Md	No	Lr
Actinium (227) 18-13-18-19-2	Thorium 232.04 18-13-18-10-2	Protactinium (231) 18-32-20-9-2	Uranium 238.03 18-13-21-3-2	Neptunium (237) 18-32-24-8-2	Plutonium (244) 18-32-24-8-2	Americium (243) 18-32-24-8-2	Curium (247) 18-32-24-8-2	Berkelium (247) 18-32-24-8-2	Californium (251) 18-32-24-8-2	Einsteinium (252) 18-32-24-8-2	Fermium (257) 18-32-24-8-2	Mendelevium (258) 18-32-24-8-2	Nobelium (259) 18-32-24-8-2	Lawrencium (262) 18-32-24-8-2

“豹科”



Objects

Objects and Properties

Objects and Relationships

Objects and Properties and Relationships



“You can get an idea of the signs if you rely on the relationship between two objects, for example, one of the objects with a data object, and if you want to say that Mike Fickrey has a (fictional villain from one of the first Palantir videos) blue eyes, you are creating a connection between the Mike Fickrey and blue eyes objects.”



Full Hierarchy

Schema.org is defined as two hierarchies: one for textual property values, and one for the things that they describe.

Thing

This is the main schema.org hierarchy: a collection of types (or "classes"), each of which has one or more parent types. Although a type may have more than one super-type, here we show each type in one branch of the tree only. There is also a parallel hierarchy for **data types**.

Select vocabulary view:

- ☐ Core vocabulary ☒ Core plus all extension vocabularies

DataType

- Boolean
- Date
- DateTime
- Number
 - Float
 - Integer
- Text
 - URL
- Time

Thing: additionalType, description, image, name, url

CreativeWork: about, accountablePerson, aggregateRating, alternativeHeadline, associatedMedia, audience, audio, author, award, awards, comment, contentLocation, contentRating, contributor, copyrightHolder, copyrightYear, creator, dateCreated, dateModified, datePublished, discussionUrl, editor, encoding, encodings, genre, headline, inLanguage, interactionCount, isFamilyFriendly, keywords, mentions, offers, provider, publisher, publishingPrinciples, review, reviews, sourceOrganization, text, thumbnailUrl, version, video

Article: articleBody, articleSection, wordCount

BlogPosting

NewsArticle: dateline, printColumn, printEdition, printPage, printSection

ScholarlyArticle

MedicalScholarlyArticle: citation, publicationType

Blog: blogPost, blogPosts

Book: bookEdition, bookFormat, illustrator, isbn, numberOfPages

Comment

Diet: dietFeatures, endorsers, expertConsiderations, overview, physiologicalBenefits, proprietaryName, risks

ExercisePlan: activityDuration, activityFrequency, additionalVariable, exerciseType, intensity, repetitions, restPeriods, workload

ItemList: itemListElement, itemListOrder

Map

[Thing](#) > [CreativeWork](#) > [Article](#) > [ScholarlyArticle](#) > [MedicalScholarlyArticle](#)

医学领域的学术文章。

属性	预期类型	描述
Thing 的属性		
<code>additionalType</code>	URL	该项的一个附加类型，通常用于从外部词典中向微数据语法添加更加具体的类型。它表示事务和事务本身所属的类之间的关系。在RDFa语法中，对多类型最好使用‘typeof’属性这样的本地RDFa语法。Schema.org 工具对额外类型的理解较弱，特别是外部定义的额外类型。
<code>description</code>	Text	该项的一个简单描述。
<code>image</code>	URL	该项的图像URL地址。
<code>name</code>	Text	该项的名称。
<code>url</code>	URL	该项的URL地址。
CreativeWork 的属性		
<code>about</code>	Thing	主题内容。
<code>accountablePerson</code>	Person	指定对CreativeWork负有法律责任的人。
<code>aggregateRating</code>	AggregateRating	基于该项的一系列评论或评价的一个总体评价。
<code>alternativeHeadline</code>	Text	CreativeWork的副标题。
<code>associatedMedia</code>	MediaObject	对该创作作品编码的媒体对象。此属性是编码的一个代名词。
<code>audience</code>	Audience	该作品所面向的观众，也就是该作品为哪些群体创作。
<code>audio</code>	AudioObject	嵌入式音频对象。
<code>author</code>	Person or Organization	此内容的作者。请注意，作者在HTML 5 中很特殊，HTML 5 为其提供了一个特殊的机制，通过rel 标签来表明作者的身份。两者等同并可互换使用。
<code>award</code>	Text	此人或该创作性作品获得的奖金(奖项)。

只针对开放域

Semantic Markup: 在网页、邮件、应用程序中嵌入语义数据

```
<p>Big (1988) is a fantasy comedy movie starting Tom Hanks and directed by Penny Marshall.</p>
```

RDFa, JSON-LD, HTML5 Microdata

```
<div itemscope itemtype="http://schema.org/Movie"><p>  
  <span itemprop="name">Big </span> (1988) is a  
  <span itemprop="genre">fantasy comedy</span> movie starting  
  <span itemprop="actor" itemscope itemtype="http://schema.org/Person">  
    <span itemprop="name">Tom Hanks</span></span> and directed by  
  <span itemprop="director" itemscope itemtype="http://schema.org/person">  
    <span itemprop="name">Penny Marshall</span></span>.</p></div>
```


搜索引擎优化

已经包含642个类，992个关系



截止2016年，全球约有1.2亿的网站，超过30%的网页已经嵌入有Schema.org的语义数据。谷歌2015年12月推出的Customizable Knowledge Graph，允许各网站基于Schema.org，以RDFa，JSON-LD，HTML Microdata等方式在网页、邮件等数据源中嵌入语义化数据，支持个人和企业定制自己的知识图谱信息。


知识图谱的表示



知识表示

基于离散符号的知识表示


RDF, OWL, 各种Rule Language等



VS

基于连续向量的知识表示

Tensor, 各种Embedding, 神经网络表示等




显式知识、强逻辑约束、易于解释、推理不易扩展


隐式知识、弱逻辑约束、不易解释、对接神经网络

"This is a pity, as in fact documents on the web describe real objects and imaginary concepts, and give particular relationships between them but we could not process them at all..."

Tim Berners-Lee, Inventor of the Web, @WWW Geneva, 1994



Web of Texts, Web of documents



Web of Objects, Web of Data, Web of Things


- 语义网
 - XML
 - RDF
 - OWL

XML最初被设计用于网络之间数据的传输，语法类似于html，但是可以自行定义标签的名字。这个特点非常适合定义符合各自要求的数据格式，也使得xml具有更强大的表达能力，不过因此也导致XML数据的结构过于松散随意，其统一性和通用性受到了严重限制。读者通常需要对xml Schema文件（xsls）有足够的详细了解之后才可以完全理解xml文件背后的语义信息。

- 语义网
 - XML
 - **RDF**
 - OWL

RDF (Resource Description Framework, 资源描述框架) 是一种资源描述语言, 它受到元数据标准、框架系统、面向对象语言等多方面的影响, 被用来描述各种网络资源, 其出现为人们在Web上发布结构化数据提供一个标准的数据描述框架。RDF提出了一个简单的二元关系模型来表示事物之间的语义关系, 即使用三元组集合的方式来描述事物和关系, 三元组的结构为“资源-属性-属性值”, 资源实体由URI表示, 属性值可以是另一个资源实体的URI, 也可以是某种数据类型的值, 也称为literals (字面量)。

基本数据模型：有向标记图



- 语义网
 - XML
 - RDF
 - **OWL**


OWL（网络本体语言），编程语言，全称Web Ontology Language，是W3C开发的一种网络本体语言，用于对本体进行语义描述。OWL被设计用来处理资讯的内容而不是仅仅向人类呈现信息的应用。通过提供更多具有形式语义的词汇，使之在Web内容的机器可理解性方面要强于XML、RDF和RDF Schema（RDF-S）。

OWL与推理机

语言类型	推理机
OWL2-DL	FaCT++ (Manchester), HermiT (Oxford), Pellet (Clarkparsia)
OWL2-EL	CEL (Dresden), ELK (Oxford)
OWL2-RL	Jena (HP Labs Bristol, Aberdeen), Oracle 11g OWL Reasoner (Oracle)
OWL2-QL	QuOnto (Rome), Quill (Aberdeen)

- Protégé软件是斯坦福大学医学院生物信息研究中心基于Java语言开发的本体编辑和本体开发工具，也是基于知识的编辑器，属于开放源代码软件
 - Protégé是一组自由开源的工具软件，用于构建域模型与基于知识的本体化应用程序。
 - Protégé提供了大量的知识模型架构与动作，用于创建、可视化、操纵各种表现形式的本体。
 - 可以通过用户定制实现域-友好(领域相关)的支持，用于创建知识模型并填充数据。
 - Protégé可以通过两种方式进行扩展：插件和基于java的API。
 - 相比与其他的本体构建工具而言，Protégé最大的好处在于支持中文，在插件上，用OntoGraf可实现中文关系的显示。

知识图谱的表示




表示学习旨在将研究对象的语义信息表示为稠密低维实值向量，知识表示学习主要是面向知识图谱中的实体和关系进行表示学习。使用建模方法将实体和关系表示在低维稠密向量空间中，然后进行计算和推理。简单来说，就是将三元组表示成向量的这个过程就称为表示学习。

数值化表示

1. DeepWalk
2. Node2vec
3. Struc2vec
4. LINE
5. SDNE
6. transE
7. transH

word2vec



架构1: CBOW

架构2: Skip_gram

更新模型参数时, 同时更新 w 和特征向量 x

负采样模型

DEEPWALK

Algorithm 1 DEEPWALK(G, w, d, γ, t)

Input: graph $G(V, E)$

 window size w

 embedding size d

 walks per vertex γ

 walk length t

Output: matrix of vertex representations $\Phi \in \mathbb{R}^{|V| \times d}$

1: Initialization: Sample Φ from $\mathcal{U}^{|V| \times d}$

2: Build a binary Tree T from V

3: **for** $i = 0$ to γ **do**

4: $\mathcal{O} = \text{Shuffle}(V)$


5: **for each** $v_i \in \mathcal{O}$ **do**


6: $\mathcal{W}_{v_i} = \text{RandomWalk}(G, v_i, t)$

7: SkipGram($\Phi, \mathcal{W}_{v_i}, w$)

8: **end for**

9: **end for**








We define a 2nd order random walk with two parameters p and q which guide the walk: Consider a random walk that just traversed edge (t, v) and now resides at node v (Figure 2). The walk now needs to decide on the next step so it evaluates the transition probabilities π_{vx} on edges (v, x) leading from v . We set the unnormalized transition probability to $\pi_{vx} = \alpha_{pq}(t, x) \cdot w_{vx}$, where

$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & \text{if } d_{tx} = 0 \\ 1 & \text{if } d_{tx} = 1 \\ \frac{1}{q} & \text{if } d_{tx} = 2 \end{cases}$$

Struc2vec





$$p_1(v_6, v_7) = \frac{1}{1 + \exp(-u_6^T \cdot u_7)}$$

联合概率分布

$$\hat{p}_1(6,7) = \frac{w_{6,7}}{w_{1,5} + w_{2,5} + w_{6,7} + \dots}$$

经验概率分布

一阶相似性：

first-order proximity, for each undirected edge (i, j) , we define the joint probability between vertex v_i and v_j as follows:

$$p_1(v_i, v_j) = \frac{1}{1 + \exp(-\vec{u}_i^T \cdot \vec{u}_j)}, \quad (1)$$

where $\vec{u}_i \in R^d$ is the low-dimensional vector representation of vertex v_i . Eqn. (1) defines a distribution $p(\cdot, \cdot)$ over the space $V \times V$, and its empirical probability can be defined as $\hat{p}_1(i, j) = \frac{w_{ij}}{W}$, where $W = \sum_{(i,j) \in E} w_{ij}$. To preserve the first-order proximity, a straightforward way is to minimize the following objective function:

$$O_1 = d(\hat{p}_1(\cdot, \cdot), p_1(\cdot, \cdot)), \quad (2)$$

where $d(\cdot, \cdot)$ is the distance between two distributions. We choose to minimize the KL-divergence of two probability distributions. Replacing $d(\cdot, \cdot)$ with KL-divergence and omitting some constants, we have:

$$O_1 = - \sum_{(i,j) \in E} w_{ij} \log p_1(v_i, v_j), \quad (3)$$

$$p_2(v_j|v_i) = \frac{\exp(\vec{u}_j'^T \cdot \vec{u}_i)}{\sum_{k=1}^{|V|} \exp(\vec{u}_k'^T \cdot \vec{u}_i)}, \quad (4)$$


where $|V|$ is the number of vertices or “contexts.” For each vertex v_i , Eqn. (4) actually defines a conditional distribution $p_2(\cdot|v_i)$ over the contexts, i.e., the entire set of vertices in the network. As mentioned above, the *second-order* proximity assumes that vertices with similar distributions over the contexts are similar to each other. To preserve the *second-order* proximity, we should make the conditional distribution of the contexts $p_2(\cdot|v_i)$ specified by the low-dimensional representation be close to the empirical distribution $\hat{p}_2(\cdot|v_i)$. Therefore, we minimize the following objective function:

$$O_2 = \sum_{i \in V} \lambda_i d(\hat{p}_2(\cdot|v_i), p_2(\cdot|v_i)), \quad (5)$$

where $d(\cdot, \cdot)$ is the distance between two distributions. As the importance of the vertices in the network may be different, we introduce λ_i in the objective function to represent

the prestige of vertex i in the network, which can be measured by the degree or estimated through algorithms such as PageRank [15]. The empirical distribution $\hat{p}_2(\cdot|v_i)$ is defined as $\hat{p}_2(v_j|v_i) = \frac{w_{ij}}{d_i}$, where w_{ij} is the weight of the edge (i, j) and d_i is the out-degree of vertex i , i.e. $d_i = \sum_{k \in N(i)} w_{ik}$, where $N(i)$ is the set of out-neighbors of v_i . In this paper, for simplicity we set λ_i as the degree of vertex i , i.e., $\lambda_i = d_i$, and here we also adopt KL-divergence as the distance function. Replacing $d(\cdot, \cdot)$ with KL-divergence, setting $\lambda_i = d_i$ and omitting some constants, we have:

$$O_2 = - \sum_{(i,j) \in E} w_{ij} \log p_2(v_j|v_i). \quad (6)$$




TransE模型

Rome = [1, 0, 0, 0, 0, 0, ..., 0]
Paris = [0, 1, 0, 0, 0, 0, ..., 0]
Italy = [0, 0, 1, 0, 0, 0, ..., 0]
France = [0, 0, 0, 1, 0, 0, ..., 0]


} 任意两两之间相似度为0

TransE模型




TransE模型

TransE直观上，将每个三元组实例 (head, relation, tail) 中的关系relation看做从实体head到实体tail的翻译，通过不断调整h、r 和 t (head、relation和tail的向量)，使 $(h + r)$ 尽可能与 t 相等，即 $h + r = t$



TransH模型

- TransH(Knowledge Graph Embedding by Translating on Hyperplanes. AAAI 2014.)



目标函数:

$$f(h, t) = \|h_{\perp} + r - t_{\perp}\|$$


$$h_{\perp} = h - \omega^T h \cdot \omega$$

$$t_{\perp} = t - \omega^T t \cdot \omega$$

损失函数:

$$L = \sum_{(h,r,t) \in S} \sum_{(h',r',t') \in S'} \max(0, f_r(h, t) + \gamma - f_r(h', t')).$$


知识图谱的存储与查询



知识图谱的存储

名称	存储格式
WikiData	JSon、Rdf、ttl
Freebase	RDF
ConceptNet	JSON- LD
DBPedia	RDF

RDF图模型



RDF图模型查询语言: SPARQL

- ▶ Query Model - **SPARQL Protocol and RDF Query Language**
- ▶ Given U (set of URIs), L (set of literals), and V (set of variables), a SPARQL expression is defined recursively:

- ▶ an atomic triple pattern, which is an element of


$$(U \cup V) \times (U \cup V) \times (U \cup V \cup L)$$

- ▶ $?x$ hasName "Abraham Lincoln"
- ▶ P FILTER R , where P is a graph pattern expression and R is a built-in SPARQL condition (i.e., analogous to a SQL predicate)
 - ▶ $?x$ price $?p$ FILTER($?p < 30$)
- ▶ $P1$ AND/OPT/UNION $P2$, where $P1$ and $P2$ are graph pattern expressions
- ▶ Example:
SELECT ?name
WHERE {
 ?m <bornIn> ?city. ?m <hasName> ?name.
 ?m<bornOnDate> ?bd. ?city <foundingYear> '1718'.
 FILTER(**regex**(**str**(?bd), '1976'))
}

RDF图模型查询语言: SPARQL

```
SELECT ?name
WHERE {
  ?m <bornIn> ?city. ?m <hasName> ?name.
  ?m<bornOnDate> ?bd. ?city <foundingYear> '1718'.
  FILTER(regex(str(?bd), '1976'))
}
```

`FILTER(regex(str(?bd), "1976"))`



详细语法细节参考: <https://www.w3.org/TR/sparql11-query/>

Triple Store存储

- 举例: RDF-3X [Neumann and Weikum, 2008], Hexastore [Weiss et al., 2008]
- Strings are mapped to ids using a mapping table

Original triple table

Subject	Property	Object
y:Abraham_Lincoln	hasName	"Abraham Lincoln"
y:Abraham_Lincoln	bornOnDate	"1809-02-12"
y:Abraham_Lincoln	diedOnDate	"1865-04-15"
y:Washington_DC	hasName	"Washington D.C."
y:Washington_DC	foundingYear	"1790"


Encoded triple table

Subject	Property	Object
0	1	2
0	3	4
0	5	6
7	1	8
7	9	10

Mapping table

ID	Value
0	y:Abraham_Lincoln
1	hasName
2	"Abraham Lincoln"
3	bornOnDate
4	"1809-02-12"
5	diedOnDate
6	"1865-04-15"
7	y:Washington_DC
8	"Washington D.C."
9	foundingYear
10	"1790"

关系数据库局限性




- 关系模型将语义关联关系隐藏在外键结构中，无显示表达，并带来关联查询与计算的复杂性。
- 数据来源多样性带来大量**离群数据 (Outlier Data)**，导致数据集的宏观结构愈发复杂和不规整，对于包含大量离群数据的场景，关系模型将造成大量表连接、稀疏行和非空处理。
- 互联网的开放世界假设要求数据模型满足**高动态和去中心化的扩增数据**的能力，关系模型对表结构的范式要求限制了Schema层的动态性。

Prefix: y=http://en.wikipedia.org/wiki/


Label	adjList
⋮	⋮
y:Reese_Witherspoon	(BornOnDate, "1976-03-22"), (gender, "Female"), (title, "Actress"), (hasName, "Reese Witherspoon"), (BornIn, New_Orleans_LA)
⋮	⋮

0010 1000


Encode all neighbors of a vertex into a bit string
vertex signature



- 自然表达：图是十分自然的描述事物关系的方式，更加接近于人脑对客观事物的记忆方式。
- 易于扩展：图模型更加易于适应变化，例如在图中，临时希望获取历史订单，只需新增边即可。
- 复杂关联表达：图模型易于表达复杂关联逻辑的查询，例如在推荐系统中，希望表达复杂的推荐逻辑，例如：“all the flavors of ice cream liked by people who enjoy espresso but dislike Brussels sprouts, and who live in a particular neighborhood.”
- 多跳优化：在处理多跳查询上，图模型有性能优势。



图数据库查询



Cypher of Neo4J

```
MATCH (a:Person {name:'Jim'})-[:KNOWS]->(b)-[:KNOWS]->(c),  
        (a)-[:KNOWS]->(c)  
RETURN b, c
```


SPARQL of W3C

```
Select ?a,?b,?c where {  
  ?a :KNOWS ?b. ?b :KNOWS ?c.  
  ?a :KNOWS ?c.  
  ?a ISA :Person.  
  ?a :name = "Jim".  
}
```

Gremlin of Apache TinkerPop

```
g.V().has("name", "Jim").  
  out(":KNOWS").  
  out(":KNOWS").  
  values("name")
```



知识图谱的构建



知识抽取



知识抽取



● 命名实体识别

□ 检测： → 库克非常兴奋。

[库克]: 实体

□ 分类： → 库克非常兴奋。

[库克]: 人物

● 术语抽取（概念抽取）

从语料中发现多个单词组成的相关术语。

● 关系抽取

王思聪是万达集团董事长王健林的独子。 → [王健林] <父子关系> [王思聪]

● 事件抽取

据路透社消息，英国当地时间9月15日早8时15分，位于伦敦西南地铁线District Line的Parsons Green地铁站发生爆炸，目前已确定有多人受伤，具体伤亡人数尚不明确。目前，英国警方已将此次爆炸与起火定性为恐怖袭击。

• 恐怖袭击事件



触发词：

发生爆炸

时间：

当地时间9月15日早8时15分

地点：

Parsons Green地铁站

攻击者：

-


伤亡人数：

-

● 规则抽取：IF this THEN that

命名实体识别

- 任务定义: 抽取文本中的原子信息元素, 是进一步实现关系抽取的基础
- 通用领域实体类型举例
 - 人名
 - 组织/机构名
 - 地理位置
 - 时间/日期
 - 字符值
 - 金额值



命名实体识别

北京时间10月25日，骑士后来居上，在主场以119-112击退公牛。

↑
地点

↑
时间

组织

中新社华盛顿10月24日电 美国众议院三个委员会24日宣布将分别展开两项与希拉里·克林顿有关的调查，国会民主党人称这是共和党人试图转移注意力。

↑
人物

- 基于模板和规则的方法
- 基于序列标注的机器学习方法
- 基于深度学习的方法
- 结合迁移学习、对抗学习等新方法


基于模板和规则的方法

- 将文本与规则进行匹配来识别出命名实体
 - “***说”、“***老师”;
 - “***大学”、“***医院”
- 优点:
 - 准确，有些实体识别只能依靠规则抽取
- 缺点:
 - 需要大量的语言学知识
 - 需要谨慎处理规则之间的冲突问题;
 - 构建规则的过程费时费力、可移植性不好。

基于序列标注的方法


	IOB标注体系	IO标注体系		IOB标注体系	IO标注体系
由	O	O	清	B-ORG	I-ORG
浙	B-ORG	I-ORG	华	I-ORG	I-ORG
江	I-ORG	I-ORG	大	I-ORG	I-ORG
大	I-ORG	I-ORG	学	I-ORG	I-ORG
学	I-ORG	I-ORG	的	O	O
的	O	O	李	B-PER	I-PER
张	B-PER	I-PER	大	I-PER	I-PER
小	I-PER	I-PER	大	I-PER	I-PER
小	I-PER	I-PER			
迎	O	O			
战	O	O			

常见模型：CRF (条件随机场)



- ▶ 随机场是由若干个位置组成的整体，当给每一个位置中按照某种分布随机赋予一个值之后，其全体就叫做随机场。
- ▶ 马尔科夫随机场是随机场的特例，它假设随机场中某一个位置的赋值仅与和它相邻的位置的赋值有关，和与其不相邻的位置的赋值无关。
- ▶ 条件随机场是马尔科夫随机场的特例，它假设马尔科夫随机场中只有X和Y两种变量，X一般是给定的，而Y一般是在给定X的条件下的输出。
- ▶ 例如：实体识别任务要求对一句话中的十个词做实体类型标记，这十个词可以从可能实体类型标签中选择，这就形成了一个随机场。如果假设某个词的标签只与其相邻的词的标签有关，则形成马尔科夫随机场，同时由于这个随机场只有两种变量，令X为词，Y为实体类型标签，则形成一个条件随机场。

常见模型：LSTM+CRF



x_i 表示句子的第 i 个字在字典中的id, 进而可以得到每个字的one-hot向量,

中文实体识别特点

- 中文没有自然分词，词的概念很模糊，也不具备英文中的字母大小写等形态特征。
- 中文用字变化多，有些实体不能脱离上下文语境，同一实体在不同语境可能是不同的实体类型。
- 中文多嵌套实体。
- 中文简化表达现象严重。

- 从文本中抽取两个或者多个实体之间的语义关系
- 信息抽取 (Information Extraction)研究领域的任务之一
- 从文本获取知识图谱三元组的主要技术手段

实体关系抽取

中国证券网讯（记者 严政）卓翼科技3月4日晚公告称，公司于近日收到中兴通讯股份有限公司发出的《中标结果》通知，公司在中兴通讯EPON产品、GPON产品招标中均获第二名的份额，预计本次中标总金额约为1.914亿元（不含税），占公司2011年度经审计的营业收入的15.46%。

其中，公司本次中标中兴通讯四个EPON产品类别，中兴通讯预计该四个EPON产品类别2013年全年总量为270万台，根据招标结果，公司中标份额的比例分别为20%、20%、30%、30%，对应的产品总量约为57万台，预计金额为8800万元，占公司2011年度经审计的营业收入的7.11%。



公司A	公司B	关系 (A是B的)	时间	来源
中兴通讯	卓翼科技 (002369)	客户	2013.03.05	中国证券网 公司公告
中兴康讯	Acacia	客户	2015.12.28	OFweek光通讯网行业新闻




Acacia自2011年开始出货高速高效节能产品，目前已拥有20家客户，包括ADVA、中兴康讯和阿尔卡特朗讯。Acacia与阿尔卡特朗讯关系良好——其CEO Raj Shanmugarai曾是阿尔卡特朗讯美国公司的光网络事业部的业务发展副总裁。

基于模板的方法—基于触发词的Pattern


姚明 老婆 叶莉

徐峥 老婆 陶虹  X 老婆 Y

黄晓明 妻子 杨颖  X 妻子 Y  夫妻关系 (X, Y)

刘德华 配偶 朱丽倩  X 配偶 Y

基于模板的方法—基于依存句法的Pattern



1. 对句子进行分词、词性标注、命名实体识别、依存分析等处理
2. 根据句子依存语法树结构上匹配规则，每匹配一条规则就生成一个三元组
3. 根据扩展规则对抽取到的三元组进行扩展
4. 对三元组实体和触发词进一步处理抽取出关系

基于模板的方法—基于依存句法的Pattern

董卿现身国家博物馆看展优雅端庄大方

依存分析结果

词顺序	词	词性	依存关系路径	依存关系
0	董卿	人名	1	定语
1	现身	动词	-1	核心词
2	国家博物馆	地名	1	宾语
3	看	动词	1	顺承
4	展	动词	3	补语
5	优雅	形容词	7	定语
6	端庄	形容词	7	定语
7	大方	形容词	4	宾语

规则抽取结果

(董卿, 现身, 国家博物馆) ➡ 位于(董卿, 国家博物馆)

基于模板的方法—优劣

□ 优点

- 在小规模数据集上容易实现
- 构建简单

□ 缺点

- 特定领域的模板需要专家构建
- 难以维护
- 可移植性差
- 规则集合小的时候，召回率很低

机器学习框架——基于CNN


- 神经网络可以直接encode句子特征

- Lexical level features

实体、实体周边词、实体同义词的连接

Features	Remark
L1	Noun 1
L2	Noun 2
L3	Left and right tokens of noun 1
L4	Left and right tokens of noun 2
L5	WordNet hypernyms of nouns

- Sentence level features $[WF, PF]^T$
WF(word features) : 窗口词, 窗口大小为3
PF(position features) : [d1, d2]



Relation Classification via Convolutional Deep Neural Network(COLING 2014)

机器学习框架——基于CNN

CNN自动抽取关系特征

- 对sentence level 特征进行线性变换（卷积）

$$\mathbf{Z} = \mathbf{W}_1 \mathbf{X} \quad \mathbf{W}_1 \in \mathbb{R}^{n_1 \times n_0} \quad \mathbf{X} \in \mathbb{R}^{n_0 \times t}$$

为卷积核维度（隐藏层节点数），为特征维度，t词数

- 在~上做池化

$$m_i = \max \mathbf{Z}(i, \cdot) \quad 0 \leq i \leq n_1 \quad \mathbf{Z} \in \mathbb{R}^{n_1 \times t}$$

- 非线性变换

$$\mathbf{g} = \tanh(\mathbf{W}_2 \mathbf{m}) \quad \mathbf{W}_2 \in \mathbb{R}^{n_2 \times n_1} \quad \mathbf{m} \in \mathbb{R}^{n_1 \times 1}$$

- 输出层 + softmax


$$\mathbf{o} = \mathbf{W}_3 \mathbf{f} \quad \mathbf{f} = [\mathbf{l}, \mathbf{g}]. \quad \mathbf{W}_3 \in \mathbb{R}^{n_4 \times n_3} \quad \mathbf{f} \in \mathbb{R}^{n_3 \times 1}$$

SemEval-2010 Task 8 , F1 = 82.7

$S : [\text{People}]_0 \text{ have}_1 \text{ been}_2 \text{ moving}_3 \text{ back}_4 \text{ into}_5 [\text{downtown}]_6$

$$\{[\mathbf{x}_s, \mathbf{x}_0, \mathbf{x}_1], [\mathbf{x}_0, \mathbf{x}_1, \mathbf{x}_2], \dots, [\mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_e]\}^5$$

https://blog.csdn.net/m0_38031488



$$p(i|x, \theta) = \frac{e^{o_i}}{\sum_{k=1}^{n_4} e^{o_k}} \quad J(\theta) = \sum_{i=1}^T \log p(y^{(i)}|x^{(i)}, \theta)$$

Relation Classification via Convolutional Deep Neural Network(COLING 2014)

机器学习框架——跨句推理

A是B的爸爸，B的妈妈是C -> A和C是夫妻

- 判断同一个句子中所有实体对的关系:
 - CNN encoder, 得到模型 $E(h, r, t|S) = \max_i p(r|\theta, \mathbf{s}_i)$.
- 找到和h, t均存在关系的实体, 判断间接关系

$$G(h, r, t|p_i) = E(h, r_A, e)E(e, r_B, t)p(r|r_A, r_B)$$


- 训练关系间relation path:
 - Path encoder, 得到r1和r2能推出关系r的概率

$$p(r|r_A, r_B) = \frac{\exp(o_r)}{\sum_{i=1}^{n_r} \exp(o_i)} \quad o_i = -\|\mathbf{r}_i - (\mathbf{r}_A + \mathbf{r}_B)\|_{L_1}$$

- 定义(h, t)总关系

$$L(h, r, t) = E(h, r, t|S) + \alpha G(h, r, t|P),$$

$$J(\theta) = \sum_{(h, r, t)} \log(L(h, r, t))$$



Test Settings(Noise)	75%				85%				95%			
P@N(%)	10%	20%	50%	F1	10%	20%	50%	F1	10%	20%	50%	F1
CNN+rand	86.7	67.0	38.9	57.5	84.6	66.4	37.5	55.0	79.9	61.8	35.2	51.4
CNN+max	86.0	68.5	38.3	57.2	85.4	67.6	37.7	56.5	84.4	66.0	36.6	54.8
Path+rand	89.4	71.7	39.9	59.3	88.2	70.2	39.0	58.1	86.0	67.2	37.0	55.6
Path+max	89.0	71.5	39.8	59.6	89.0	71.4	39.6	59.4	88.6	71.0	39.1	59.1

Incorporating Relation Paths in Neural Relation Extraction(EMNLP 2017)

机器学习框架——多元关系


- 传统的二元关系扩展的缺点
 - 产生 $C(n,2)$ 种特征组合
 - 拆分成多个binary会丧失多元语义联系
- 学习出所有实体的表示，连接后分类
 - 能表示所有实体对的全局关系
- Graph LSTM :
 - Chain LSTM : 按照time-step输入后一个词
 - Tree LSTM : 按照time-step输入当前语法依赖词
 - Graph LSTM : 节点同时依赖上一时刻不同的语法依赖词和线性输入词，重新定义一个维度表示当前依赖种类

$$i_t = \sigma(W_i x_t + \sum_{j \in P(t)} U_i \times_T (h_j \otimes e_j) + b_i)$$

$$f_{tj} = \sigma(W_f x_t + U_f \times_T (h_j \otimes e_j) + b_f)$$


$$o_t = \sigma(W_o x_t + \sum_{j \in P(t)} U_o \times_T (h_j \otimes e_j) + b_o)$$

Cross-Sentence N-ary Relation Extraction with Graph LSTMs(TACL 2017)



Model	Single-Sent.	Cross-Sent.
Feature-Based	74.7	77.7
CNN	77.5	78.1
BiLSTM	75.3	80.1
Graph LSTM - EMBED	76.5	80.6
Graph LSTM - FULL	77.9	80.7

机器学习框架——联合抽取



Miwa et. al ACL 2016

半监督学习—远程监督

两个实体如果在知识库中存在某种关系，则包含该两个实体的非结构化句子均能表示出这种关系。


在某知识库中存在：创始人(乔布斯, 苹果公司)

则可构建训练正例：乔布斯是苹果公司的联合创始人和CEO


具体步骤

1. 从知识库中抽取存在关系的实体对
2. 从非结构化文本中抽取含有实体对的句子作为训练样例

知识图谱的应用



知识推理




Infer ➔

New facts
New relations
New axioms
New rules

- 基于描述逻辑的推理（如DL-based）
- 基于图结构和统计规则挖掘的推理（如：PRA、AMIE）
- 基于知识图谱表示学习的推理（如：TransE、GCN）
- 基于概率逻辑的方法（如：Statistical Relational Learning）

基于图结构和统计规则挖掘的推理



$hasChild(A,B) \Rightarrow hasParent(B,A)$

$marryTo(A,B) \Rightarrow marryTo(B,A)$


$marryTo(A,B) \wedge hasChild(A,C) \Rightarrow hasChild(B,C)$

$marryTo(A,B) \wedge livesIn(A,C) \Rightarrow livesIn(B,C)$

主要方法:

- 基于路径排序学习方法(PRA, Path ranking Algorithm)
- 基于关联规则挖掘方法(AMIE)

基于知识图谱表示学习的关系推理




Representation Learning

- 将实体和关系都表示为向量
- 通过向量之间的计算代替图的遍历和搜索来预测三元组的存在，由于向量的表示已经包含了实体原有的语义信息，计算含有一定的推理能力。
- 可应用于链接预测，基于路径的多度查询等。

In this section, we provide theoretical motivation for a specific graph-based neural network model $f(X, A)$ that we will use in the rest of this paper. We consider a multi-layer Graph Convolutional Network (GCN) with the following layer-wise propagation rule:

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}\right). \quad (2)$$




$$A: \begin{bmatrix} 0. & 1. & 1. & 0. \\ 1. & 0. & 1. & 0. \\ 1. & 1. & 0. & 1. \\ 0. & 0. & 1. & 0. \end{bmatrix}$$

$$\tilde{A} = A + I_N: \begin{bmatrix} 1. & 1. & 1. & 0. \\ 1. & 1. & 1. & 0. \\ 1. & 1. & 1. & 1. \\ 0. & 0. & 1. & 1. \end{bmatrix}$$

$$\tilde{D}: \begin{bmatrix} 3. & 0. & 0. & 0. \\ 0. & 3. & 0. & 0. \\ 0. & 0. & 4. & 0. \\ 0. & 0. & 0. & 2. \end{bmatrix}$$

$$\tilde{D}^{-\frac{1}{2}}: \begin{bmatrix} 0.57735027 & 0. & 0. & 0. \\ 0. & 0.57735027 & 0. & 0. \\ 0. & 0. & 0.5 & 0. \\ 0. & 0. & 0. & 0.70710678 \end{bmatrix}$$



(a) Graph Convolutional Network

类别:

1.最后一层GCN的隐层特征数等于类别数,直接使用softmax输出概率

2.在输出的 F 维特征后,再接一个全连接层,训练标签

语义搜索



美国现任总统的夫人




百度一下

找到相关图片约255,000张 版权 高清 最新 动图 全部尺寸 ∨ 全部颜色 ∨


Q 相关搜索: 现任美国总统是谁 墨西哥总统的夫人 美国总统夫人今年几岁 各国总统夫人合影 美国历任总统 蒙古国总统的夫人 缅甸现任总统夫人 蒙古国总统夫人



文本分类




预训练



Embedding Representation

Token	[CLS]	Tim	Cook	CEO	Apple	is	visiting	Beijing	capital	China	is_a	City	now
Token embedding	+	+	+	+	+	+	+	+	+	+	+	+	+
Soft-position embedding	0	1	2	3	4	3	4	5	6	7	6	7	6
Segment embedding	A	A	A	A	A	A	A	A	A	A	A	A	A


Sentence Tree





问答交互


对话式的信息获取更加需要精准度和可靠度，知识图谱对于提升用户体验更加不可少。




DUER OS
Conversational AI OS for everyone and everywhere



个性化推荐





论文推荐



大数据分析



大数据分析



- ▶ 语义集成: Dynamic Ontology
- ▶ 语义搜索: 围绕Ontology来搜索发现结果和关系;
- ▶ 知识管理: 所有的知识是有权限控制的;
- ▶ 协作: 知识可以在不同的用户之间共享, 协同工作;
- ▶ 算法引擎: 对于通用领域问题, 提供了通用算法来发现趋势。

大数据分析



当一个人听到或看到一句话的时候，他使用自己所有的知识和智能去理解。这不仅包括语法，也包括他的词汇知识、上下文知识，更重要的，是对相关事务的理解。

--Terry Winograd (自然语言理解系统SHRDLU作者)

WINOGRAD SCHEMA CHALLENGE


I. The trophy would not fit in the brown suitcase because **it** was too big (small). What was too big (small)?

Answer 0: the trophy Answer 1: the suitcase

II. The town councilors refused to give the demonstrators a permit because **they** feared (advocated) violence. Who feared (advocated) violence?

Answer 0: the town councilors Answer 1: the demonstrators

典型知识图谱项目




- Cyc是在1984年由Douglas Lenat开始创建。最初的目标是要建立人类最大的常识知识库。典型的常识知识如“Every tree is a plant”，“Plants die eventually”等。
- Cyc知识库主要由术语Terms和断言Assertions组成。Terms包含概念、关系和实体的定义。Assertions用来建立Terms之间的关系，这既包括事实Fact描述，也包含规则Rule的描述。
- 最新的Cyc知识库包含有50万条Terms和700万条Assertions。Cyc的主要特点是基于形式化的知识表示方法来刻画知识。形式化的优势是可以支持复杂的推理。但过于形式化也导致知识库的扩展性和应用的灵活性不够。Cyc提供开放版本OpenCyc。

- WordNet是最著名的词典知识库，主要用于词义消歧。WordNet 由普林斯顿大学认识科学实验室从1985年开始开发。
- WordNet主要定义了名词、动词、形容词和副词之间的语义关系。例如名词之间的上下位关系（如：“猫科动物”是“猫”的上位词），动词之间的蕴含关系（如：“打鼾”蕴含着“睡眠”）等。
- WordNet3.0已经包含超过15万个词和20万个语义关系。

ConceptNet

- ConceptNet是常识知识库。最早源于MIT媒体实验室的Open Mind Common Sense (OMCS)项目。OMCS项目是由著名人工智能专家Marvin Minsky于1999年建议创立。
- ConceptNet主要依靠互联网众包、专家创建和游戏三种方法来构建。新版本导入大量开放的结构化数据，如DBPedia、Wikinary，Wordnet等
- ConceptNet知识库以三元组形式的关系型知识构成。ConceptNet5版本已经包含有2800万关系描述。与Cyc相比，ConceptNet采用了非形式化、更加接近自然语言的描述，而不是像Cyc那样采用形式化的谓词逻辑。
- 与链接数据和谷歌知识图谱相比，ConceptNet比较侧重于词与词之间的关系。从这个角度看，ConceptNet更加接近于WordNet，但是又比WordNet包含的关系类型多。此外，ConceptNet完全免费开放，并支持多种语言。

采用CC BY SA开放许可协议



ConceptNet

An open, multilingual knowledge graph



Freebase



通过开源免费吸引用户贡献数据，增值的应用及技术服务收费

WikiData

目标是构建全世界最大的免费知识库，采用CC0完全自由许可协议



维基基金会

导入维基数据



开放社区贡献



相对小众、专业、严格的众包社区

提供资金



谷歌

导入Freebase数据



摩尔基金会


提供资金

提供资金




Allen AI Institute

开放知识图谱



Linked Open Data





全球人工智能学者 知识图谱: **kg4ai**

实体 2,034
关系 16,998
三元组 26,981

[下载](#)

农业 知识图谱: **agriculture**

实体 32,967
关系 122,795
三元组 188,916

[下载](#)

百科人物 知识图谱: **people**

实体 913,111
关系 5,298,430
三元组 8,980,390

[下载](#)

佛学 知识图谱: **buddism**

实体 8,661
关系 41,511
三元组 64,862

[下载](#)

七律 知识图谱: **7Lore**

实体 8,618,115
关系 46,089,861
三元组 77,815,063

[下载](#)

二次元 知识图谱: **ACGN**

实体 299,302
关系 1,255,018
三元组 2,751,026

[下载](#)

一带一路 知识图谱: **OneBeltAndRoad**

实体 14,308
关系 1,290,747
三元组 2,447,378

[下载](#)

'知识图谱领域 知识图谱: **kg4openkg**

实体 658
关系 1,713
三元组 4,445

[下载](#)

法律 知识图谱: **legal**

实体 26,990
关系 120,736
三元组 330,603


[下载](#)

清华Xlore 知识图谱: **xlore**

实体 1,597,798
关系 6,988,697
三元组 14,654,430

[下载](#)

扩展：认知图谱





认知图谱



Question: Who is the director of the 2003 film which has scenes in it filmed at the Quality Cafe in Los Angeles?

1-hop

Quality Cafe
(jazz club)

Quality Cafe was a historical restaurant and jazz club...

Quality Cafe (diner)

location featured in a number of Hollywood films, including "Old School", "Gone in 60 Seconds"...

Los Angeles

Los Angeles officially the City of Los Angeles and often known by its initials L.A.,...

2-hop

Old School (film)

Old School is a 2003 American comedy film... directed by Todd Phillips.

Gone in 60 Seconds

Gone in 60 Seconds is a 2000 American action heist film... directed by Dominic Sena.


3-hop

Todd Phillips

correct answer

Dominic Sena

认知图谱



谢谢！

