



大语言模型

Large Language Model

基于人类反馈的强化学习 RLHF

阶段一：监督微调 (SFT)

收集示范数据，有监督训练。收集高质量的问答对，让模型通过模仿学习知道"这样回答是好的"。

阶段二：建立奖励模型 (RM)

收集比较数据，训练奖励模型。人类标注者会对同一问题的不同回答进行比较和排序，然后用这些数据训练一个“评分”模型，能预测"人类会更喜欢哪个回答"。

阶段三：强化学习 (RL)

利用第二步训练的奖励模型作为指导，对模型进行优化。每当模型生成一个回答，奖励模型就会给出评分，模型根据这个信号不断调整自己的策略，逐渐生成更符合人类偏好的内容。

A large white number '2' is positioned on the left side of the image, set against a green background. A horizontal green band runs across the middle of the image, containing the text 'Scaling Law' and '“大力出奇迹”'.

Scaling Law

“大力出奇迹”

Scaling Law

规模化法则（Scaling Law）是人工智能描述模型性能与模型规模、训练数据集大小及计算资源之间可预测关系的经验性规律，被业界视为大模型预训练的核心原则。

其数学关系通常遵循幂律分布，表现为模型性能随规模扩大呈现边际效益递减特征，亦称“缩放定律”或“规模定律”。


幂律分布

幂律分布是指某个具有分布性质的变量，且其分布密度函数是幂函数。幂律分布表现为一条斜率为幂指数的负数的直线，

符合幂律分布的事物各个因素之间是相互联系，相互影响的。




马太效应，长尾效应，二八法则

极少数的关键事物带来绝大多数的收益，其他大多数普通事物只获得少量收益。






Scaling Law

2020年, OpenAI发表论文《Scaling Laws for Neural Language Models》
损失值随着模型规模、训练数据量、训练计算量的增加, 呈现出幂律下降的趋势。



Scaling Law


模型的最终性能主要与计算量，模型参数量和数据大小三者相关，而与模型的具体结构(层数/深度/宽度)基本无关。




Scaling Law

大型模型比小型模型具有更高的样本效率，可以用更少的数据达到相同的性能水平。
大型模型比小型模型具有更好的算力利用效率。

Larger models require **fewer samples** to reach the same performance



The optimal model size grows smoothly with the loss target and compute budget



Scaling Law

- ✓ 影响模型性能的三要素：计算量、参数、数据集


每个要素会受到另外两个要素的影响。当没有其他两个瓶颈时，性能会急剧上升，影响程度为计算量 > 参数 > 数据集。

- ✓ 在固定计算预算下，最佳性能：训练参数量大的模型并在远离饱和点前停止(Early Stopping)。
- ✓ 更大的模型在样本效率方面表现更好，能以更少的优化步骤和使用更少的数据量达到相同的性能水平。

Scaling Law - Chinchilla


训练计算利用率最优的LLM：

在固定计算预算下，**模型参数量和训练tokens数量应该随着计算的增加而等比例增加**，数据量（以token计）与模型参数量应保持约20:1的比例关系。



Scaling Law - Chinchilla



- ✓对于给定的FLOP预算，不是模型越大越好。在给定的计算量下，数据量和模型参数量之间的选择平衡存在一个最优解。
- ✓在计算成本达到最优情况下，模型大小和训练数据 (token) 的数量应该等比例进行缩放。对于给定参数量的模型，最佳的训练数据大小约为模型参数量的20倍。
- ✓大模型训练需要更加关注数据集的扩展，但是只有数据是高质量的时候，更大数据集的益处才能体现出来。



MoEs混合专家模型

Mixed Expert Models



MoEs架构



MoEs架构



•**稀疏 MoE 层**: 包含多个专家, 每个专家本身是一个独立的神经网络。专家可以是前馈网络 (FFN)、或更复杂的网络结构, 甚至可以是 MoE 层本身 (层级式 MoE 结构)。

•**门控网络或路由**: 决定哪些令牌 (token) 被发送到哪个专家。令牌的路由方式是 MoE 的关键点, 路由器由学习的参数组成, 与网络的其他部分一同预训练。




MoE的特点

- ✓ 稀疏性
- ✓ 预训练速度更快
- ✓ 推理速度更快
- ✓ 显存需求大
- ✓ 微调方面的挑战



MoE的专家选择与路由机制

Top-K 专家选择策略 (K常见1-4)



DeepSeekMoE

• **路由专家 (Routed Experts) :**
每个 MoE 层包含 256 个路由专家, 这些专家主要负责处理输入中某些特定、专业化的特征。

• **共享专家 (Shared Expert) :**
每个 MoE 层中还有 1 个共享专家, 用于捕捉通用的、全局性的知识, 为所有输入提供基本的特征提取支持。




Figure 2 | Illustration of the basic architecture of DeepSeek-V3. Following DeepSeek-V2, we adopt MLA and DeepSeekMoE for efficient inference and economical training.

MoE总结

混合专家模型 (Mixture of Experts, MoE)

核心结构包含三部分：

1. 专家网络池：由N个独立专家子网络组成，每个专家专注于特定数据分布

2. 门控网络：采用轻量级神经网络（通常为单层MLP）计算输入样本与各专家的匹配度，输出概率分布向量

3. 动态路由机制：根据门控网络输出，选择Top-k个专家进行激活（k通常取1-4），未被选中的专家不参与计算

计算效率的提升：通过动态路由机制实现高效训练和快速推理

- **条件计算：**激活Top-k专家，使理论计算量降低至 $O(N/k)$

- **参数扩展性：**在大参数规模下，推理速度较Dense模型提升数倍

- **能耗优化：**实验显示，在相同精度下MoE架构的GPU利用率较传统模型提升30%

模型容量的扩展：通过增加专家数量而非模型深度

- **线性参数增长：**专家数量可扩展至数千个

- **知识专业化：**不同专家自动学习不同数据特征

- **灾难性遗忘缓解：**专家间的低耦合性减少知识覆盖冲突