

深度学习

主讲：刘夏雷、郭春乐、王亚星
南开大学计算机学院

致谢：本课件主要内容来自浙江大学吴飞教授、
南开大学程明明教授

下面对误差反向传播 (error back propagation, BP)描述不正确的是 ()

- ☐ A BP算法是一种将输出层误差反向传播给隐藏层进行参数更新的方法
- ☐ B BP算法将误差从后向前传递, 获得各层单元所产生误差, 进而依据这个误差来让各层单元修正各单元参数
- ☐ C 对前馈神经网络而言, BP算法可调整相邻层神经元之间的连接权重大小
- ☒ D 在BP算法中, 每个神经元单元可包含不可偏导的映射函数

提交

下面对前馈神经网络这种深度学习方法描述不正确的是（ ）

- ☐ A 是一种端到端学习的方法
- ☐ B 是一种监督学习的方法
- ☐ C 实现了非线性映射
- ☒ D 隐藏层数目大小对学习性能影响不大

提交

请问深度学习和传统的机器学习有什么区别？从数据大小、硬件要求、特征构建和解决问题方式等方面出发。

数据：深度学习适合处理大数据，机器学习算法更适用于小数据；

硬件：深度学习由于巨大的计算量，需要大量计算资源，比如GPU，机器学习算法对计算资源的需求相对较低；

特征构建：深度学习试图从数据中学习特征，机器学习中许多特征都需要由行业专家确定，并手工构造；

解决问题方式：深度学习通常利用“端到端”的方式构建模型，机器学习通常将问题分为几个步骤，每个步骤逐一解决，然后将结果组合。

作答

在前馈神经网络中，所有的参数能否被初始化为0？
如果不能，能否全部被初始化为其他相同的值？
为什么？

不能初始化为0，也不能被同时初始化为其他相同的值。
如果参数被初始化为相同的值后，在误差反向传播过程中，同一层的神经元所接收到的误差都相同，更新后这些参数的值仍然相同。不管经过多少轮迭代，同一层神经元的输出保持相同，因此不同的神经元无法学习到不同特征的重要程度，失去了深度神经网络学习特征的能力。

作答

练习题

题目：手工计算一个简单神经网络的反向传播

考虑一个简单的单隐藏层前馈神经网络，如下：

- 输入： $x = [x_1, x_2]$
- 隐藏层（1个神经元）：
 - 权重： w_1, w_2
 - 偏置： b
 - 激活函数： $\text{ReLU}(z) = \max(0, z)$
- 输出层：
 - 权重： w_3
 - 偏置： b_2
 - 输出激活函数：恒等映射（即不加激活）
- 损失函数：平方损失 $L = \frac{1}{2}(y_{\text{pred}} - y_{\text{true}})^2$

网络计算过程：

1. 计算隐藏层输出： $z = w_1x_1 + w_2x_2 + b$, $a = \text{ReLU}(z)$
2. 计算输出层输出： $y_{\text{pred}} = w_3a + b_2$

已知数值如下：

- 输入 $x_1 = 1, x_2 = 2$
- 初始参数 $w_1 = 0.5, w_2 = -0.5, b = 0, w_3 = 1, b_2 = 0$
- 真实标签 $y_{\text{true}} = 1$

要求：

1. 手工计算前向传播得到 y_{pred} 和损失 L 。
2. 手工推导并计算各参数的梯度：
 - $\frac{\partial L}{\partial w_1}, \frac{\partial L}{\partial w_2}, \frac{\partial L}{\partial b}, \frac{\partial L}{\partial w_3}, \frac{\partial L}{\partial b_2}$
3. （选做）给出参数使用学习率 $\eta = 0.1$ 更新后的新值。

提示


- $\frac{dL}{dy_{\text{pred}}} = y_{\text{pred}} - y_{\text{true}}$
- 对 ReLU, $\frac{da}{dz} = \begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases}$
- 链式法则：一层一层往回传导梯度

提纲


- 深度学习历史发展
- 前馈神经网络
- 卷积神经网络
- 循环神经网络
- 注意力机制与Transformer
- 深度学习应用与研讨

从前馈神经网络到卷积神经网络

- 三层前馈神经网络





- 卷积神经网络(convolution neural network, CNN)



卷积神经网络 (CNN)

- 前馈神经网络中，输入层的输入直接与第一个隐藏层中所有神经元相互连接。



卷积神经网络 (CNN)


- 前馈神经网络中，输入层的输入直接与第一个隐藏层中所有神经元相互连接。
 - 如果输入数据是一幅 $1000*1000$ 的图像，即1,000,000维的向量，考虑输入数据与第一个隐藏层（与输入维度一致）中所有神经元均相连，则输入层到第一个隐藏层之间有 10^{12} 个参数。

卷积神经网络 (CNN)

- 前馈神经网络中，输入层的输入直接与第一个隐藏层中所有神经元相互连接。
 - 如果输入数据是一幅 $1000*1000$ 的图像，即1,000,000维的向量，考虑输入数据与第一个隐藏层（与输入维度一致）中所有神经元均相连，则输入层到第一个隐藏层之间有 10^{12} 个参数。
 - 模型参数数量如此巨大不仅会占用大量计算机内存，同时也使神经网络模型变得难以训练收敛。因此，对于图像这样的数据，不能直接将所构成的像素点向量与前馈神经网络神经元相连。


卷积神经网络 (CNN)

- 人脑 “视觉系统的信息处理” 这一机制
 - 即可视皮层对外界信息是分级感受的
 - 1959年，David Hubel和Torsten Wiesel发现



卷积神经网络 (CNN)

- 卷积神经网络的前身：满足平移不变性的网络Neocognitron
 - 1980年Kunihiko Fukushima, 将神经科学所发现的结构进行了计算机模拟, 提出级联方式 (cascade, 即逐层滤波)




卷积神经网络 (CNN)

- **图像中像素点具有很强的空间依赖性**
 - 卷积就是针对像素的空间依赖性来对图像进行处理的一种技术。

卷积神经网络 (CNN)


- 在图像卷积计算中，需要定义一个卷积核（kernel）
 - 卷积核是一个二维矩阵，矩阵中数值为对图像中与卷积核同样大小的子块像素点进行卷积计算时所采用的权重。



卷积核

卷积神经网络 (CNN)


- 卷积核中的权重系数 w_i 是通过数据驱动机制学习得到
 - 用来捕获某像素点及其邻域像素点所构成的特有空间模式。
 - 一旦从数据中学习得到权重系数，这些权重系数就刻画了图像中像素点构成的空间分布不同模式。



卷积神经网络：卷积操作

- 图像经过特定卷积矩阵滤波后，所得到的卷积结果可认为是保留了像素点所构成的特定空间分布模式

卷积神经网络：卷积操作示意



练习题：理解卷积核作用

- 题目：下列哪种功能不太可能通过单个小尺寸卷积核直接实现？
 - A. 边缘检测
 - B. 模糊滤波
 - C. 全图统计
 - D. 特征平滑

练习题：理解卷积核作用

- 题目：下列哪种功能不太可能通过单个小尺寸卷积核直接实现？
 - A. 边缘检测
 - B. 模糊滤波
 - C. 全图统计
 - D. 特征平滑
- 答案：C
- 解释：单个小卷积核集中处理局部区域，难以直接实现全图尽管统计

练习题：卷积与全连接层对比


- 题目：相较于全连接层，卷积层在图像处理中具有哪些优势？
(多选)
 - A. 参数更少
 - B. 能保留空间结构信息
 - C. 训练速度更慢
 - D. 更容易过拟合

练习题：卷积与全连接层对比

- 题目：相较于全连接层，卷积层在图像处理中具有哪些优势？
(多选)
 - A. 参数更少
 - B. 能保留空间结构信息
 - C. 训练速度更慢
 - D. 更容易过拟合
- 答案：A, B
- 解释：卷积层具有局部联通和参数共享特性，适合处理图像


卷积神经网络：卷积操作

7*7大小的图像，通过3*3大小卷积矩阵，以1的步长进行卷积操作，可得到5*5大小的卷积结果




卷积神经网络：卷积操作

7*7大小的图像，通过3*3大小卷积矩阵以1的步长进行卷积操作，可得到5*5大小的卷积结果




卷积神经网络：卷积操作

7*7大小的图像，通过3*3大小卷积矩阵以1的步长进行卷积操作，可得到5*5大小的卷积结果




卷积神经网络：卷积操作

7*7大小的图像，通过3*3大小卷积矩阵以1的步长进行卷积操作，可得到5*5大小的卷积结果





卷积神经网络：卷积操作

7*7大小的图像，通过3*3大小卷积矩阵以1的步长进行卷积操作，可得到5*5大小的卷积结果





卷积神经网络：卷积操作

如果步长改为2





卷积神经网络：卷积操作

如果步长改为2



卷积神经网络：卷积操作

如果步长改为2



思考题：如何计算卷积结果的分辨率


- 图像大小 $\omega \times \omega$
- 卷积核大小为 $F \times F$
- Padding为 P
- 步长为 S
- 结果： $(\omega - F + 2P) / S + 1$

练习题: 卷积计算基础

- **题目：**已知输入图像为 5×5 大小，卷积核为 3×3 ， $\text{stride} = 1$ ， $\text{padding} = 0$ ，请问输出 feature map 大小为？
 - A. 5×5
 - B. 3×3
 - C. 2×2
 - D. 1×1
- **答案：** B
- **解释：** $\text{Output size} = (5 - 3)/1 + 1 = 3$


卷积神经网络：卷积操作

有一张 $32*32*3$ (RGB) 的图像，使用 $5*5*3$ 的卷积核 W_1 ，步长为1对其进行卷积操作。卷积核 W_1 在原始图像上从左到右、从上到下进行计算，得到 $28*28$ 的特征图 m_1




卷积神经网络：卷积操作

使用另一个 $5*5*3$ 的卷积核 W_2 与原始图像做卷积操作，得到特征图 m_2



卷积神经网络：卷积操作

- 使用6个 $5 \times 5 \times 3$ 的卷积核与原始图像做卷积操作，则得到6个 28×28 的特征图
- 注意:6个 $5 \times 5 \times 3$ 的卷积核均是数据驱动学习得到，其刻画了不同的视觉模式




练习题: 可训练参数计算

- **题目:** 一个卷积层使用了16个3x3的卷积核, 输入通道数为3, 如果忽略 bias, 该层共有多少个可训练参数?
 - A. 432
 - B. 144
 - C. 4320
 - D. 160
- **答案:** A
- **解释:** $3 \times 3 \times 3 = 27$, 每个卷积核 27 个参数, 共有 16 个, 总计 $16 \times 27 = 432$

卷积神经网络：卷积+激活函数(非线性映射)

在对原始图像做卷积操作后，可使用ReLU激活函数对卷积后结果进行处理，继续卷积。



卷积神经网络：卷积操作

- 神经科学家发现，人的视觉神经细胞对不同的视觉模式具有特征选择性（Feature Selectivity）

练习题：感受野

- **题目：**下列关于感受野的说法，哪一项是正确的？
 - A. 感受野仅与卷积核大小有关
 - B. 卷积层堆加不会改变感受野
 - C. 越向后置的层，感受野越大
 - D. 感受野是固定不变的
- **答案：** C
- **解释：** 层级越深，即对应于输入图像的范围越大，感知的信息越广

卷积神经网络：池化(pooling)操作

- 对输入的特征图进行下采样，以获得最主要信息

卷积神经网络：最大池化操作

在输入特征图中每一个区域寻找最大值。

1	5	4	3
2	6	4	0
3	1	7	9
2	8	6	5

对2*2大小区域，按照步长为2进行最大池化操作



6	4
8	9

卷积神经网络：平均池化操作

对输入特征图的每一个区域的值求平均值（取整）


1	5	4	3
2	6	4	0
3	1	7	9
2	8	6	5

对2*2大小区域，按照步长为2进行平均池化操作




3	2
3	6

卷积神经网络：池化操作



由于图像中存在较多冗余，在图像处理中，可用某一区域子块的统计信息（如最大值或均值等）来刻画该区域中所有像素点呈现的空间分布模式，以替代区域子块中所有像素点取值，这就是卷积神经网络中池化(pooling)操作。池化操作对卷积结果特征图进行约减，实现了下采样，同时保留了特征图中主要信息。

卷积神经网络：池化操作



对于输入的海量标注数据，通过多次迭代训练，卷积神经网络在若干次卷积操作、接着对卷积所得结果进行激活函数操作和池化操作下，最后通过全连接层来学习得到输入数据的特征表达，即**分布式向量表达(distributed vector representation)**。

卷积神经网络：padding操作

对特征进行填充，一般用0


0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

Kernel


0	-1	0
-1	5	-1
0	-1	0

114				


卷积神经网络：全连接层与分类层



卷积神经网络基本架构




卷积神经网络



算力




数据



大模型算法

体现了数据、模型和算力的结合



模拟人脑




Alex Krizhevsky, et.al., **ImageNet Classification with Deep Convolutional Neural Networks**

神经网络正则化

为了缓解神经网络在训练过程中出现的过拟合问题，需要采取一些**正则化技术**来提升神经网络的泛化能力 (generalization)

- Dropout
- Batch-Normalization
- L1-Norm & L2-Norm




L_1 范数：数学表示为 $\|W\|_1 = \sum_{i=1}^N |w_i|$ ，指模型参数 W 中各个元素的绝对值之和。 **L_1 范数**也被称为“稀疏规则算子” (Lasso regularization) 。

L_2 范数：数学表示为 $\|W\|_2 = \sqrt{\sum_{i=1}^N w_i^2}$ ，指模型参数 W 中各个元素平方和的开方。

提纲

- 深度学习历史发展
- 前馈神经网络
- 卷积神经网络
- 循环神经网络
- 注意力机制与Transformer
- 深度学习应用与研讨

循环神经网络（RNN）



循环神经网络（RNN）


- 循环神经网络（Recurrent Neural Network, RNN）是一类**处理序列数据（如文本句子、视频帧等）**时所采用的网络结构。先前所介绍的前馈神经网络或卷积神经网络所需要处理的输入数据一次性给定，难以处理存在**前后依赖关系的数据**。

循环神经网络（RNN）

- 循环神经网络在处理数据过程中构成了一个循环体
 - 对于序列数据，在 t 时刻循环神经网络单元会读取当前输入数据 x_t 和前一时刻输入数据 x_{t-1} 所对应的隐式编码结果 h_{t-1} ，一起生成 t 时刻的隐式编码结果 h_t 。接着将 h_t 后传。

循环神经网络（RNN）

- 在处理数据过程中构成了一个循环体
 - 时刻 t 所得到的隐式编码 h_t 是由上一时刻隐式编码 h_{t-1} 和当前输入 x_t 共同参与生成的。
- 隐式编码 h_{t-1} 已经“记忆”了 t 时刻之前的时序信息。或者说前序时刻信息影响了后续时刻信息的处理。




循环神经网络（RNN）

- 在处理数据过程中构成了一个循环体

- 对当前输入数据 x_t ，RNN会结合 $t-1$ 时刻的隐式编码 h_{t-1} ，产生当前隐式编码 h_t ：

$$h_t = \Phi(U \times x_t + W \times h_{t-1})$$

- 这里 $\Phi(\cdot)$ 是激活函数，可为Sigmoid或者Tanh，使模型能够忘掉无关的信息，同时更新记忆内容。U与W为模型参数。
- 当前时刻的隐式编码输出 h_t 不仅仅与当前输入数据 x_t 相关，与网络已有的“记忆” h_{t-1} 也有着密不可分的联系。



循环神经网络（RNN）

- 为了更加直观展示在循环神经网络中前序时刻信息被“记住”来影响当前时刻信息编码，这里对上述公式进行如下变化：

$$h_t = \Phi(U \times x_t + W \times h_{t-1}) = \Phi(U \times x_t + W \times \Phi(U \times x_{t-1} + W \times h_{t-2}))$$


$$= \Phi \left(U \times \underbrace{x_t}_{t\text{时刻输入}} + W \times \Phi \left(U \times \underbrace{x_{t-1}}_{t-1\text{时刻输入}} + W \times \Phi \left(U \times \underbrace{x_{t-2}}_{t-2\text{时刻输入}} + \dots \right) \right) \right)$$

- 当前时刻编码中，的确均包含了历史信息，这也说明了循环神经网络能够记忆的原因，使得一些需要记忆历史过往信息的任务能够被循环神经网络有效处理。

循环神经网络（RNN）


- 将RNN展开，可以得到和前馈神经网络相似的网络结构。

- 这个网络结构可利用反向传播算法和梯度下降算法来训练参数，称为“沿时间反向传播算法(backpropagation through time, BPTT)”。
- 由于RNN每个时刻都有一个输出，所以在计算循环神经网络的损失时，通常需将所有时刻上的损失进行累加。



循环神经网络（RNN）

- 单词之间存在前后依赖，这种依赖会被有效利用起来，得到各自单词的隐式编码以及句子的向量表达。



提纲

- 深度学习历史发展
- 前馈神经网络
- 卷积神经网络
- 循环神经网络
- 注意力机制与Transformer
- 深度学习应用与研讨

研讨内容

- 选题：图像超分、图像生成、图像分类、目标检测等
- 组队：3人
- 提交报告：问题描述、每篇文章核心内容、相互联系等
- 文档工具：基于latex编写，使用overleaf在线共享
https://nankai.feishu.cn/file/SovubR3AToVdZoxXSFkc7jUCnrT?from=from_copylink
- 截止日期：2025年6月15日23：59
- 组队信息递交时间：2025年5月19日23：59

研讨内容

- 自选选题：任何
- 组队：3人
- 提交报告：问题描述、每篇文章核心内容、相互联系等
- 文档工具：基于latex编写，使用overleaf在线共享
https://nankai.feishu.cn/file/SovubR3AToVdZoxXSFkc7jUCnrT?from=from_copylink
- 截止日期：2025年6月15日23：59
- 组队信息递交时间：2025年5月19日23：59

图像分类和目标定位


Classification

Localization

Object Detection



...



...

Car

(x, y, w, h)

Eagle, Fish

Single Object

Multi Objects

图像分类




Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." *Advances in neural information processing systems* 25 (2012).

图像分类


- **[ResNet]** He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." *CVPR* 2016.
- **[Swin Transformer]** Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, Baining Guo. "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows." *ICCV* 2021
- **[MAGE]** Tianhong Li, Huiwen Chang, Shlok Kumar Mishra, Han Zhang, Dina Katabi, Dilip Krishnan, MAGE: MAsked Generative Encoder to Unify Representation Learning and Image Synthesis, CVPR 2023

目标检测




Girshick, Ross. "Fast r-cnn." *Proceedings of the IEEE international conference on computer vision*. 2015.


图像分类和目标定位



图像分类和目标定位



图像分类和目标定位



目标检测

- **[EfficientDet]** Mingxing Tan, Ruoming Pang, Quoc V. Le.
EfficientDet: Scalable and Efficient Object Detection, CVPR2020.
- **[DETR]** Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, Sergey Zagoruyko, End-to-End Object Detection with Transformers, ECCV2020 .
- **[DetCLIPv2]** Lewei Yao, Jianhua Han, Xiaodan Liang, Dan Xu, Wei Zhang, Zhenguo Li, Hang Xu. "DetCLIPv2: Scalable Open-Vocabulary Object Detection Pre-training via Word-Region Alignment." CVPR2023.

图像超分辨率重建


图像分辨率是一组用于评估图像中蕴含细节信息丰富程度的性能参数，包括时间分辨率、空间分辨率及色阶分辨率等，体现了成像系统实际所能反映物体细节信息的能力。相较于低分辨率图像，高分辨率图像通常包含更大的像素密度、更丰富的纹理细节及更高的可信赖度。但在实际上情况中，受采集设备与环境、网络传输介质与带宽、图像退化模型本身等诸多因素的约束，我们通常并不能直接得到具有边缘锐化、无成块模糊的理想高分辨率图像。



部分图片和文字来自网络：https://blog.51cto.com/u_15404184/4323223

图像超分辨率重建

图像的超分辨率重建技术指的是将给定的**低分辨率图像**通过特定的算法**恢复成相应的高分辨率图像**。具体来说，图像超分辨率重建技术指的是利用数字图像处理、计算机视觉等领域的相关知识，借由特定的算法和处理流程，从给定的低分辨率图像中重建出高分辨率图像的过程。



图像超分辨率重建

基于深度学习的超分辨率重构算法：

1. Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[C]//European conference on computer vision. Springer, Cham, 2014: 184-199.
2. Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1646-1654.
3. Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.

图像生成

生成模型是一种训练模型进行无监督学习的模型，给模型一组数据，希望从数据中学习到信息后的模型能够生成一组和训练集尽可能相近的数据。图片生成模型就是更具体的指向说给模型一组图片作为训练集让模型进行学习，希望模型生成一组和训练集图片尽可能相近的图片。



利用DCGAN生成动漫人脸实例，分别为0，100，200次迭代结果。

部分图片和文字来自网络：https://blog.csdn.net/like_red/article/details/79192374

https://blog.csdn.net/qq_34739497/article/details/79902356

图像生成

图像生成经典算法：

1. Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. NeurIPS 2014.
2. Yang Song, Diederik P. Kingma, How to Train Your Energy-Based Models. arXiv 2021.
3. Tim Salimans, Andrej Karpathy, Xi Chen, Diederik P. Kingma, PixelCNN++: Improving the PixelCNN with Discretized Logistic Mixture Likelihood and Other Modifications, arxiv 2021.

图像编辑

利用生成模型，对用户提供的图像做各种个性化的操作。



input: "A man with a beard wearing glasses and a beanie in blue shirt"



"A man with a beard wearing **glasses** and a beanie in blue shirt"



"A man with a **beard** wearing glasses and a beanie in blue shirt"



"A man with a beard wearing glasses and a **beanie** in blue shirt"



Input: "Yoshua Bengio with beard"



"Yoshua Bengio with **beard**"



Input: "Yoshua Bengio with glasses"



"Yoshua Bengio with **glasses**"

图像编辑

图像编辑经典算法：

1. Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, Björn Ommer. High-Resolution Image Synthesis with Latent Diffusion Models, CVPR 2022.
2. Lvmin Zhang, Anyi Rao, Maneesh Agrawala. Adding Conditional Control to Text-to-Image Diffusion Models. ICCV2023.
3. Senmao Li, Joost van de Weijer, Taihang Hu, Fahad Shahbaz Khan, Qibin Hou, Yaxing Wang, Jian Yang. Get What You Want, Not What You Don't: Image Content Suppression for Text-to-Image Diffusion Models. ICLR2024.

低光增强算法

原始图像文件（RAW图像文件）包含从数字相机、扫描器或电影胶片扫描仪的图像传感器所处理数据。由于传感器排列不能重叠，因此通常是单通道数据。此外相较于RGB图像的8Bit存储格式，RAW数据可以存储更多位也意味着更丰富的细节，在低光场景下有着极大的优势。相机中内置的图像信号处理流水线（Image Signal Processing Pipeline, ISP Pipeline）可以将RAW图像转化为常见的RGB图像，细节可参考 *附件：图像信号处理流水线仿真*。由于传感器记录的数据与接收到的光子数量呈正相关关系，因此RAW数据的像素值与曝光时间成正比。




图1: 排列方式为BGGR的传感器

低光增强算法

低光场景下的成像往往会遇到光照条件不足、信噪比低的情况。基于RGB的方法由于ISP的影响，其噪声模型被破坏，因此最近的研究主要聚焦于光照条件的调节，如图2所示。对于RAW数据来讲，由于其噪声分布更为原始，因此通常可以处理更加极端的低光环境，如图3所示。




图2: 基于RGB图像的低光增强算法




图3: 基于RAW图像的低光增强算法

低光增强算法

基于深度学习的低光增强算法：

- Guo C, Li C, Guo J, et al. Zero-reference deep curve estimation for low-light image enhancement[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 1780-1789.
- Jin X, Han L H, Li Z, et al. Dnf: Decouple and feedback network for seeing in the dark[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 18135-18144.
- Jin X, Xiao J W, Han L H, et al. Lighting every darkness in two pairs: A calibration-free pipeline for raw denoising[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 13275-13284.

高质量视频修复

- 高质量的视频内容：**高时域连续性**、**高清晰度**、**高帧率**
- 视频内容生成**质量**依赖于**视频超分**、**补全和插帧**算法



高质量视频修复

基于深度学习的高质量视频修复算法：

- Li Z, Lu C Z, Qin J, et al. Towards an end-to-end framework for flow-guided video inpainting[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 17562-17571.
- Li Z, Zhu Z L, Han L H, et al. Amt: All-pairs multi-field transforms for efficient frame interpolation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 9801-9810.
- Zhou S, Yang P, Wang J, et al. Upscale-A-Video: Temporal-Consistent Diffusion Model for Real-World Video Super-Resolution[J]. arXiv preprint arXiv:2312.06640, 2023.

连续学习

- 什么是连续学习？
 - 机器学习模型像人类大脑一样连续更新
- 挑战：灾难性遗忘 (Catastrophic forgetting)
- **Continual learning / Lifelong learning / Incremental learning**




活到老
学到老

国家重大项目牵引

1.2 面向开放环境的自适应感知（2018年）



1.2 连续学习理论和方法（2021年）



考核指标：研究建立针对知识和数据相融合的不断学习理论和模型；围绕不少于 3 个具有代表性任务场景，构建基准测试数据集；实现零样本和小样本学习，学习方法鲁棒可靠和可验证；实现不断学习过程中知识稳定增扩；开源学习数据、模型和软件框架等，开源成果下载量和注册使用等方面具有一定影响力。

连续学习（continual learning）

基于深度学习的连续学习算法：

1. Rebuffi, Sylvestre-Alvise, et al. "**icarl: Incremental classifier and representation learning.**" Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2017.
2. Dhar, Prithviraj, et al. "**Learning without memorizing.**" Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019.
3. Zhai, Jiang-Tian, et al. "**Masked autoencoders are efficient class incremental learners.**" Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023.

更多前沿课题选择

- 通用目标检测：从经典到前沿
- 洞见隐微：红外弱小目标检测
- 面向下游任务的多模态图像融合
- 事件相机：多模态融合与目标检测
- 迈向大一统：非对齐多模态目标检测
- 回归本源：RAW 图像重建与目标检测
- 视觉语言大模型：模型加速与高效微调
- 克服极限：恶劣环境下的视觉感知与处理
- 轻量化与高效部署：深度学习模型的实用之旅
- 事件相机多模态融合：迈向更鲁棒、更全面的感知
- 遥感感知模型
- 多模态图像生成
- 图像重建与恢复
- 大语言模型 Agent
- 人像属性细粒度编辑
- 图像恢复的优化理论
- 小样本图像分割与分类
- 持续学习：从基础到前沿
- 伪装目标检测：从方法到认知
- 扩散式生成模型：从噪声到图像
- 发生在成像之前：RAW 数据噪声建模与去噪

下载链接: <https://pan.baidu.com/s/1mckWP4gdD9PR6thPvKnVGw?pwd=grok>

报名链接

每组由组长填写，每组只填一次，三人一组。

* 1. 选择课程报告题目

- ☐ 图像超分
- ☐ 图像生成
- ☐ 图像分类
- ☐ 目标检测
- ☐ 图像编辑
- ☐ 低光增强
- ☐ 连续学习
- ☐ 高质量视频修复

* 2. 组长

* 3. 组员

* 4. 组员



2025人工智能导论课程 报告分组-刘夏雷



长按图片扫码

谢谢!