



机器学习导论

第6章 机器学习模型评估

谢茂强

南开大学软件学院

01. 机器学习回顾

02. 机器学习预测结果的评估

- 准确率、查准率、查全率、 F_1 Measure、ROC和AUC
- 差异显著性检验

03.


- 其他：调参、代价敏感错误率、代价敏感分类器

机器学习模型评估环境搭建和分析

- 训练误差、验证/测试误差
- 交叉检验
- 通过学习曲线调整模型

1.回顾机器学习定义


- **Definition**[Tom Mitchell, 1997]: A computer program is said to *learn* from *experience* E with respect to some class of *tasks* T and *performance measure* P, if its performance at tasks in T, as measured by P, improves with experience E.
- **Machine Learning** Addresses the question of how to *build computer programs that improve their performance at some task through experience.*



- 目的：利用预测模型 $y=h(\mathbf{x})$ 或 $\text{argmax}_k\{P(y_k|\mathbf{x})\}$ ，为用户提供的 $\mathbf{x}$ 预测输出 y
- 预测模型从何而来：从历史经验（带专家标注的训练数据 $\{(\mathbf{x}_i, y_i)\}, i=1, 2, \dots, m$ ）中学习

机器学习模型的性能评估

- 工程 v.s. 科学
- 量化评估是工程的基石
- 个人认为机器学习是体现自身优化最直观的技术
- 实验能力



01. 机器学习回顾

02. 机器学习预测结果的评估

- 准确率、查准率、查全率、 F_1 Measure、ROC和AUC
- 差异显著性检验

03.

- 其他：调参、代价敏感错误率、代价敏感分类器

机器学习模型的评估环境搭建

- 训练误差、验证/测试误差
- 交叉检验
- 通过学习曲线调整模型

2.1 预测准确率(Accuracy)

将 $err(h_{\Theta}(x), y)$ 的返回值控制在 $\{0, 1\}$,那么

$$\text{Accuracy} = \left(1 - \frac{1}{m} \sum_{i=1}^m err(h_{\Theta}(x^{(i)}, y^{(i)}))\right) \times 100\%$$

使用标注和预测结果的组合进行评估

样本的标注 y : 样本的真实输出(Ground Truth)

样本的预测结果 $f(x)$: 机器学习模型对样本的预测输出(Prediction)

		Predicted condition	
Total population		Predicted Condition positive	Predicted Condition negative
True condition	condition positive	True positive	False Negative (Type II error)
	condition negative	False Positive (Type I error)	True negative

该矩阵也被称为混淆矩阵(confusion matrix)

混淆矩阵的4种组合



		Predicted condition	
		Predicted Condition positive	Predicted Condition negative
True condition	condition positive	True positive	False Negative (Type II error)
	condition negative	False Positive (Type I error)	True negative

TP: True Positive,被判定为正样本，事实上也是正样本。

TN: True Negative,被判定为负样本，事实上也是负样本。

FN: False Negative,被判定为负样本，但事实上是正样本。

FP: False Positive,被判定为正样本，但事实上是负样本。

（相对地，用户更为关心positive结果和true样本的重合度）

2.2 查准率与查全率 (Table 2.1 P.30)

Precision: 查准率，即在**分类器预测出的正例中**，真正正确的个数占整个结果的比例。

$$Precision = \frac{TP}{TP + FP}$$

Recall: 查全率，即在预测结果中真正正确的个数**占整个标注数据集中正例个数**的比例。

$$Recall = \frac{TP}{TP + FN}$$

查准率与查全率曲线(PR Curve)

• Precision和Recall相矛盾

- 使用阈值(threshold)决定判别, 如LR, NN
- 想将所有感兴趣的样本识别出来, 需要降低阈值, 扩大接受范围
- 想提高识别感兴趣样本的查准率, 需要提高阈值, 提高拒绝率




图 2.3 P-R曲线与平衡点示意图

- Precision和Recall相矛盾
 - 好的方法应该能够尽量包住对比方法的P-R曲线
 - 平衡点 (Break-Event Point)
“查准率=查全率”时的取值可以用来作为衡量分类器性能的指标之一




图 2.3 P-R曲线与平衡点示意图

相比于P-R曲线的平衡点， F_1 度量更为专业一些，它是 precision和recall的调和平均（harmonic mean），最差为0，最好为1

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}$$

调和平均（harmonic mean）又叫倒数平均

$$H_n = \frac{n}{\frac{1}{a_1} + \frac{1}{a_2} + \dots + \frac{1}{a_n}}$$


ROC: Receiver Operating Characteristic

预测方法:

- 1) 使用阈值 (阈值确认风险大)
- 2) 使用排序 (搜索引擎v.s.问答系统)

排序做法:

将最可能的正例排在前, 最不可能是正例的排在后面, 通过cut-point区分预测结果是否为正




2.3 ROC曲线

- 通过不断调整分割点，使用排序更能全方位反映分类器性能。
- ROC曲线则可以用来评估不同分割点下的排序性能

Y轴: $TPR = TP / (TP + FN)$

X轴: $FPR = FP / (FP + TN)$

- 偏向左上好，偏向右下不好



True positive	False Negative (Type II error)
False Positive (Type I error)	True negative

AUC(Area Under Curve) of ROC


若随机抽取一个true样本和一个false样本，AUC表示分类器接受true样本高于接受false样本的概率

AUC取值在0~1之间

AUC值越大的分类器，
正确率越高


AUC=1

+ valor diagnóstico perfecto




AUC=0,8

+ valor diagnóstico



AUC=0,5

+ sin valor diagnóstico



ROC曲线

A

TP=63	FP=28	91
FN=37	TN=72	109
100	100	200

TPR = 0.63

FPR = 0.28

ACC = 0.68

B

TP=77	FP=77	154
FN=23	TN=23	46
100	100	200

TPR = 0.77

FPR = 0.77

ACC = 0.50

C

TP=24	FP=88	112
FN=76	TN=12	88
100	100	200

TPR = 0.24

FPR = 0.88

ACC = 0.18


C'

TP=76	FP=12	88
FN=24	TN=88	112
100	100	200

TPR = 0.76

FPR = 0.12

ACC = 0.82



梯形法计算AUC


梯形法（trapezoid method）：简单地将每个相邻的点以直线连接，计算连线下方的总面积。因为每一线段下方都是一个梯形，所以叫梯形法。

可以看作积分




具体实现：随着FP的增加，累加TP

Recall@K与AUROC@K的示例

强调头部性能的意义



(A) 100-fold Cross-validation



(B) Test Data

2.4 差异显著性检验(Student's T-Test)

主要用于判断所提方法(proposed method)与基准方法(baseline methods)之间的性能差异是否显著 (significantly)

例如：这些方法在多个任务（数据集）上的性能结果作比较。

$\text{mean}(\text{PM}) > \text{mean}(\text{BM})$, 则对 $[h, p, ci] = \text{ttest2}(\text{PM}, \text{BM})$;

- 当 $h=1$ 时, 表明可以从统计上断定算法A1的结果大于A2的结果 (即两组数据均值的比较是有意义的)
- $h=0$ 则表示不能根据平均值来断定两组数据的大小关系 (因为区分度小)

2.5 不同类型的错误代价不一样

例1. “将患者诊断为健康人” 和 “把健康人诊断为患者”
的后果不同

例2. “降低信用评估标准贷款” 和 “提高信用评估标准拒绝
贷款” 的后果不同

之前提到的算法将不同类型的错误赋予 “等价错误”

2.5 代价矩阵

- 以二分类为例，可以计算不同类型的错误，将FP和FN分别计算，记为 cost_{10} 和 cost_{01} 。
- 解决方法
 - 按照任务的关注，选择 cost_{ij} 小的模型
 - 按照任务关注，调整损失函数

表 2.2 二分类代价矩阵

真实类别	预测类别	
	第 0 类	第 1 类
第 0 类	0	cost_{01}
第 1 类	cost_{10}	0

2.5 代价敏感(Cost Sensitive)的错误率

$$E(f; D; cost) = \frac{1}{m} \left(\sum_{\mathbf{x}_i \in D^+} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{01} + \sum_{\mathbf{x}_i \in D^-} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{10} \right) .$$

- 代价敏感的分类算法或排序算法：更改代价函数

目录

01. 机器学习回顾

02. 机器学习预测结果的评估

- 准确率、查准率、查全率、 F_1 Measure、ROC和AUC
- 其他：调参、代价敏感错误率、代价敏感分类器

03. 机器学习模型的评估环境搭建

- 训练误差、验证/测试误差
- 交叉检验
- 通过学习曲线调整模型

- Training/Empirical Error

$$\text{Training Error} = \frac{1}{m_{train}} \sum_{i=1}^{m_{train}} err(h_{\Theta}(x_{train}^{(i)}), y_{train}^{(i)}) \quad \text{训练模型参数}$$

$$\text{CV Error} = \frac{1}{m_{CV}} \sum_{i=1}^{m_{CV}} err(h_{\Theta}(x_{CV}^{(i)}), y_{CV}^{(i)}) \quad \begin{array}{l} \text{选择超参数} \\ \text{(HyperParameter)} \end{array}$$


- Test/Generalization Error(这个体现模型的真实性能)

$$\text{Test Error} = \frac{1}{m_{test}} \sum_{i=1}^{m_{test}} err(h_{\Theta}(x_{test}^{(i)}), y_{test}^{(i)})$$

Evaluating your hypothesis

Dataset:

	Size	Price	
	2104	400	60% Training set
	1600	330	
	2400	369	
	1416	232	
	3000	540	
	1985	300	
	1534	315	20% Cross validation set (CV)
	1427	199	
	1380	212	20% test set
	1494	243	



3.2 交叉验证Cross Validation

- 目的：使用现有数据集获得更好的模型和更全面的性能评估

- N-fold Cross-Validation (Fig. 2.2, page 26)**

将整个训练数据集划分成 n 份，选取其中一份作为验证数据集，其余 $n-1$ 份作为训练数据集。

进行轮换让每一份数据都有机会作为验证数据集。尽可能避免 overfitting

- **Leave One Out Cross-Validation**

是N-fold Cross-Validation的特例，每个样本都当作一份验证数据集

10折交叉验证示意




图 2.2 10 折交叉验证示意图

10-fold Cross-Validation

10折交叉验证的示例代码

```
for i = 1 : loop↓
    read_begin = round((i - 1) * rows / loop) + 1;↓
    read_end = round(i * rows / loop);↓

    ↓

    tmp_buffer = g_p_network(read_begin : read_end, :);↓
    g_p_network(read_begin : read_end, :) = 0;↓

    ↓

    tmpR = birw_mn(phenotype_logistic, ppi_network, g_p_network, m, n, alpha,

    ↓

    R(read_begin:read_end, :) = tmpR(read_begin:read_end, :);↓

    ↓

    g_p_network(read_begin : read_end, :) = tmp_buffer;↓

    ↓

end↓
```



- 是N-fold Cross-Validation的特例，每个样本都当作一份验证数据集
- 对于耗时不是很长的，建议使用LOOCV

3.3 使用学习曲线(Learning curves)来反映模型的学习程度

(或拟合训练和验证数据的程度)


$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$





$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$$

3.3使用学习曲线展示欠拟合(Underfit, High bias)




- 模型太简单，在训练数据和验证数据上错误率都高
- 错误率高的情形不会因为训练数据集规模扩大而改善




3.3使用学习曲线展示过拟合(高方差)

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \cdots + \theta_{100} x^{100}$$

(and small λ)



- 过拟合：模型复杂，且训练数据和验证数据分布差异大
- 扩大训练数据集规模（主要是让其分布更接近验证数据集）对解决过拟合很有帮助



- 机器学习回顾
- 机器学习预测结果的评估
 - 准确率、查准率、查全率、 F_1 Measure、ROC和AUC
 - 其他：调参、代价敏感错误率、代价敏感分类器
- 机器学习模型的评估环境搭建
 - 训练误差、验证/测试误差
 - 交叉检验
 - 通过学习曲线调整模型