



机器学习导论

第7章 贝叶斯分类器

谢茂强

南开大学软件学院

目录

01. 贝叶斯公式
02. 朴素贝叶斯分类器 (Naïve Bayes Classifier)
03. 贝叶斯信念网 (Bayes Belief Network)
04. 贝叶斯与语言模型(Language Model)
05. 极大似然估计(Maximum Likelihood Estimation)
06. EM（期望最大化）算法

基于概率模型的分类器（回顾）

- 定义

- X: 图像集合=



- Y: 识别结果集合={0, 1, 9, M, z}

- 任务: 估计以下的概率

- $P(Y=0 \mid x=\text{9})=0.01$
 - $P(Y=1 \mid x=\text{9})=0.02$
 - $P(Y=9 \mid x=\text{9})=0.95$
 - $P(Y=M \mid x=\text{9})=0.01$
 - $P(Y=z \mid x=\text{9})=0.01$

- 选择最大估计概率对应的Y作为预测结果
 - 也可以使用函数来 $y = f(x)$ 表示, 其中

$$f(\mathbf{x}) = \arg \max_{c \in \{0,1,9,M,z\}} P(y = c | \mathbf{x})$$

1. 贝叶斯公式 (1763年)

- 由条件概率公式

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$



$$P(A \cap B) = P(A | B)P(B) = P(B | A)P(A)$$

- 可得贝叶斯公式 $P(A | B) = \frac{P(B | A)P(A)}{P(B)}$

- 全概率公式: $P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$

1.从预测角度看估计后验概率 $P(c | \boldsymbol{x})$

$$P(c | \boldsymbol{x}) = \frac{P(c, \boldsymbol{x})}{P(\boldsymbol{x})} = \frac{P(c)P(\boldsymbol{x}|c)}{P(\boldsymbol{x})}$$

$P(\boldsymbol{x})$: 样本 $\boldsymbol{x}$ 在样本空间中出现的概率

$P(\boldsymbol{x}|c)$: 代表样本 $\boldsymbol{x}$ 相对于类别 c 的类条件概率 (class-conditional probability) , 或称为似然 (likelihood)

$P(c)$: $\mathcal{Y}$ 中各 $c \in \mathcal{Y}$ 的先验概率

2. 朴素贝叶斯分类器(Naïve Bayes Classifier)

- 在估计 $P(\mathbf{x}|c)$ 时很难估计 $\mathbf{x}$ 所有维联合发生的概率，原因在于很难用频率估计概率，因此，通过假设“各维度条件独立”，将联合概率的估计变成各维度概率连乘。

$$P(c|\mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c)$$

2.朴素贝叶斯分类器的判决函数

- 由于对于给定 x , 其 $P(x)$ 对于所有 $c \in \mathcal{Y}$ 是一样的。
- 朴素贝叶斯的判决函数简化为:

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

2. 类先验概率、类条件概率的估计

$P(c)$: 使用样本空间中各类样本所占比重来估计。根据大数定理，当训练集包含充足的独立同分布样本时，可使用高频率来估计概率。

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c) = \prod_{i=1}^d P(x_i|c)$$

直接使用样本出现频率来估计对关于 所有特征的联合概率将会遇到严重困难——很多种取值未在训练集中出现。（“未被观测到” v.s. “出现概率为0”）

假设样本 d 维特征都是二值的。联合随机事件数 2^d ，独立的事件数 $2d$

2. 判决函数中的各概率的估计

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

- 类先验概率: $P(c) = \frac{|D_c|}{|D|}$
- 类条件概率:
(离散属性) $P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$

2. 判决函数中的各概率的估计

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

- 类先验概率: $P(c) = \frac{|D_c|}{|D|}$
- 类条件概率: $P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp \left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2} \right)$
(连续属性)
- 第 c 类样本在第 i 个属性上取值的 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$

2. 参数化方法估计类条件概率

- 形式上简单
- 估计的准确性严重依赖于“假设是否成立”
- 实际应用中需要融合任务本身的经验知识，用先验知识引导类条件概率的分布假设。

2.估计 $P(x|c)$ 和 $P(c)$ 时碰到的问题

- 训练样本不充足，导致概率估计为零。
- 可以进行“平滑” smoothing。比如拉普拉斯修正 (Laplacian Correction)

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N} ,$$

N : 数据集中的类别数

$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i} .$$

N_i : 第 i 维特征的可能取值数

2.总结：朴素Bayes分类器的训练算法

1. 数据预处理（特征的离散化，样本分布与样本采集）
2. 估计每个类别的类先验概率 $P(c)$
3. 估计每个类别条件下各特征下每种取值出现的概率 $P(x_i|c)$

2. 总结：朴素Bayes分类器的预测算法

1. 数据预处理(按照训练的预处理方法进行)
2. 利用预计算好的 $P(c)$ 和 $P(\mathbf{x}_i|c)$, 根据贝叶斯公式为每个类别 c 计算

$$P(c|\mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c)$$

3. 选择最大后验概率对应的类别作为结果输出。

2. 从最小化风险的角度来看NB

训练Naïve Bayes其实也是寻找判别模型 $h : \mathcal{X} \mapsto \mathcal{Y}$ 以最小化总体风险

$$R(h) = \mathbb{E}_{\mathbf{x}}[R(h(\mathbf{x})|\mathbf{x})]$$

基于 $P(c_i|\mathbf{x})$ ，可获得将样本 $\mathbf{x}$ 分类为 c_i 所产生的条件风险（或损失）

$$R(c_i|\mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j|\mathbf{x})$$

$$\lambda_{ij} = \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise.} \end{cases}$$

Bayes Decision Rule: 为最小化总体风险，只需在每个样本上选择使条件风险 $R(c|\mathbf{x})$ 最小的类别标记，即

$$h^*(\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} R(c | \mathbf{x})$$

h^* : Bayes Optimal Classifier, 对应的总体风险 $R(h^*)$ 被称为 Bayes Risk。 $1 - R(h^*)$ 是通过机器学习所能产生的模型精度的理论上限。

插播：贝叶斯分类器是生成式模型

- 生成式模型 (Generative Models)
 - 需要对生成样本的分布进行建模(如下述3个分布), 然后估计 $P(c | \mathbf{x})$

$$P(\mathbf{x}, c) \quad P(\mathbf{x} | c) \quad P(c)$$

- 判决式模型 (Discriminative Models)
 - 直接建模 $P(y = c | \mathbf{x})$ (即直接求解判决模型(参数))

目录

01. 贝叶斯公式
02. 朴素贝叶斯分类器 (Naïve Bayes Classifier)
03. 贝叶斯信念网 (Bayes Belief Network)
04. 贝叶斯与语言模型(Language Model)
05. 极大似然估计(Maximum Likelihood Estimation)
06. EM（期望最大化）算法

3. 贝叶斯信念网(Bayes Belief Network)

- 使用条件概率表 (Conditional Probability Table, CPT) 来描述属性的联合概率分布。




图 7.2 西瓜问题的一种贝叶斯网结构以及属性“根蒂”的条件概率表

$$P(x_1, x_2, x_3, x_4, x_5) = P(x_1)P(x_2)P(x_3|x_1)P(x_4|x_1, x_2)P(x_5|x_1)$$

Bayesian Information Criterion



A statistical
method



Helps identify the best
model among a set of
available options



Used in hypothesis
testing and model
selection

3. 贝叶斯信念网的特点

- 多维变量中联合概率估计时属性组合爆炸问题，对样本分布和样本量要求剧增
- 样本稀疏导致概率估计值为0的问题
- 朴素贝叶斯分类器属性条件独立性假设不满足的问题
 - 只需各类条件概率排序正确、无需精准概率值即可
 - 若属性间依赖对所有类别影响相同，或依赖关系的影响能够相互抵消，则假设不符合对性能影响不大
 - 在信息检索领域中，应用效果很好

目录

01 贝叶斯公式

02 朴素贝叶斯分类器 (Naïve Bayes Classifier)

03 贝叶斯信念网 (Bayes Belief Network)

04 贝叶斯与语言模型(Language Model)

05 极大似然估计(Maximum Likelihood Estimation, MLE)

06 EM（期望最大化）算法

4. 语言模型(Language Model)

- 语言模型的核心是估计句子(Sentence)被生成的概率

$$\begin{aligned}P(S) &= P(w_1, w_2, w_3, \dots, w_k) \\&= P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \dots P(w_k|w_{k-1}, w_{k-2} \dots w_1)\end{aligned}$$

其中，句子 S 由单词 w_i 组合而成。

- 条件概率估计对样本量的需求巨大，例如，在估计下述概率得0可能性很大

$$P(w_k|w_{k-1}, w_{k-2} \dots w_1)$$

4. N-gram for Language Model

Markov 假设:下一个词出现的概率仅依赖前面一个或几个词

- 1-gram (Unigram,不依赖前面的词)

$$P(S) = P(w_1)P(w_2)P(w_3) \cdots P(w_k)$$

- 2-gram (Bigram,依赖前面一个词)

$$P(S) = P(w_1)P(w_2|w_1)P(w_3|w_2) \cdots P(w_k|w_{k-1})$$

- 3-gram (Trigram,依赖前面两个词)

$$P(S) = P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \cdots P(w_k|w_{k-1}, w_{k-2})$$

4.文本情感分类 (Sentiment Classification)



基于贝叶斯公式和语言模型

- 该问题可建模为二分类问题

1 : 正向情感、0 : 负向情感

$$Sentiment = \frac{P(Y = 1|S)}{P(Y = 0|S)} = \frac{P(S|Y = 1)P(Y = 1)}{P(S|Y = 0)P(Y = 0)}$$

- 使用语言模型N-gram来估计 $P(Y = 1|S)$

5. 参数估计: Frequentist v.s. Bayesian

- 频率主义学派(Frequentist)
 - 认为参数未知, 但客观存在一个定值
 - 通过极大似然估计 (Maximum Likelihood Estimation) 确定概率模型参数
- 贝叶斯学派(Bayesian)
 - 参数是未观测到的随机变量, 本身可能也有分布。
 - 可假设参数服从一个分布, 然后使用数据估计参数的后验分布。

两派区别: 参看教材的参考文献[Efron, 2005]和[Samaniego, 2010]

5. 极大似然估计

- 概率分布的参数估计(parameter estimation)
 - 先假定某随机事件的概率符合某种确定的分布形式，可基于抽样数据（训练数据）对概率分布的参数进行估计。
 - 从机器学习的角度可以将参数估计看成模型训练
- 对于NB所需的 $P(\boldsymbol{x}|c)$ ，可假设其形式，且被参数 θ_c 唯一确定，那么使用训练集训练概率模型的任务，其实就是数理统计中的估计参数 θ_c

5. 极大似然估计

• 以估计类条件概率分布为例

令 D_c 表示训练集 D 中第 c 类样本组成的集合, 假设这些样本是独立同分布的, 则参数 θ_c 对于数据集 D_c 的似然是

$$P(D_c | \theta_c) = \prod_{x \in D_c} P(x | \theta_c) . \quad (7.9)$$

对 θ_c 进行极大似然估计, 就是去寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$. 直观上看, 极大似然估计是试图在 θ_c 所有可能的取值中, 找到一个能使数据出现的“可能性”最大的值.

5.Log-likelihood: 对似然进行对数化

式(7.9)中的连乘操作易造成下溢, 通常使用对数似然(log-likelihood)

$$\begin{aligned} LL(\boldsymbol{\theta}_c) &= \log P(D_c \mid \boldsymbol{\theta}_c) \\ &= \sum_{\boldsymbol{x} \in D_c} \log P(\boldsymbol{x} \mid \boldsymbol{\theta}_c) , \end{aligned} \quad (7.10)$$

此时参数 $\boldsymbol{\theta}_c$ 的极大似然估计 $\hat{\boldsymbol{\theta}}_c$ 为

$$\hat{\boldsymbol{\theta}}_c = \arg \max_{\boldsymbol{\theta}_c} LL(\boldsymbol{\theta}_c) . \quad (7.11)$$

极大对数似然估计的特点


- 每一个样本均是由同一个分布相互独立生成。
 - 生成整个数据集的联合概率是生成每个样本概率的乘积
- 使用对数似然可以将连乘化为连加

$$p(X | \Theta) = \prod_{i=1}^N p(x_i | \Theta) \quad \Rightarrow \quad \ln p(X | \Theta) = \sum_{i=1}^N \ln p(x_i | \Theta)$$


- 遏制概率连乘导致的浮点数下溢
- 概率密度中如有指数项，使用对数似然有利计算

对数似然不影响单调，最大似然处参数相同

$$p(x | \Theta_1) > p(x | \Theta_2) \Leftrightarrow \ln p(x | \Theta_1) > \ln p(x | \Theta_2)$$



(a) $f(x) = x$



(b) $f(x) = \ln(x)$

<https://blog.csdn.net/songyunlililil>

因为相同的单调性，它确保了概率的最大对数值出现在与原始概率函数相同的点上。因此，可以用更简单的对数似然来代替原来的似然。

- 估计正态分布的参数: μ σ
- 教材 “3.3 Logistic回归” 中, 使用极大似然法估计代价函数的参数
 - P59
 - 对比本课2.2节 “基于交叉熵的代价函数”。

6. EM算法

- 最初解决数据缺失条件下的参数估计问题
- 思路
 - 用现有数据估计分布（模型参数）
 - 用估计的分布（模型参数）估计缺失数据
 - 整合原有数据和补齐数据重新估计分布
 - 反复迭代直至收敛
- 目前：认为分布未被现有观测数据完全体现，存在隐含变量，因此，在分布参数估计时要考虑隐含变量的存在。

- 分布生成的未被观测的随机事件用 Z 表示

$$P(X|\theta) = P(X, Z|\theta) = \sum_Z P(X|Z, \theta)P(Z|\theta)$$

- 使用极大似然法估计模型参数

$$\hat{\theta} = \arg \max_{\theta} \ln P(X, Z|\theta)$$

6. EM算法

交替执行E步和M步，直至收敛到局部最优解

- E步(Expectation):

- 基于 Θ^t 推断因变量Z的期望，记为 Z^t

$$Q(\Theta|\Theta^t) = \mathbb{E}_{Z|X, \Theta^t} LL(\Theta|X, Z)$$

- M步(Maximization):

- 寻找参数最大化期望似然

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta|\Theta^t)$$

6. EM算法用途

- EM算法多用于高斯混合模型的参数估计
 - 隐变量是样本属于混合模型中的某个高斯分布
- 隐变量估计
 - 在极大似然估计因隐变量存在失效时，可以考虑用EM算法
- 典型应用：高斯混合模型(Gaussian Mixture Model)

高斯混合模型将在本课第10章中讲解，也可参看教材9.4.3节

4.2 Gaussian Mixture Model

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
高斯混合成分个数 k .

过程:

- 1: 初始化高斯混合分布的模型参数 $\{(\alpha_i, \mu_i, \Sigma_i) \mid 1 \leq i \leq k\}$
- 2: **repeat**
- 3: **for** $j = 1, 2, \dots, m$ **do**
- 4: 根据式(9.30)计算 $\mathbf{x}_j$ 由各混合成分生成的后验概率, 即
 $\gamma_{ji} = p_{\mathcal{M}}(z_j = i \mid \mathbf{x}_j) \ (1 \leq i \leq k)$
- 5: **end for**



- 6: **for** $i = 1, 2, \dots, k$ **do**
- 7: 计算新均值向量: $\mu'_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}};$
- 8: 计算新协方差矩阵: $\Sigma'_i = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu'_i)(x_j - \mu'_i)^T}{\sum_{j=1}^m \gamma_{ji}};$
- 9: 计算新混合系数: $\alpha'_i = \frac{\sum_{j=1}^m \gamma_{ji}}{m};$
- 10: **end for**
- 11: 将模型参数 $\{(\alpha_i, \mu_i, \Sigma_i) \mid 1 \leq i \leq k\}$ 更新为 $\{(\alpha'_i, \mu'_i, \Sigma'_i) \mid 1 \leq i \leq k\}$
- 12: **until** 满足停止条件
- 13: $C_i = \emptyset \ (1 \leq i \leq k)$
- 14: **for** $j = 1, 2, \dots, m$ **do**
- 15: 根据式(9.31)确定 x_j 的簇标记 λ_j ;
- 16: 将 x_j 划入相应的簇: $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$
- 17: **end for**
- 输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$
-

- 贝叶斯理论
- 朴素贝叶斯分类器 (Naïve Bayes Classifier)
- 贝叶斯信念网 (Bayes Belief Network)
- 贝叶斯与NLP中的语言模型(Language Model)
- 极大似然估计(Maximum Likelihood Estimation, MLE)
- EM（期望最大化）算法