



机器学习导论

第8章 集成学习

谢茂强

南开大学软件学院

- 多分类器系统(Multi-Classifier System)
- 基于委员会的学习(Committee-based Learning)




图 8.1 集成学习示意图

01. 集成学习（个体与集成）
02. Boosting与AdaBoost
03. Bagging 与 Bootstrap抽样
04. Stacking

- 个体和集体的优缺点
- 集体的一种分类
 - 同质集成学习 (Homogeneous EL)
 - 异质集成学习 (Heterogeneous EL)
- 个体学习器 (基学习器、弱学习器、分类器)

集成策略的好坏

- 个体学习器要有一定的准确性、并且要有一定的多样性 (Diversity, 或差异性) 即 “好且不同”

	测试例1	测试例2	测试例3
h_1	✓	✓	×
h_2	×	✓	✓
h_3	✓	×	✓
集成	✓	✓	✓

(a) 集成提升性能

	测试例1	测试例2	测试例3
h_1	✓	✓	×
h_2	✓	✓	×
h_3	✓	✓	×
集成	✓	✓	×

(b) 集成不起作用

	测试例1	测试例2	测试例3
h_1	✓	×	×
h_2	×	✓	×
h_3	×	×	✓
集成	×	×	×

(c) 集成起负作用

图 8.2 集成个体应 “好而不同” (h_i 表示第 i 个分类器)

集成分类器错误率上限


- 在基分类器的错误率相互独立的情况下，根据Hoeffding不等式，集成的错误率为：

$$\begin{aligned} P(H(\mathbf{x}) \neq f(\mathbf{x})) &= \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\epsilon)^k \epsilon^{T-k} \\ &\leq \exp\left(-\frac{1}{2}T(1-2\epsilon)^2\right). \end{aligned} \quad (8.3)$$


- 随着T(基分类器个数)的增大，错误率将指数级下降，并趋近于0
- 个体分类器目标相同、数据集相同，独立性很难成立
- 准确率与差异性的矛盾

2. Boosting历史

- Valiant和 Kearns于1984年、89年提出了 PAC学习模型中弱学习算法和强学习算法的等价性问题。
- 1990年, Schapire提出构造性证明 (有前提假设)
- 1993年, Freund提出投票多分类器
- 1995年, Freund和 Schapire(AT&T Bell Lab)改进了Boosting算法,提出了 AdaBoost (Adaptive Boosting)算法, 97年提出泛化误差上界。
- 2000年, Friedman和Hastie等人从统计角度重新解释AdaBoost
- 2003年, Freund和 Schapire获得理论计算机科学Gödel Prize




弱分类器：横向或纵向的分类面（比如，1层决策树）



第 1 次迭代


弱分类器：横向或纵向的分类面




第 3 次迭代

AdaBoost算法示意


弱分类器:




分类器 1



分类器 2



分类器 3



Algorithm 1: AdaBoost.M1

Input: 训练数据集 D , 子分类器学习算法, 迭代次数 T

Output: $F(x) = \sum_{t=1}^T \alpha_t f_t(\mathbf{x})$

- 1 初始化各训练样本权重 $\mathbf{w}_1^{(i)} = \frac{1}{m}$
- 2 **for** $t = 1, \dots, T$ **do**
- 3 使用带权重 $\mathbf{w}_t^{(i)}$ 的训练数据集 D 训练得到子分类器 $f_t(\mathbf{x})$
- 4 计算 $f_t(x)$ 的权重: $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$, 其中, 错误率 $\epsilon_t = \frac{\sum_{i=1}^m \mathbf{w}_i I(y^{(i)} \neq f_t(\mathbf{x}^{(i)}))}{\sum_{i=1}^m \mathbf{w}_i}$ 。当
 $\epsilon > 0.5$ 时 $\alpha_t = 0$
- 5 更新样本权重: $\mathbf{w}_{t+1}^{(i)} = \frac{\mathbf{w}_t^{(i)}}{Z_t} \exp(-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)}))$, 其中,
 $Z_t = \sum_{i=1}^m \mathbf{w}_t^{(i)} \exp(-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)}))$
- 6 **end**

- AdaBoost可以看作是加权(Re-weighting)的投票法:

$$F_T(\mathbf{x}) = \sum_{t=1}^T \alpha_t f_t(\mathbf{x})$$

2.2 AdaBoost的损失函数


- 使用指数函数(Exponential Loss Function)度量经验误差

$$F_T(\mathbf{x}) = \sum_{t=1}^T \alpha_t f_t(\mathbf{x})$$

$$\text{设 } w_t^{(i)} = e^{-y^{(i)} F_{t-1}(\mathbf{x}^{(i)})}$$

$$\begin{aligned} L(F_t(\mathbf{x})) &= \sum_{i=1}^m e^{-y^{(i)} F_t(\mathbf{x}^{(i)})} \\ &= \sum_{i=1}^m e^{-y^{(i)} F_{t-1}(\mathbf{x}^{(i)})} e^{-\alpha_t y^{(i)} f_t(\mathbf{x}^{(i)})} \\ &= \sum_{i=1}^m w_t^{(i)} e^{-\alpha_t y^{(i)} f_t(\mathbf{x}^{(i)})} \end{aligned}$$

$$L(\alpha_t f_t(\mathbf{x}) | \mathbf{w}_t) = \sum_{i=1}^m w_t^{(i)} e^{-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)})}$$



2.3.1 算法：AdaBoost弱分类器 f_t 的权重优化(求导=0)

$$\begin{aligned}
 \frac{\partial L(\alpha_t f_t(\mathbf{x}))}{\partial \alpha_t} &= \frac{\partial}{\partial \alpha_t} \sum_{i=1}^m e^{-y^{(i)}(F_{t-1}(\mathbf{x}^{(i)}) + \alpha_t f_t(\mathbf{x}^{(i)}))} \\
 &= \frac{\partial}{\partial \alpha_t} \sum_{i=1}^m w_t^{(i)} e^{-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)})} \quad \text{其中, } \epsilon_t = \frac{\sum_{i=1}^m w_t^{(i)} \mathbb{I}(y^{(i)} \neq f_t(\mathbf{x}^{(i)}))}{\sum_{i=1}^m w_t^{(i)}} \\
 &= - \sum_{i=1}^m w_t^{(i)} y^{(i)} f_t(\mathbf{x}^{(i)}) e^{-\alpha_t y^{(i)} f_t(\mathbf{x}^{(i)})} \\
 &= - e^{-\alpha_t} \sum_{i=1}^m w_t^{(i)} \mathbb{I}(y^{(i)} = f_t(\mathbf{x}^{(i)})) + e^{\alpha_t} \sum_{i=1}^m w_t^{(i)} \mathbb{I}(y^{(i)} \neq f_t(\mathbf{x}^{(i)})) \\
 &= - e^{-\alpha_t} (1 - \epsilon_t) w_t^{(i)} + e^{\alpha_t} \epsilon_t w_t^{(i)} = 0
 \end{aligned}$$

可得：

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$$

2.3.2 调整下一轮样本权重 w_t

- 【主要思路】：通过调整样本权重，使得加入新的基分类器 h_t 后，尽可能纠正之前的全部错误。

5 更新样本权重： $w_{t+1}^{(i)} = \frac{w_t^{(i)}}{Z_t} \exp(-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)}))$ ，其中，
 $Z_t = \sum_{i=1}^m w_t^{(i)} \exp(-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)}))$

$$\begin{aligned} L(F_t(\mathbf{x})) &= \sum_{i=1}^m e^{-y^{(i)} F_t(\mathbf{x}^{(i)})} \\ &= \sum_{i=1}^m e^{-y^{(i)} F_{t-1}(\mathbf{x}^{(i)})} e^{-\alpha_t y^{(i)} f_t(\mathbf{x}^{(i)})} \\ &= \sum_{i=1}^m w_t^{(i)} e^{-\alpha_t y^{(i)} f_t(\mathbf{x}^{(i)})} \end{aligned}$$

$$\begin{aligned} w_t^{(i)} &= e^{-y^{(i)} F_{t-1}(\mathbf{x}^{(i)})} \\ w_{t+1}^{(i)} &= e^{-y^{(i)} F_t(\mathbf{x}^{(i)})} \\ &= e^{-y^{(i)} F_{t-1}(\mathbf{x}^{(i)})} e^{-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)})} \\ &= w_t^{(i)} e^{-y^{(i)} \alpha_t f_t(\mathbf{x}^{(i)})} \end{aligned}$$

2.3.3 弱分类器 h_t -一层决策树

- 从训练数据集 D 的 n 个属性中选择最值得划分的属性。
- 度量属性 a 分类能力的度量 “信息增益” (Information Gain)

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v) . \quad (4.2)$$

“信息熵” (information entropy) 是度量样本集合纯度最常用的一种指标。假定当前样本集合 D 中第 k 类样本所占的比例为 p_k ($k = 1, 2, \dots, |\mathcal{Y}|$), 则 D 的信息熵定义为

$$\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k . \quad (4.1)$$

$\text{Ent}(D)$ 的值越小, 则 D 的纯度越高。

以购买电脑数据集为例

- 分割属性：当前数据集中具有最大信息增益的那个属性


Age	Income	Student	Credit_rating	Buys_computer
<=30	<2K	No	excellent	no
<=30	<2K	No	Fair	no
<=30	<2K	Yes	Fair	no
<=30	>=2K	No	excellent	yes
<=30	>=2K	Yes	fair	yes
31..40	>=2K	No	fair	yes
31..40	<2K	Yes	excellent	yes
31..40	<2K	Yes	excellent	yes
31..40	<2K	No	excellent	yes
31..40	>=2K	Yes	excellent	yes
>40	<2K	Yes	excellent	yes
>40	<2K	Yes	excellent	yes
>40	>=2K	No	fair	no
>40	<2K	Yes	fair	no

Algorithm 1: AdaBoost.M1


Input: 训练数据集 D , 子分类器学习算法, 迭代次数 T

Output: $F(x) = \sum_{t=1}^T \alpha_t f_t(x)$


- 1 初始化各训练样本权重 $w_1^{(i)} = \frac{1}{m}$
- 2 **for** $t = 1, \dots, T$ **do**
- 3 使用带权重 $w_t^{(i)}$ 的训练数据集 D 训练得到子分类器 $f_t(x)$
- 4 计算 $f_t(x)$ 的权重: $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$, 其中, 错误率 $\epsilon_t = \frac{\sum_{i=1}^m w_i I(y^{(i)} \neq f_t(x^{(i)}))}{\sum_{i=1}^m w_i}$ 。当
 $\epsilon > 0.5$ 时 $\alpha_t = 0$
- 5 更新样本权重: $w_{t+1}^{(i)} = \frac{w_t^{(i)}}{Z_t} \exp(-y^{(i)} \alpha_t f_t(x^{(i)}))$, 其中,
 $Z_t = \sum_{i=1}^m w_t^{(i)} \exp(-y^{(i)} \alpha_t f_t(x^{(i)}))$
- 6 **end**




弱分类器:




分类器 1





分类器 2



分类器 3




示意2：通过Reweighting获得子分类器



延伸：决策树分类器


- 从属性角度来递归分割训练样本的方式来获得决策树分类器
- 而分割属性则选择当前数据集中具有最大信息增益的那个属性

Age	Income	Student	Credit_rating	Buys_computer
<=30	<2K	No	excellent	no
<=30	<2K	No	Fair	no
<=30	<2K	Yes	Fair	no
<=30	>=2K	No	excellent	yes
<=30	>=2K	Yes	fair	yes
31..40	>=2K	No	fair	yes
31..40	<2K	Yes	excellent	yes
31..40	<2K	Yes	excellent	yes
31..40	<2K	No	excellent	yes
31..40	>=2K	Yes	excellent	yes
>40	<2K	Yes	excellent	yes
>40	<2K	Yes	excellent	yes
>40	>=2K	No	fair	no
>40	<2K	Yes	fair	no



通过划分来降熵

- 以AllElectronic数据训练决策树的根节点为例。



假定离散属性 a 有 V 个可能的取值 $\{a^1, a^2, \dots, a^V\}$, 若使用 a 来对样本集 D 进行划分, 则会产生 V 个分支结点, 其中第 v 个分支结点包含了 D 中所有在属性 a 上取值为 a^v 的样本, 记为 D^v .

01. 集成学习（个体与集成）
02. Boosting与AdaBoost
03. Bagging 与 Bootstrap抽样
04. Stacking

Bagging

- Bagging[Breiman, 1996a]: Bootstrap AGGREGatING(自举汇聚法)
- 靠抽样构建具有差异度的基模型, 相比之下, 属于级联算法



Bagging算法

$\mathcal{D}_{bs}$ 是自助采样产生的
样本分布.

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

- 1: **for** $t = 1, 2, \dots, T$ **do**
- 2: $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$
- 3: **end for**

输出: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y)$

图 8.5 Bagging 算法

Bootstrap Sampling(自助采样法)

- 给定包含 m 个样本的数据集 D , 我们对它进行 m 次放回采样, 得到数据集 D' 。改变了数据集分布, 引入了估计偏差。
- 样本在 m 次采样始终不被采到的概率是 $(1-1/m)^m$, 其极限为:


$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368, \quad (2.1)$$

- 对于样本规模小, 难以进行交叉检验时经常使用。


- 是一种策略，适于多分类、回归等任务。
- 抽样带来剩余样本，可以用作验证集，对泛化性能进行“包外估计” (out-of-bag estimation)
 - 决策树的剪枝
 - 降低样本对神经网络对的扰动等

随机森林(Random Forest)

- 以决策树为基学习器构建Bagging集成分类器;
- 在决策树的训练过程中引入了随机属性选择
 - 先从 d 个属性中随机选择 k 个属性 (如 $k=\log_2 d$)
 - 再从这 k 个属性中选择一个最优属性



(a) glass 数据集




(b) auto-mpg 数据集

图 8.7 在两个 UCI 数据上, 集成规模对随机森林与 Bagging 的影响

01. 集成学习（个体与集成）
02. Boosting与AdaBoost
03. Bagging 与 Bootstrap抽样
04. Stacking

- 使用机器学习技术根据基模型（子模型）的输出来预测最后的结果。



使用初级学习算法 $\mathcal{L}_t$
产生初级学习器 h_t .

生成次级训练集.

在 D' 上用次级学习算法 $\mathcal{L}$ 产生次级学习器 h' .

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
初级学习算法 $\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_T$;
次级学习算法 $\mathcal{L}$.

过程:

```
1: for  $t = 1, 2, \dots, T$  do
2:    $h_t = \mathcal{L}_t(D)$ ;
3: end for
4:  $D' = \emptyset$ ;
5: for  $i = 1, 2, \dots, m$  do
6:   for  $t = 1, 2, \dots, T$  do
7:      $z_{it} = h_t(\mathbf{x}_i)$ ;
8:   end for
9:    $D' = D' \cup ((z_{i1}, z_{i2}, \dots, z_{iT}), y_i)$ ;
10: end for
11:  $h' = \mathcal{L}(D')$ ;
输出:  $H(\mathbf{x}) = h'(h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_T(\mathbf{x}))$ 
```

图 8.9 Stacking 算法

- 集成学习（个体与集成）
- Boosting (Re-weighting)与AdaBoost
- Bagging 与 Bootstrap抽样 (Re-sampling)
- Stacking